

Doble Grado en Ingeniería Informática y Administración de
Empresas
2024-2025

Trabajo Fin de Grado

“Técnicas de búsqueda para navegación
de UAVs en entornos con incertidumbre”

Alejandro Blanco Fernández

Tutores

Jesús García Herrero

Juan Pedro Llerena Caña

Campus de Colmenarejo, junio de 2025



Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento - No Comercial - Sin Obra Derivada**

RESUMEN

El reparto de mercancías a usuarios individuales está experimentando desde hace años un crecimiento elevado gracias, en gran medida, a las grandes plataformas de venta *online* y a la reducción de costes de reparto. Las estrategias de reparto generalmente empleadas permiten la entrega de productos de bajo coste ya que los beneficios de estas se basan en la entrega diaria de grandes volúmenes de mercancía. A su vez, esto permite generar redes de reparto a nivel local que pueden aumentar su frecuencia de reparto.

Generalmente, la forma de indicar la zona de entrega se basa en direcciones postales, que supone un gran problema cuando la dirección de entrega corresponde a una gran extensión de terreno como puede suceder en zonas rurales. Además, cuando en un reparto no se identifica donde se tiene que entregar la mercancía, supone un retraso que se propaga al conjunto de la estrategia de reparto en un coste adicional a la empresa de reparto.

En dichos contextos de reparto complejo, se están estudiando la viabilidad del uso de sistemas aéreos no tripulados (UAS- *Unmanned Aerial System*) mediante drones como plataformas aéreas. Sin embargo, las estrategias de entrega requieren una dirección geolocalizada donde se colocan pequeñas superficies de aterrizaje que pueden identificar los drones. Esto requiere que la aeronave se aproxime a dicha región geolocalizada, que implica un alto grado de incertidumbre a la empresa al tener que interactuar el usuario. En estos casos, si la mercancía no se entrega el coste será aún más elevado que en regiones urbanas.

En este Trabajo de Fin de Grado se presenta un sistema de reparto de mercancías para vehículos aéreos no tripulados empleando un sistema de búsqueda de la zona de entrega que se sustenta en diferentes estrategias de búsqueda en espacios con incertidumbre. Concretamente, se presenta un caso de uso de reparto en el contexto del Campus de Colmenarejo, la Universidad Carlos III de Madrid en el que se modela la incertidumbre del espacio de búsqueda y la procedente de sistema de detección.

Los resultados obtenidos demuestran que se pueden reproducir con fiabilidad la trayectoria teórica en un vuelo simulado, pese a tener diferencias, que se deben, entre otros, a las limitaciones físicas del dron y en el sistema de control o errores en los sensores. El sistema construido da soporte a futuras líneas de investigación sobre el vuelo de drones desde el nombre de una calle hasta una simulación realista en 3D.

Palabras clave: UAVs, planificación de trayectorias, análisis de datos, simulación en AirSim, comparación de trayectorias.

DEDICATORIA

Dedico este trabajo a mis padres, que siempre han sido una fuente de inspiración y apoyo incondicional. Agradezco la confianza que depositan en mí y su motivación para alcanzar mis objetivos.

ÍNDICE GENERAL

1. INTRODUCCIÓN.	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Entorno socioeconómico	2
1.3.1. Presupuesto del proyecto	3
1.4. Marco regulador	4
1.5. Estructura	7
2. ESTADO DEL ARTE.	9
2.1. Contexto histórico	9
2.2. Clasificación actual de los drones.	12
2.2.1. Diseño.	12
2.2.2. Uso	13
2.2.3. Sistema de control	14
2.3. Formulación de la planificación.	15
2.3.1. Modelo Probabilístico de la Posición Inicial del Objetivo	15
2.3.2. Dinámica del UAV	16
2.3.3. Modelo del objetivo:.	17
2.3.4. Modelo de Sensor	17
2.3.5. Integración de fuentes de información	18
2.4. Notación	18
3. PROPUESTA	21
3.1. Inicialización del problema	22
3.2. Visualización de algoritmos	31
3.2.1. Evaluación de trayectorias de los algoritmos	40
3.3. Entorno de simulación.	56
3.3.1. Herramientas de la simulación	57

4. EVALUACIÓN DE LA PROPUESTA	63
4.1. Comparación de algoritmos	65
4.1.1. Heurística Miope	68
4.1.2. Heurística	70
4.1.3. Lawnmower.	72
4.1.4. Expanding	74
4.2. Observaciones generales.	76
5. CONCLUSIONES	77
5.1. Futuras líneas de trabajo.	77
5.2. Gestión del proyecto	78
6. ANEXO	80
6.1. Anexo 1	80
6.2. Anexo 2: Declaración de uso de IA Generativa en el TFG	80
BIBLIOGRAFÍA	85

ÍNDICE DE FIGURAS

1.1	Proyección de crecimiento en el valor del mercado de drones [2].	3
1.2	Tipos de sistemas de aeronave no tripulada [3].	5
1.3	Categorías de operación de los UAS [3].	6
1.4	Restricción geográfica de vuelo en el campus de Colmenarejo [4].	7
2.1	Diseño de helicóptero primitivo hecho por Leonard Da Vinci [5].	9
2.2	Planeador de George Cayley, de 1852 [7].	10
2.3	Un prototipo del Kettering Bug en 1918 [8].	11
2.4	Un dron moderno [9].	12
2.5	Clasificación de drones [11].	12
2.6	Dron de ala fija a la izquierda [12] y de ala rotatoria a la derecha [13]. . .	13
2.7	Dron militar Reaper [14].	14
2.8	Dron controlado remotamente por un niño [15].	15
3.1	Bloques en que se divide la propuesta.	22
3.2	Esquema del flujo de trabajo de la Inicialización del problema.	23
3.3	Sistema de Coordenadas Geodésicas [27].	24
3.4	Sistema de Coordenadas Geocéntricas. [27]	25
3.5	Marco de referencia ENU. [28]	25
3.6	Transformaciones de sistemas de referencia.	27
3.7	Ángulo de rotación φ entre sistemas.	29
3.8	Representación gráfica del mapa inicial del caso de uso.	31
3.9	Esquema del flujo de trabajo de la Visualización de algoritmos.	32
3.10	Mapa inicial con la posición inicial del dron elegida por el usuario.	33
3.11	Posición inicial del dron con respecto al sistema de referencia A.	34
3.12	Rotación y traslación del sistema de referencia A a ENU.	35
3.13	Trayectoria hallada para el sistema del planificador sin reescalar.	36
3.14	Planificación de la trayectoria para el algoritmo Heurística Miope.	36
3.15	Visualización en QGroundControl de la trayectoria planificada.	37

3.16 Experimento 1: posición inicial del dron fija en (40, 40) y del objetivo aleatoria.	40
3.17 Promedio de la distancia y pasos por algoritmo.	41
3.18 Porcentaje de casos de éxitos y fracasos por algoritmo.	42
3.19 Boxplots de los pasos dados para cada uno de los algoritmos.	43
3.20 Histogramas con la distribución de los pasos para cada algoritmo.	43
3.21 Función de distribución acumulada por algoritmo.	44
3.22 Experimento 2: posición inicial del dron aleatoria y del objetivo fija en (20, 30).	45
3.23 Promedio de la distancia y pasos por algoritmo.	46
3.24 Porcentaje de casos de éxitos y fracasos por algoritmo.	47
3.25 Boxplots de los pasos dados para cada uno de los algoritmos.	47
3.26 Histogramas con la distribución de los pasos para cada algoritmo.	48
3.27 Función de distribución acumulada por algoritmo.	49
3.28 Experimento 3: posición inicial del dron y del objetivo aleatoria.	50
3.29 Promedio de la distancia y pasos por algoritmo.	51
3.30 Porcentaje de casos de éxitos y fracasos por algoritmo.	51
3.31 Boxplots de los pasos dados para cada uno de los algoritmos.	52
3.32 Histogramas con la distribución de los pasos para cada algoritmo.	53
3.33 Función de distribución acumulada por algoritmo.	54
3.34 Número de pasos requeridos por algoritmo y experimento.	55
3.35 Esquema del flujo de trabajo de la Simulación de algoritmos en AirSim.	56
3.36 Simulador AirSim con Unreal Engine en el Campus de Colmenarejo.	57
3.37 Dron de vuelo en AirSim.	58
3.38 Ejemplo de ArUco.	58
3.39 Interfaz gráfica de la estación de control terrestre QGroundControl.	59
3.40 Arquitectura de MAVLink con PX4 [31].	59
3.41 Estructura de un mensaje MAVLink [32].	60
3.42 Intercambio de mensajes entre el simulador y el flight stack de PX4 [33].	61
3.43 Componentes de un sistema SITL [33].	61
3.44 Configuración del <i>firmware</i> con QGC [35].	62

4.1	Configuración del <i>firmware</i> con QGC [37].	64
4.2	Matriz de coste para minimizar la distancia acumulada entre dos series temporales[39].	65
4.3	Datos de la trayectoria planificada en coordenadas locales.	66
4.4	Datos del <i>ground truth</i> de una misión.	66
4.5	Planificación y simulación de vuelo de la Heurística Miope.	68
4.6	Aterrizaje con éxito de la Heurística Miope.	69
4.7	Comparación de la trayectoria teórica y la real con la Heurística Miope.	69
4.8	Dynamic Time Warping de la Heurística Miope.	70
4.9	Planificación y simulación de vuelo de la Heurística.	70
4.10	Aterrizaje con éxito de la Heurística.	71
4.11	Comparación de la trayectoria teórica y la real con la Heurística.	71
4.12	Dynamic Time Warping de la Heurística.	72
4.13	Planificación y simulación de vuelo del Lawnmower.	72
4.14	Aterrizaje con éxito del <i>Lawnmower</i>	73
4.15	Comparación de la trayectoria teórica y la real con el <i>Lawnmower</i>	73
4.16	Dynamic Time Warping del <i>Lawnmower</i>	74
4.17	Planificación y simulación de vuelo del Expanding.	74
4.18	Aterrizaje con éxito del Expanding.	75
4.19	Comparación de la trayectoria teórica y la real con el <i>Expanding</i>	75
4.20	Dynamic Time Warping del <i>Expanding</i>	76
5.1	Diagrama de Gantt del trabajo realizado.	79

ÍNDICE DE TABLAS

1.1	Presupuesto estimado del proyecto con desglose por horas y tarifas	4
3.1	Comparación de las trayectorias para distintos algoritmos.	38
3.2	Estadísticas descriptivas de las distancias del Experimento 1.	41
3.3	Estadísticas descriptivas de las distancias del Experimento 2.	46
3.4	Estadísticas descriptivas de las distancias del Experimento 3.	50
4.1	Parámetros comunes utilizados en la comparación de algoritmos	68
4.2	Comparativa de distancia DTW entre algoritmos y distancia promedio por emparejamiento.	76

GLOSARIO

AESA	<i>Agencia Estatal de Seguridad Aérea</i>
EASA	<i>European Aviation Safety Agency</i>
ENU	<i>East, North, Up</i>
CGS	<i>Control Ground System</i>
DTW	<i>Dynamic Time Warping</i>
MTS	<i>Minimum Time Search</i>
SAR	<i>Search and Rescue</i>
RBF	<i>Recursive Bayesian Filter</i>
UAS	<i>Unmanned Aircraft System</i>
UAV	<i>Unmanned Aerial Vehicle</i>
VLOS	<i>Visual Line of Sight</i>

1. INTRODUCCIÓN

1.1. Motivación

El uso de vehículos aéreos no tripulados (UAVs) en tareas de reparto ha surgido como una solución innovadora ante la complejidad de la logística moderna. En aplicaciones como el envío de paquetes o la distribución en áreas de difícil acceso, los drones pueden ofrecer entregas autónomas y eficientes que superan las limitaciones de los métodos tradicionales.

A pesar de su utilidad en la teoría, el despliegue de este tipo de sistemas plantea problemas de planificación, sobre todo en entornos donde la información no es completa, es complejo. Algunos factores, como los errores de localización, coordinación de varios drones o condiciones dinámicas del entorno, introducen el concepto de incertidumbre en el proceso de búsqueda. Por tanto, surge la necesidad de diseñar algoritmos capaces de localizar el objetivo de forma rápida que minimicen el tiempo de búsqueda incluso cuando no se conoce su posición exacta.

En este sentido, la incertidumbre juega un papel muy importante en estos problemas. El desconocimiento de la posición del objetivo supone que el dron se debe guiar por algún tipo de información, llamado indicio, que le pueda acercar a la zona de interés. Es por ello que, en un inicio, los UAVs empiezan con un mínimo conocimiento de la situación y, en función del tipo de trayectoria y cada instante de tiempo, actualiza su posición.

En este tipo de problemas, los métodos clásicos de planificación determinista han sido los más utilizados, pero también existen técnicas, como la búsqueda activa, los sistemas parcialmente observables (POMDPs), o las búsquedas en tiempo mínimo (MTS), que abordan directamente la necesidad de minimizar el tiempo necesario para localizar el objetivo en entornos inciertos.

Este último, en concreto, la búsqueda de objetivos dentro de un espacio es un problema que se ha estudiado desde la Segunda Guerra Mundial. En cambio, en versiones más modernas, además, se intenta minimizar el tiempo de esa búsqueda, y que aparece en diversas aplicaciones, como en operaciones militares como en misiones de búsqueda y rescate tras un desastre natural. Combina elementos de planificación de trayectorias y gestión de incertidumbre, y tiene especial relevancia en el ámbito de los sistemas autónomos, donde los recursos son limitados y se necesita tener una estrategia efectiva.

Este trabajo propone un sistema para el reparto de paquetes con drones. A través de simulaciones con AirSim y QGroundControl, se implementan y analizan técnicas de planificación adaptadas a entornos inciertos, donde sólo se tienen escasos indicios de donde se encuentra el objetivo. El entorno de simulación construido sirve como base sobre la que en trabajos futuros se podrán implementar otras técnicas como la exploración multiagente, aprendizaje activo o planificación predictiva.

1.2. Objetivos

Este trabajo tiene como objetivo principal el desarrollo de un sistema de búsqueda en espacios con incertidumbre que pueda ser desplegado en drones de reparto. Para ello se establecen los siguientes objetivos secundarios:

- **Objetivo 1:** Capturar y segmentar las coordenadas de las distintas fuentes de información que construyen el escenario.
- **Objetivo 2:** Planificar trayectorias y ejecución de las mismas en simulación.
- **Objetivo 3:** Evaluar la trayectoria teórica planificada frente a la trayectoria de vuelo en simulación hiperrealista.

1.3. Entorno socioeconómico

El uso extenso de drones está transformando de manera significativa el panorama económico y social. El avance en transporte aéreo supone múltiples beneficios que abarcan desde la eficiencia operativa hasta la sostenibilidad medioambiental. Algunos aspectos sobre los que tienen efecto son [1]:

- **Reducción de costes operativos:** la entrega de paquetes permite a las empresas disminuir los costes asociados con vehículos terrestres, como adquisición, mantenimiento, combustible y seguros.
- **Eficiencia de las entregas:** los drones pueden realizar entregas en poco tiempo, por lo que en áreas densamente pobladas proponen una solución para la congestión de tráfico. Además, tienen un acceso privilegiado a zonas remotas o destruidas, donde pueden superar los límites de la infraestructura.
- **Generación de empleo:** abre nuevas posibilidades de trabajo en sectores de ingeniería, logística y operaciones. La creciente inversión en este sector se ve reflejada en los puestos de trabajo que crea.
- **Sostenibilidad ambiental:** contribuye a la sostenibilidad ambiental al reducir las emisiones de carbono.

La navegación no tripulada es una industria que se encuentra en expansión. A día de hoy, el mercado se estima en un valor en torno a 40 mil millones de dólares, que, con una tasa de crecimiento anual compuesta del 13,90 % (CAGR), alcanzará aproximadamente 70 mil millones de dólares en 2029 [2].




Fig. 1.1. Proyección de crecimiento en el valor del mercado de drones [2].

Entre otros, los drones están reemplazando rápidamente a los métodos tradicionales en la vigilancia terrestre, puesto que ofrecen una reducción significativa de la mano de obra y el tiempo necesario para capturar datos. Además, se utilizan cada vez más para inspecciones visuales en zonas de alto riesgo en obras de construcción, por lo que mejoran la eficiencia de la comunicación y la gestión mediante la recopilación de datos en tiempo real.

Sin embargo, el crecimiento del mercado de drones puede verse obstaculizado por limitaciones tecnológicas, como los relacionados con el tamaño, peso y potencia, así como por la presencia de regulaciones que pueden restringir el uso de estos sistemas en el espacio aéreo.

1.3.1. Presupuesto del proyecto

También se ha llevado a cabo un análisis del coste en que se concurriría en caso de materializar este proyecto en un escenario realista. A continuación se desglosan los distintos costes asociados al proceso y su cuantificación correspondiente:

Concepto	Detalle	Coste estimado (€)
Desarrollo de software	30 horas (20€/hora) – Implementación de scripts, módulos de búsqueda, análisis de datos, etc.	600
Simulación con AirSim	10 horas (15€/hora) – Configuración de escenarios y pruebas de vuelo.	150
Uso de hardware	Amortización proporcional por uso intensivo de CPU/GPU durante 50 horas de desarrollo.	200
Documentación del proyecto	10 horas (10€/hora) – Redacción de memoria, generación de gráficos, compilación en LaTeX.	100
Investigación y revisión técnica	10 horas (10€/hora) – Lectura y análisis del estado del arte.	100
Supervisión	10 horas (30€/hora) – Reuniones periódicas y revisión.	300
Total estimado		1.450

TABLA 1.1. PRESUPUESTO ESTIMADO DEL PROYECTO CON DESGLOSE POR HORAS Y TARIFAS

1.4. Marco regulador

Existen diferentes términos a tener en cuenta para referirse a las aeronaves no tripuladas que recoge la normativa [3]:

- **Dron:** es el término más común y generalizado para referirse a los vehículos aéreos no tripulados. Se suele usar a nivel coloquial para sistemas voladores pequeños, pero también incluye otros tipos de vehículos autónomos o controlados remotamente.
- **Sistema de aeronave no tripulada (UAS):** no sólo engloba al dron como aeronave, sino también al conjunto de componentes que forman el sistema, como, por ejemplo, la estación de control y los enlaces de comunicación. Es de carácter técnico y se usa en contextos profesionales y regulatorios.
- **Sistema de aeronave pilotada por control remoto (RPAS):** es una categoría dentro de los UAS que se refiere a aquellos dispositivos que cuentan con un piloto remoto humano que opera la aeronave, es decir, que la toma de decisiones no es autónoma.



Fig. 1.2. Tipos de sistemas de aeronave no tripulada [3].

El vuelo de drones está regulado por la EASA, que se encarga de unificar los estándares comunes en todos los Estados miembros para velar por la seguridad de las operaciones en la aviación civil, y la AESA, cuya función principal consiste en asegurarse del cumplimiento de las normas de aviación civil en el conjunto de la actividad aeronáutica en España [3].

Con respecto al marco normativo, en junio de 2019, entraron en vigor dos reglamentos desarrollados por la EASA para regular los drones (UAS), así como su utilización en todos los Estados miembros:

- **Reglamento Delegado (UE) 2019/945 de la Comisión:** establece los requisitos para el diseño, fabricación y comercialización de drones utilizados principalmente en la categoría «abierta». Define las clases C0 a C4 según el tipo de uso y riesgo asociado, y aplica, tanto a fabricantes europeos como a operadores de terceros países que vuelen en el espacio aéreo del Cielo Único Europeo. Este reglamento fue modificado por el Reglamento Delegado (UE) 2020/1058, que introdujo las clases C5 y C6 para operaciones en escenarios estándar europeos.
- **Reglamento de Ejecución (UE) 2019/947 de la Comisión:** regula el uso operativo de drones, incluyendo los requisitos para los pilotos a distancia, operadores y organizaciones implicadas. Establece las normas para las categorías de operación (abierta, específica y certificada) y ha sido modificado por varios reglamentos posteriores que introducen requisitos para escenarios estándar (STS), así como aplazamientos de fechas clave debido a la pandemia de COVID-19 y a la implementación progresiva de medidas como la identificación a distancia y el uso de luces verdes para vuelos nocturnos.

Además, el Reglamento de Ejecución 2019/947 describe tres categorías de operación de los UAS:

- **Categoría abierta:** dedicada a operaciones de bajo riesgo, tanto recreativas como profesionales, que no requieren autorización previa por parte de la AESA. Está

restringida a drones de hasta 25 kg, que deben volar dentro del alcance visual del piloto, VLOS, y a una altura máxima de 120 metros. Además, se distribuye en tres subcategorías: A1, A2 y A3, que dependen del peso del dron y la distancia mínima a las personas que no interactúan.

- **Categoría específica:** orientada a operaciones que implican un riesgo moderado y que no pueden cumplir todas las condiciones de la categoría anterior. Requiere una evaluación de riesgos por parte del operador y, en muchos casos, una autorización por parte de la AESA para llevar a cabo la misión.
- **Categoría certificada:** dirigida a operaciones de alto riesgo, como el transporte de mercancías peligrosas o de personas. Se requiere la certificación del dron, del operador y, en ciertos casos, del piloto, y también se deben cumplir con requisitos técnicos y de seguridad similares a los de la aviación tripulada.



Fig. 1.3. Categorías de operación de los UAS [3].

Otro aspecto importante a tener en cuenta es la restricción geográfica de vuelo. No todas las zonas están bajo la misma regulación y se distinguen por colores [4]: las zonas rojas están prohibidas, salvo autoridad expresa, para sobrevolarlas debido a que son zonas de espacio aéreo controlado, como aeropuertos o zonas militares; las zonas amarillo o marrón tienen advertencias o requisitos adicionales; y las zonas naranjas están limitadas para un vuelo bajo ciertas condiciones (altitud, tipo de dron, etc.).



Fig. 1.4. Restricción geográfica de vuelo en el campus de Colmenarejo [4].

1.5. Estructura

Este trabajo se divide en diferentes capítulos que permiten dar respuesta a los objetivos planteados:

2. **Estado del arte:** se realiza una revisión de la situación actual de los drones y sus funciones en el reparto de mercancías.
3. **Formulación del problema:** se explica el problema definiendo sus características y la implementación de ciertos aspectos adicionales.
4. **Propuesta y experimentación:** se desarrolla la propuesta de valor del trabajo, así como la metodología usada con la que se analizan los resultados obtenidos en las

pruebas.

5. **Evaluación de la propuesta:** se indaga a posteriori en la diferencia del cálculo de vuelo teórico y real, es decir, las disimilitudes entre la planificación de la trayectoria y el vuelo en el simulador.
6. **Conclusiones:** finalmente se explican las conclusiones del trabajo, que abarcan los objetivos que se han completado y se presentan algunas posibles líneas de investigación para futuros trabajos en este campo.

2. ESTADO DEL ARTE

2.1. Contexto histórico

La historia del reparto con drones es relativamente reciente, aunque los conceptos de UAVs se remontan a siglos atrás. Si bien no existían en un sentido moderno, ya en el siglo XV se mostraba interés por la aviación, cuando Leonardo Da Vinci diseñó varias máquinas que pudiesen levantar el ser humano del suelo [5]. Incidía en la idea de que el ser humano no contaba con la musculatura suficientemente potente como para alzar el vuelo y tuvo fe en que la clave del éxito estaba en las corrientes de aire.



Fig. 2.1. Diseño de helicóptero primitivo hecho por Leonard Da Vinci [5].

A medida que la tecnología avanzaba, en el siglo XIX, el inventor británico George Cayley, considerado el "padre de la aerodinámica", tuvo contribuciones fundamentales sobre su campo con algunos planeadores no tripulados. Identificó las 4 fuerzas que caracterizan un vuelo, sustentación, resistencia, peso y empuje, que marcarían la base científica sobre la que a día de hoy se sustenta cualquiera aeronave, sea tripulada o no [6].





Fig. 2.2. Planeador de George Cayley, de 1852 [7].

Más adelante, durante la Primera Guerra Mundial, se desarrollaron los primeros prototipos de aeronaves con fines militares. Entre ellos, destaca el "Kettering Bug", diseñado por Elmer Sperry y Charles Kettering para el ejército estadounidense. Se trataba de un avión guiado por un sistema de control programado y cargado con una bomba explosiva. Aunque no era controlado remotamente como los UAVs de hoy en día, el "Kettering Bug" representa uno de los primeros intentos de desarrollar un vehículo aéreo no tripulado con capacidad de ataque [8].




Fig. 2.3. Un prototipo del Kettering Bug en 1918 [8].

Desde entonces, se produjeron avances importantes en el desarrollo de tecnologías de control remoto, como fue el caso del Telekino, creado por John Hays Hammond, un ingeniero estadounidense, y que permitía controlar barcos de manera inalámbrica. Aunque no estaba aplicado directamente sobre el ámbito aéreo en una primera instancia, se demostró la capacidad del control remoto para vehículos no tripulados. A su vez, también se comenzó a experimentar con aeronaves no tripuladas para entrenamiento antiaéreo y misiones de reconocimiento, por ejemplo, durante la Guerra de Corea entorno a los años 50. En ese conflicto, se emplearon aeronaves como el RP-71 Falconer, un UAV encargado de realizar esos vuelos de reconocimiento [9].

Ya en los años 80, el ingeniero Abraham Karem creó su empresa, Leading Systems Inc., y diseñó el Albatross, un UAV autónomo muy superior a sus predecesores. Se perfeccionó posteriormente su diseño con el modelo Amber, que se utilizaría como base para el desarrollo del MQ-1 Predator, uno de los drones más conocidos y representativos a día de hoy [10].

A partir de los años 2000, el uso de las aeronaves no tripuladas se expandió a otras áreas, ya no sólo militares, sino también comerciales, como la fotografía, agricultura, vigilancia y entrega de paquetes [9]. A día de hoy se constituye como un mercado de transporte en pleno crecimiento y que promueve el desarrollo tecnológico y el impacto socioeconómico en todos los ámbitos de la vida de los seres humanos.



Fig. 2.4. Un dron moderno [9].

2.2. Clasificación actual de los drones

Los drones pueden ser clasificados según distintos criterios, como, por ejemplo, las aplicaciones para las que se usan, el diseño técnico o la regulación legal. En este trabajo se dividen en tres categorías [11]:




Fig. 2.5. Clasificación de drones [11].

2.2.1. Diseño

La clasificación por diseño se refiere a su estructura física, y el tipo de ala es la característica principal del dron. Esta categoría se divide en dos a su vez: ala fija y ala rotatoria.

- **Ala fija:** al tener las alas fijas, tienen una mayor sustentación y se asemejan a un avión convencional. Son más eficientes porque su diseño les permite planear a la hora de cubrir grandes distancias de espacio, por lo que tienen un menor consumo de energía y sirven para vuelos de larga duración. Además, suelen tener una

mayor capacidad de carga comparado con los de ala rotatoria y cuentan con una gran estabilidad de vuelo, por lo que son más fiables en condiciones climatológicas adversas.

- **Ala rotatoria:** tienen rotores que giran para generar la sustentación y mantener el vuelo. Su diseño les produce una mayor maniobrabilidad y agilidad en el aire, que se traduce en cambios rápidos de dirección u otros movimientos precisos. En contrapartida a su análogo, la rotación de sus alas da la posibilidad a mantenerse en vuelo estacionario en un punto en el aire, como si fuese una técnica de flote. A pesar de su menor autonomía en términos generales, estos drones son versátiles porque pueden cargar con cámaras, sensores y otros equipos de telemetría.



Fig. 2.6. Dron de ala fija a la izquierda [12] y de ala rotatoria a la derecha [13].

2.2.2. Uso

También se pueden clasificar según el ámbito en que se usan, como el entorno civil y militar, que influye en las capacidades técnicas y normativas aplicables.

- **Civil:** es el conocido uso comercial y es donde se encuentran la gran mayoría de drones en la actualidad dado que incluye distintas aplicaciones de uso, desde los más sencillos para niños hasta fotografía, topografía, inspección técnica, protección civil, seguridad, reparto de paquetes, etc. Suelen estar sujetos a estrictas regulaciones y se suelen usar en entornos urbanos
- **Militar:** en cambio, están diseñados para las estrategias de ataque militares. Tienen mayor autonomía, capacidad de carga y sistemas de comunicación, pero son muy escasos comparados con los civiles. Han tenido un gran desarrollo tecnológico desde el siglo XX debido a intereses bélicos que ha derivado en debates éticos sobre el uso de la fuerza aeronáutica y la responsabilidad en caso de errores.



Fig. 2.7. Dron militar Reaper [14].

2.2.3. Sistema de control

La forma en que se tiene control sobre la aeronave es la tercera forma de clasificación que se utiliza.

- **Autónomo:** tiene programada la ruta que van a seguir, por lo que no necesitan la intervención directa del operador o piloto en tiempo real. Utilizan sistemas avanzados de navegación, como GPS y sensores, y se suelen usar para cartografía y misiones de investigación científica.
- **Remoto:** son los más populares y se controlan mediante ondas de radio. El piloto u operador utilizar el control remoto para enviar comandos que controlan el movimiento de la nave en tiempo real. Pueden ser utilizados tanto por aficionados como por profesionales en un gran espectro de aplicaciones.
- **Supervisado:** se controlan mediante un aplicación móvil o dispositivo inteligente a través de Wi-Fi o Bluetooth. Es común que ofrezcan una interfaz para controlar el vuelo y estén diseñados para usuarios menos experimentados.



Fig. 2.8. Dron controlado remotamente por un niño [15].

2.3. Formulación de la planificación

En aplicaciones como la entrega de paquetes, la eficiencia de la trayectoria que realiza el dron es clave, no sólo por los cortos tiempos de espera, sino también por otros aspectos que se deben tener en cuenta, como su autonomía o la restricción geográfica de vuelo. Por lo tanto, es crucial tener una planificación de la ruta que va a seguir el dron en la mayor brevedad posible, es decir, se quiere modelar un problema de espacio con incertidumbre para que el dron encuentre el objetivo. En este contexto, se aborda el problema de primera mano, pero cabe destacar que, pese a no haber sido el pilar fundamental del trabajo, sí que ha sido útil a la hora de definir el problema y crear el caso de uso, sobre todo porque deja abierta una posible línea futura de investigación que utilice el sistema planteado en este trabajo.

En el problema MTS, se considera un conjunto de U UAVs que sobrevuelan un área de búsqueda Ω , discretizada en una cuadrícula G_Ω de celdas cuadradas de dimensiones $w_x \cdot w_y$, con el objetivo de detectar la presencia de un único objetivo ubicado dentro de ella. La resolución de la cuadrícula determina el nivel de detalle en la representación de la posición del objetivo.

Debido a la incertidumbre asociada con la posición y la dinámica del objetivo, así como con las mediciones del sensor a bordo de cada UAV, el problema MTS se formula dentro del marco probabilístico introducido en [16].

2.3.1. Modelo Probabilístico de la Posición Inicial del Objetivo

El mapa de probabilidades del objetivo, denotado como $b(v^t) = P(v^t)$, contiene toda la información disponible sobre la ubicación del objetivo en el tiempo t . Este mapa asigna a cada posición dentro del área de búsqueda Ω una probabilidad que refleja la creencia de que el objetivo se encuentra en esa ubicación. Se asume como hipótesis que el objetivo se encuentra dentro de Ω por lo que el mapa de creencias cumple 2.1.

$$\sum_{v_0 \in G_\Omega} P(v_0) = \sum_{v_0 \in G_\Omega} b(v_0) = 1. \quad (2.1)$$

La posición del objetivo en el tiempo t se representa como una variable aleatoria v_t . Esta variable indica que la posición del objetivo no es fija ni conocida con certeza, sino que está distribuida probabilísticamente en el espacio de búsqueda Ω .

Para definir el mapa de probabilidad inicial $b(v_0) \equiv P(v_0)$, se discretiza uniformemente el área de búsqueda rectangular Ω , quedando ésta dividida en una red G_Ω de $w_x \cdot w_y$ celdas. Una vez discretizada Ω , se asigna a cada celda del mapa una probabilidad de que el objetivo se encuentre en ella.

En el trabajo de [17] para asignar dichas probabilidades, se proponen combinar la información sobre la localización del objetivo procedente de J fuentes de información diferentes mediante (2.2), donde $b_j(v_0)$ es la capa de probabilidad de la fuente de información j y w_j el peso que el operador asigna a dicha fuente de información de acuerdo a su fiabilidad.

$$b(v_0) = \frac{1}{\sum_{j=1}^J w_j} \sum_{j=1}^J w_j \cdot b_j(v_0). \quad (2.2)$$

En operaciones marítimas SAR (*Search And Rescue*) también es común utilizar el modelado mediante un conjunto finito de partículas inicial τ_0^i , que se conocen como indicios [18]. Cada partícula representa una posible localización del objetivo, donde cada una tiene un peso w_0^i , que es mayor conforme más probable es que se encuentre ahí. Los tipos de muestreo de partículas iniciales pueden ser [19], [20]:

- **Última posición conocida (LKP):** se utiliza cuando se conoce la posición aproximada del naufragio. La posición x e y de las partículas ($\tau_0^i = [\tau_{0,i,x}, \tau_{0,i,y}]$) se calcula a partir de una distribución gaussiana bidimensional centrada en el punto y con una varianza asociada a la incertidumbre en el lugar del naufragio.
- **Última trayectoria conocida (LKT):** en los casos que se conoce la ruta pero no el lugar del naufragio. Se calculan gaussianas bidimensionales equi-espaciadas en los puntos de la trayectoria.

En ambos casos, los pesos de las partículas se igualan a $w_0^i = \frac{1}{N}$, siendo N el número de partículas generadas, por lo tanto, se obtiene una equi-probabilidad de la localización del objetivo.

2.3.2. Dinámica del UAV

Los UAVs realizan movimientos de decisión en pasos de tiempo discretos dentro de un intervalo de tiempo Δ . El modelo determinista de la dinámica de los UAVs está definido por (2.3).

$$s_u^{t+1} = f(s_u^t, c_u^t), \quad (2.3)$$

donde s_u^{t+1} es la posición del UAV u en el paso de tiempo $t + 1$, s_u^t representa la posición previa del UAV u en el paso de tiempo t , y c_u^t es la acción de control aplicada en ese instante.

El uso de modelos dinámicos de UAV permite a los algoritmos de búsqueda probabilística (*PS*, *Probabilistic Search*) definir las trayectorias de los UAVs ya sea mediante las posiciones $s_{1:U}^{0:t}$ de los UAVs, o mediante las posiciones iniciales $s_{1:U}^0$ de los UAVs y la secuencia de acciones de control $c_{1:U}^{1:t}$. Esto habilita tomar como variables de decisión las trayectorias de búsqueda o las secuencias de acciones de control, aprovechando la posibilidad de obtener indirectamente trayectorias que cumplen con las restricciones dinámicas implícitas en (2.3).

Sin embargo, también existen los modelos complejos o continuos [21] que no se restringen a las celdas de una cuadrícula, sino que permiten que el UAV se mueva a cualquier posición dentro de Ω mediante comandos de bajo nivel o secuencias de variables continuas (como consignas de velocidad, rumbo, altura) [22]. Se suelen utilizar para drones de ala fija, que tienen restricciones dinámicas más estrictas que los de ala rotatoria, con herramientas como Simulink, que puede capturar dinámicas de alto nivel, como el consumo de combustible, altura, velocidad y dinámica lateral.

2.3.3. Modelo del objetivo:

La información disponible sobre la dinámica del objetivo se modela mediante el modelo dinámico del objetivo $P(v^t|v^{t-1})$, que describe la probabilidad de que el objetivo se desplace de una celda v^{t-1} a otra v^t en un solo paso de tiempo de duración Δ . Este modelo permite actualizar el mapa de probabilidad utilizando la información dinámica del objetivo modelada por $P(v^t|v^{t-1})$. Por ejemplo, esta información puede derivarse de las corrientes marinas en el caso de un objetivo perdido en el mar o de los posibles movimientos de un vehículo en una red vial.

Esta dinámica puede modelarse mediante un modelo Markoviano [22], o modelos de difusión [18]-[20]. En el caso de una misión de búsqueda con múltiples objetivos, el algoritmo de búsqueda de objetivo único puede utilizarse para múltiples objetivos homogéneos utilizando como creencia inicial la probabilidad conjunta de todos ellos y realizando la búsqueda hasta encontrar todos los objetivos.

2.3.4. Modelo de Sensor

Considerando que la posición del sensor coincide con la posición del UAV, el modelo del sensor se describe mediante la función de verosimilitud $P(z_t^u|v^t, s_u^t)$, que representa la probabilidad de obtener una medición z_t^u dada la posición del objetivo v^t y la ubicación

del UAV u en el instante t , s_u^t . Este modelo permite actualizar el mapa de probabilidad con la información proporcionada por las nuevas mediciones del sensor.

Para el problema de búsqueda en espacios con incertidumbre, se consideran dos posibles resultados de medición del sensor: detección del objetivo ($z_u^t = D$) o no detectar ($z_u^t = \bar{D}$) un objetivo ubicado en v^t , dado el estado del UAV u y la orientación del sensor s_u^t . Estas probabilidades son complementarias, por lo que $P(z_u^t = D|v^t, s_u^t) = 1 - P(z_u^t = \bar{D}|v^t, s_u^t)$.

Este enfoque probabilístico permite incorporar las observaciones del sensor de manera sistemática en la actualización del mapa de probabilidad, maximizando la eficacia de la búsqueda. En este sentido, un sensor binario es ideal porque considera como 1 la probabilidad de detección si el objetivo se encuentra en la celda directamente debajo del sensor del UAV y 0 en cualquier otro caso [23]. En otras palabras, la probabilidad de detección es 1 si la distancia entre el objetivo y el sensor/UAV es menor que el tamaño lateral de una celda de la cuadrícula, y 0 para distancias mayores, por lo que también se puede hacer hincapié en la resolución de la malla y la altura de vuelo (asumiendo que el sensor detecta una cuadrícula entera). Cuanto más grande sea el tamaño de la cuadrícula, mayor tendrá que ser la altura para que se pueda detectar el objetivo. En cambio, si la malla es muy pequeña, el dron debería volar a menor altura.

2.3.5. Integración de fuentes de información

En el contexto de entornos con incertidumbre, resulta fundamental la correcta integración de fuentes de información para la navegación de los UAVs. El Filtro Bayesiano Recursivo (*RBF*, por sus siglas en inglés) permite inferir el estado desconocido de un sistema a partir de observaciones de indicios. A diferencia de métodos deterministas, el filtrado bayesiano modela la incertidumbre mediante distribuciones de probabilidad, es decir, utilizando la regla de Bayes, se actualiza en tiempo real y modifica el estado del sistema para tener nuevas medidas [24]. Esta metodología es la base de otras, como el filtro de Kalman o el filtro de partículas.

Con respecto a este último, los filtros de partículas se utilizan en navegación bajo incertidumbre, sobre todo cuando la dinámica del sistema es no lineal y el ruido no gaussiano. Por ejemplo, en [25] se propone el filtro de partículas insaturado (QUPF-VIN) para sistemas de navegación visual-inercial de drones. Utiliza la fusión de sensores IMU y observaciones mediante *landmarks* para manejar no linealidades mediante cuaterniones. Por otro lado, [26] hace uso del filtro basado en MCMC para mejorar la trazabilidad de múltiples drones usando datos GPS con ruido, por lo que se obtiene una precisión continua

2.4. Notación

A continuación, se presenta la notación utilizada a lo largo del trabajo, ordenada por orden de aparición:

- Ω : Área de búsqueda.
- G_Ω : Conjunto de celdas que representan la cuadrícula (malla) del área de búsqueda Ω .
- $w_x \cdot w_y$: Dimensiones de la malla G_Ω .
- U : Número de UAVs que participan en la búsqueda.
- v^t : Posición del objetivo en el tiempo t , modelada como una variable aleatoria.
- $b(v^t) = P(v^t)$: Mapa de probabilidad que describe la creencia sobre la ubicación del objetivo en el tiempo t .
- $b(v_0)$: Probabilidad inicial del objetivo en cada celda, combinando diferentes fuentes de información.
- $b_j(v_0)$: Capa de probabilidad de la fuente de información j .
- w_j : Peso asignado a la fuente de información j según su fiabilidad.
- $P(v^t|v^{t-1})$: Modelo dinámico del objetivo, que describe la probabilidad de transición del objetivo de v^{t-1} a v^t en un intervalo de tiempo Δ .
- $P(z_t^u|v^t, s_u^t)$: Modelo del sensor, que describe la probabilidad de obtener una medición z_t^u dada la posición del objetivo v^t y la ubicación del UAV s_u^t .
- z_t^u : Medición del sensor a bordo del UAV u en el instante t , con valores $z_t^u = D$ (detección) o $z_t^u = \bar{D}$ (no detección).
- $huella(s_u^t)$: Área observable por el sensor desde la posición s_u^t del UAV.
- $P_{\text{cámara}}$: Probabilidad base de detección del sensor a bordo del UAV.
- s_u^t : Posición del UAV u en el tiempo t .
- c_u^t : Acción de control aplicada al UAV u en el tiempo t , que determina su dirección de movimiento.
- $c_u^t \in \{N, NE, E, SE, S, SW, W, NW\}$: Conjunto de direcciones cardinales y diagonales que el UAV puede tomar como acciones de control.
- Δ : Intervalo de tiempo entre dos mediciones consecutivas.
- $\hat{b}(v^t)$: Creencia predicha sobre la ubicación del objetivo en el tiempo t .
- ξ : Factor de normalización que asegura que $\sum_{v^t \in G_\Omega} b(v^t) = 1$.
- P_{kernel} : Kernel bidimensional que representa las probabilidades de transición hacia celdas vecinas.

- $\tilde{b}(v')$: Mapa de probabilidad actualizado de la ubicación del objetivo v' utilizando un enfoque bayesiano recursivo sin normalización.
- $P_d(s_{1:U}^{0:N})$: Probabilidad de detección, definida como la probabilidad de detectar al menos una vez el objetivo durante el horizonte de tiempo N .
- x_t^i : Posible localización del objetivo en el área de búsqueda en el instante de tiempo t , representada por la partícula i .
- w_t^i : Peso asociado a la partícula i en el instante de tiempo t .
- $\hat{x}_t$: Estado estimado, calculado como el promedio ponderado de las partículas en el instante de tiempo t .

3. PROPUESTA

En este trabajo se propone un sistema de planificación, para el reparto de mercancías con UAVs en espacios con incertidumbre. Dicha propuesta consta de tres partes: captura de datos, planificación de la trayectoria y la simulación/evaluación de vuelo.

La primera parte se encarga de obtener toda la información relativa a la localización de la zona de reparto, es decir, la zona del campus de la universidad. Para ello, se utilizan diferentes librerías de Python y la API(*Application Programming Interface*) de *OpenStreetMap*, un entorno de mapas geográficos de libre acceso y editado por la comunidad científica e industrial, para obtener todas las coordenadas de un parámetro inicial que introduce el usuario, como puede ser la calle. A partir de ahí, se generan otras *queries* que devuelvan las coordenadas de un radio posible de actuación con metadatos de otras fuentes de información enriquecida, como calles, edificios y perímetros decatastrales.

Una vez se han obtenido todas las coordenadas de las distintas fuentes de información, se establece una posición inicial del dron desde donde se desea desplegar y así como el conjuntos de indicios donde es más probable que se encuentre la zona de entrega, la cual definimos como objetivo dentro de un espacio de búsqueda. Se utilizan 4 algoritmos clave en todo el trabajo para planificar las trayectorias trayectorias: *Lawnmower* (Cortacésped), *Expanding*, Heurística y Heurística Miope. Cada uno cuenta con características que hacen diferentes las trayectorias.

Por último, esa trayectoria planificada se plasma en el simulador AirSim que, junto a la estación de tierra QGroundControl, monitorizan la ruta que debe seguir el dron. Se captura información del dron mientras realiza la misión, y luego se hace una comparación con la trayectoria planificada.

El sistema propuesto para el caso de uso se divide en los bloques de la Figura 3.1:




Fig. 3.1. Bloques en que se divide la propuesta.

La Inicialización del problema consiste en la captación de los datos, cálculo del espacio de búsqueda y probabilidad inicial del mapa y almacenamiento de los datos en un fichero JSON. Este fichero es el que posteriormente se emplea para el cálculo de las trayectorias y su visualización. Después se reproduce la trayectoria en AirSim, un entorno para simular vuelos realistas con drones. Y, en último lugar, se hace una comparación del cálculo teórico de las trayectorias de vuelo frente a los resultados obtenidos al ejecutar las misiones en el simulador hiperrealista de AirSim. El desglose de los bloques del 1 al 4 de la propuesta se desarrolla con profundidad en los siguientes subapartados. La comparación de trayectorias se lleva a cabo en el próximo capítulo.

3.1. Inicialización del problema

Entrando más en detalle de la preparación del escenario, el diagrama de la Figura 3.2 muestra el flujo de trabajo para plantear el problema:




Fig. 3.2. Esquema del flujo de trabajo de la Inicialización del problema.

Este bloque empieza con el usuario introduciendo el país, municipio y nombre de una calle para hacer una consulta a OpenStreetMap (OSM), un mapa global de código abierto que almacena datos geoespaciales de carreteras, edificios, puntos de interés, etc. A través de su API Overpass, se obtienen las coordenadas globales que identifican la calle y se define el punto de referencia, que en los siguientes pasos será el centro de G_Ω , y que se calcula como el promedio de todas las latitudes y longitudes obtenidas.

Además, este punto es el que se utiliza para hacer tres consultas más a la API (ver Anexo 1) sobre las coordenadas de los edificios, calles y parcela de indicios de un radio alrededor, w , también definido por el usuario, y cuyas coordenadas devueltas de cada una de esas capas de información j se almacenan en otros archivos JSON.

El área de búsqueda, Ω , se define como un mapa cuadrado que abarca todas las calles, edificios e indicios obtenidos de las consultas anteriores con la API. A partir del factor w , esto es, la mitad de un lado del área, se hallan las cuatro esquinas en coordenadas locales

y, a continuación, se transforman a coordenadas globales.

Cabe destacar que esa transformación se conoce como la conversión de coordenadas geográficas, y es necesaria por los diferentes sistemas de referencia que existen. En este trabajo, se hace uso de tres sistemas de referencia distintos:

- **Sistema de Coordenadas Geodésicas** (GCS, por sus siglas en inglés: *Geodetic Coordinate System*): representa la posición de un punto en la Tierra mediante la latitud, longitud y altura sobre una elipsoide de referencia.




Fig. 3.3. Sistema de Coordenadas Geodésicas [27].

donde:

- ϕ es la latitud geodésica.
 - λ es la longitud geodésica.
 - h es la altura geodésica sobre el elipsoide.
- **Sistema de Coordenadas Geocéntricas** (ECEF, por sus siglas en inglés: *Earth-Centered, Earth-Fixed Coordinate System*): está basado en el centro de la Tierra y con los ejes fijos respecto a su rotación.




Fig. 3.4. Sistema de Coordenadas Geocéntricas. [27]

- **ENU**: el tercer sistema de referencia local que representa las coordenadas en los tres ejes hacia el este, norte y hacia arriba (en inglés *East, North, Up*) con respecto a un puesto de la superficie terrestre.




Fig. 3.5. Marco de referencia ENU. [28]

En el sentido del flujo del trabajo, el proceso de conversión consta de dos transformaciones: 1) de coordenadas locales ENU a ECEF; y 2) de ECEF a de coordenadas geodésicas. Inspirado por [29], matemáticamente se escribe como:

1. De locales a ECEF:

$$\begin{bmatrix} x_{ecef} \\ y_{ecef} \\ z_{ecef} \end{bmatrix} = \begin{bmatrix} -\sin \lambda & \cos \lambda & 0 \\ -\sin \phi \cos \lambda & -\sin \phi \sin \lambda & \cos \phi \\ \cos \phi \cos \lambda & \cos \phi \sin \lambda & \sin \phi \end{bmatrix} \begin{bmatrix} x_{enu} \\ y_{enu} \\ z_{enu} \end{bmatrix} + \begin{bmatrix} x_{ref} \\ y_{ref} \\ z_{ref} \end{bmatrix} \quad (3.1)$$

donde $(x_{enu}, y_{enu}, z_{enu})$ son las coordenadas en el sistema local ENU; $(x_{ecef}, y_{ecef}, z_{ecef})$ son las coordenadas en el sistema global ECEF; $(x_{ref}, y_{ref}, z_{ref})$ son las coordenadas ECEF del punto de referencia; ϕ es la latitud geodésica del punto de referencia; y λ es la longitud geodésica del punto de referencia.

2. De ECEF a geodésicas:

1. Cálculo de la longitud λ :

$$\lambda = \tan^{-1} \left(\frac{y}{x} \right) \quad (3.2)$$

2. Cálculo de la latitud ϕ utilizando el método iterativo de Newton-Raphson:

$$p = \sqrt{x^2 + y^2} \quad (3.3)$$

$$\theta = \tan^{-1} \left(\frac{z}{p(1 - e^2)} \right) \quad (3.4)$$

$$\phi = \tan^{-1} \left(\frac{z + e^2 \cdot N(\phi) \cdot \sin(\theta)}{p} \right) \quad (3.5)$$

donde x, y, z son las coordenadas en el sistema ECEF; $e^2 = \frac{a^2 - b^2}{a^2}$ es la excentricidad de la elipsoide, donde a es el semi-eje mayor y b es el semi-eje menor; $N(\phi)$ es el radio de curvatura en el meridiano, dado por:

$$N(\phi) = \frac{a}{\sqrt{1 - e^2 \sin^2(\phi)}} \quad (3.6)$$

3. Cálculo de la altura h :

$$h = \frac{p}{\cos(\phi)} - N(\phi) \quad (3.7)$$

donde h es la altura sobre el elipsoide. Estas fórmulas permiten transformar un punto en el sistema ECEF a coordenadas geodésicas (ϕ, λ, h) , sabiendo que: ϕ es la latitud geodésica, λ es la longitud geodésica y h es la altura geodésica sobre el elipsoide.

Por otro lado, el centro de Ω corresponde con el origen del marco de referencia, por lo que esos puntos en coordenadas locales que lo delimitan son: $(-w, w)$, (w, w) , $(w, -w)$ y $(-w, -w)$. A su vez, Ω se divide en celdas cuadradas dependientes del tamaño en metros que el usuario ha introducido. Se genera una malla con el mismo número de cuadrículas de ancho que de largo:

$$\text{Número de cuadrículas} = \frac{2 \cdot w}{\text{Tamaño de cuadrícula}} \quad (3.8)$$

De esta forma se obtiene toda la información: la mitad del lado, w , Ω en coordenadas locales en función de w , Ω en coordenadas locales y globales y las dimensiones de la malla.

Para el cálculo de la probabilidad inicial del objetivo en cada celda, $b(v_0)$, y teniendo en cuenta las distintas fuentes de información, se asigna un 1 a todas aquellas cuadrículas que se encuentran en la zona de indicios y un 0 en el resto. Al normalizar esta distribución, se obtiene una equiprobabilidad para cada una de las celdas dentro del área donde se encuentra el objetivo.

Además, es muy importante aclarar que las coordenadas globales iniciales capturadas del dron deben ser transformadas para su posterior cálculo y visualización en la planificación. Esa conversión es necesaria y se debe a los distintos sistemas y marcos de referencia con los que se trabaja que, de manera similar a [29], se puede ver como:




Fig. 3.6. Transformaciones de sistemas de referencia.

La coordenadas iniciales del dron en el sistema del planificador, P_{mts}^t , vienen determinadas por las siguientes transformaciones:

$$P_t^{sim} = {}^{sim}T_{mts} \cdot {}^{mts}T_B \cdot {}^B T_A \cdot {}^A T_g \cdot P_t^{osm} \quad (3.9)$$

Y donde los sistemas son:

- El Sistema A tiene su origen en el centro de Ω y representa el estado inicial de la Figura 3.8. El punto P_t^{osm} es la posición inicial del dron en un momento t con OpenStreetMap, que se captura en coordenadas globales y se pasan a locales con respecto al anterior origen a través de la transformación:

$$P_A = {}^A F_g(P_t^{osm}, P_o) = {}^A T_g \cdot P_t^{osm} \quad (3.10)$$

donde P_A representa una posición inicial cualquiera del dron en coordenadas locales ENU del Sistema A; P_g es la posición inicial del dron en coordenadas globales; P_o es el origen de Ω en coordenadas globales y que se utiliza como referencia para el paso de coordenadas geodésicas a ENU; ${}^A F_g(P_g, P_o)$ consiste en la transformación no lineal de las coordenadas geodésicas capturadas en un inicio al marco de referencia ENU; y ${}^A T_g$ representa la conversión de coordenadas geodésicas a ENU. Es el proceso inverso al inicialmente hecho para calcular las esquinas de Ω .

- Se pasa del sistema A al sistema de rototraslación B, a través de esa transformación que combina una rotación y una traslación en un mismo movimiento. La transformación viene dada por:

$$P_B = {}^B F_A(P_A, P_{oB}) = {}^B T_A \cdot P_A \quad (3.11)$$

donde P_B representa una posición inicial del dron en el sistema rototrasladado; P_{oB} es el origen del sistema de rototraslación, la esquina inferior izquierda de Ω ; ${}^B F_A(P_A, P_{oB})$ es la transformación no lineal que representa tanto la rotación como la traslación; ${}^B T_A$ es la matriz de la transformación, que expresa la rototraslación como:

$${}^B T_A = \begin{bmatrix} {}^B R_A & \mathbf{t}_A^B \\ 0 & 1 \end{bmatrix} \quad (3.12)$$

donde ${}^B R_A$ es la matriz de rotación 3×3 que transforma las coordenadas del sistema A al sistema B; $\mathbf{t}_A^B$ es el vector de traslación 3×1 que representa el desplazamiento entre los dos sistemas de referencia; La fila extra en la matriz homogénea permite realizar transformaciones afines.

Y aplicando esta transformación a un punto en coordenadas homogéneas:

$$P_B = \begin{bmatrix} x^B \\ y^B \\ z^B \\ 1 \end{bmatrix} = \begin{bmatrix} {}^B R_A & \mathbf{t}_A^B \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x^A \\ y^A \\ z^A \\ 1 \end{bmatrix} \quad (3.13)$$

donde (x^A, y^A, z^A) son las coordenadas del punto en el sistema A, y (x^B, y^B, z^B) son las coordenadas transformadas en el sistema B.

La traslación del origen ocurre desde el centro hasta lo que en el Sistema A es $(-w, w)$, es decir, la esquina inferior izquierda de Ω . Por su parte, la rotación del sistema de referencia viene dada por la declinación magnética, que representa la diferencia angular entre el norte geográfico (verdadero) y el norte magnético, y puede variar con el tiempo y la ubicación en la Tierra.

Sin embargo, en este caso, el ángulo de desviación magnética, φ , se considera 0 por cómo se representan los mapas en OpenStreetMap (ver 3.7), basado en el sistema WGS 84 (World Geodetic System 1984), un sistema de referencia global que asume que el norte en el mapa está alineado con el norte geográfico real. Por tanto, las consultas realizadas en el bloque anterior devuelven coordenadas con una orientación alineada con la realidad geográfica.




Fig. 3.7. Ángulo de rotación φ entre sistemas.

- El Sistema de búsqueda contiene otra transformación del sistema anterior, un reescalado que depende del tamaño de la cuadrícula de la malla, t_c .

$$P_{mts} = {}^{mts}F_B(P_B, t_c) = {}^{mts}T_B \cdot P_B \quad (3.14)$$

En concreto, se divide las coordenadas iniciales del dron transformadas entre este factor y se utiliza como *input* para calcular la trayectoria.

$${}^{mts}T_B = \frac{1}{t_c} \begin{pmatrix} P_{B,x} \\ P_{B,y} \end{pmatrix} \quad (3.15)$$

- La última transformación es bidireccional, puesto que una vez se ha calculado la trayectoria teórica, se necesita mantener la relación original, la que se ha capturado con OSM, en el siguiente bloque de simulación en AirSim y QGC.

$$P_{sim} = {}^{sim}F_{mts}(P_{mts}, t_c) = {}^{sim}T_{mts} \cdot P_{mts} \quad (3.16)$$

donde

$${}^{sim}T_{mts} = t_c \begin{pmatrix} P_{mts,x} \\ P_{mts,y} \end{pmatrix} \quad (3.17)$$

Y luego se hace la transformación a coordenadas globales en un instante t de tiempo:

$$P_t^{gsim} = {}^{sim}F_{mts}(P_{sim}, P_{ref}) \quad (3.18)$$

En la Figura 3.15 se muestra la trayectoria que va a seguir el dron en AirSim.

El penúltimo paso de este bloque consiste en crear una representación gráfica del mapa inicial, como la Figura 3.8 utilizando las bibliotecas Matplotlib y GeoPandas para visualizar todas las capas de información anteriores en una proyección realista. El mapa resultante es interactivo y permite al usuario elegir la posición inicial en coordenadas globales del dron haciendo click en él (punto rojo).




Fig. 3.9. Esquema del flujo de trabajo de la Visualización de algoritmos.

Como output, este bloque genera, además del cálculo de la trayectoria y su visualización, un archivo .plan que se utiliza para el siguiente bloque, la simulación en AirSim.

Se han probado varios algoritmos con el objetivo de comparar distintos tipos de recorridos. Esos algoritmos de búsqueda en tiempo mínimo implementados son los siguientes:

- **Lawnmower:** es el primero de los algoritmos por fuerza bruta que barren Ω en su totalidad por tramos rectos. Cada tramo recorre la longitud del espacio y después realiza dos giros consecutivos de 90° para cambiar de sentido. Se considera como un algoritmo *greedy* porque, para cada instante de tiempo, realiza la mejor opción sin tener en cuenta las consecuencias futuras.
- **Expanding Square Search (SSE):** se trata de otra trayectoria por fuerza bruta que se basa en una espiral cuadrada creciente (de dentro hacia fuera). Es especialmente útil para hacer un rastreo en Ω cuando el objetivo se encuentra cerca de la posición de inicio de búsqueda.
- **Heurística Miope:** algoritmo de búsqueda voraz que se guía por la maximización de la información que da en cada paso. Prioriza la información en su proximidad inmediata y, como consecuencia, no evalúa su impacto en futuras decisiones. Por tanto, es un algoritmo reactivo porque se ajusta de manera dinámica a la probabilidad que observa, sin considerar las implicaciones de cada una de sus decisiones en el trayecto completo.
- **Heurística con Corrección de Miopía:** algoritmo similar al anterior pero con la corrección de la miopía. En este caso, prevalece toda la información, tanto local como global, por lo que no se ve influenciado por la vecinidad dado un punto cualquiera, y se dirige hacia las zonas con mayor probabilidad. En el largo plazo, se considera más efectiva que la heurística anterior.

Para mostrar un ejemplo de las transformaciones del caso de uso que se han explicado en el módulo anterior, se ha tomado la Heurística Miope:

1. **Captura de coordenadas globales:** en el mapa inicial que se muestra por pantalla, el usuario escoge la posición inicial del dron (punto rojo), donde ha hecho *click* dentro del espacio de búsqueda, y se almacenan esas coordenadas globales.




Fig. 3.10. Mapa inicial con la posición inicial del dron elegida por el usuario.

2. **Cálculo de coordenadas locales en A:** con respecto al sistema de referencia A, cuyo origen se encuentra en el centro del espacio de búsqueda (más concretamente, el centro de la calle que el usuario introdujo como *input*), se hallan las coordenadas capturadas del paso anterior en coordenadas locales ENU del sistema A.




Fig. 3.11. Posición inicial del dron con respecto al sistema de referencia A.

3. **Transformación al sistema del planificador:** es necesario hacer la rototraslación anterior. Se trasladan las coordenadas locales anteriores a un sistema cuyo origen se pasa a la esquina inferior izquierda, y se rota el sistema en un ángulo φ . Con el nuevo sistema de referencia, la posición inicial del dron se muestra en la Figura 3.12:




Fig. 3.12. Rotación y traslación del sistema de referencia A a ENU.

4. **Reescalado hacia atrás del mapa:** dado que el mapa del planificador tiene un tamaño que es igual al número de cuadrículas en el ancho y largo, puesto que cada cuadrado (unidad) puede representar varios metros, es necesario escalar el espacio de búsqueda para que se ajuste al planificador. Por tanto, se divide las coordenadas del paso anterior entre la longitud del lado de un cuadrado, t_c .
5. **Cálculo de la trayectoria:** con los módulos del planificador, que se explicarán más en detalle en el siguiente apartado, y a partir de las coordenadas iniciales ya reescaladas, se calculan los puntos que va a seguir el dron según el algoritmo elegido.




Fig. 3.13. Trayectoria hallada para el sistema del planificador sin reescalar.

6. **Reescalado hacia delante del mapa:** una vez se tiene toda la trayectoria calculada en coordenadas locales, y al contrario que en el paso 4, se quiere representar las dimensiones reales del problema, para lo que se multiplica, tanto los puntos de paso como al tamaño del mapa de probabilidades, por el tamaño del cuadrado de la malla. En la Figura 4.17 se puede ver el inicio y final de esa trayectoria teórica.




Fig. 3.14. Planificación de la trayectoria para el algoritmo Heurística Miope.

Después, se genera el fichero .plan, que se muestra en la Figura 3.15, que se utiliza para el siguiente bloque de la propuesta.

TABLA 3.1. COMPARACIÓN DE LAS TRAYECTORIAS PARA DISTINTOS ALGORITMOS.

Algoritmo	Planificación inicio	Planificación final	QGC
Heurística			
Lawnmower			

Algoritmo	Planificación inicio	Planificación final	QGC
Expanding	Búsqueda de objetivo usando método 10 Legend: Target, Obstacle, Path, Search Area	Búsqueda de objetivo usando método 10 Legend: Target, Obstacle, Path, Search Area	

3.2.1. Evaluación de trayectorias de los algoritmos

Para cada uno de los algoritmos anteriores, se han hecho dos experimentos distintos y se han evaluado los resultados de sus trayectorias. Se han hecho 1000 ejecuciones por algoritmo y experimento, por lo que se ha podido aleatorizar las casuísticas del problema y, además, para todos los experimentos se ha establecido un horizonte temporal máximo de 5000 pasos. En el siguiente análisis de los datos, se destacan las estadísticas más relevantes de cada uno de los tipos de trayectoria.

- **Experimento 1:** mantiene la posición inicial del dron fija (círculo azul) y se calcula otra aleatoria para el objetivo (cruz roja) dentro de la parcela de indicios (área gris).




Fig. 3.16. Experimento 1: posición inicial del dron fija en (40, 40) y del objetivo aleatoria.

Análisis del Experimento 1

La distancia es el factor que permite saber el tiempo y la efectividad de cada trayectoria. En la Tabla 3.2 se recogen las estadísticas descriptivas sobre todas las ejecuciones de este primer experimento.

Strategy	Count	Mean	Std	Min	25 %	50 %	75 %	Max
Expanding	1000	597.66	406.92	14.66	244.66	534.66	854.66	1849.66
Lawnmower	1000	1357.99	427.72	464.77	1008.77	1406.77	1708.77	2100.77
Heurística	1000	1317.87	2037.80	8.49	55.33	156.21	1785.49	6582.30
Heurística Miope	1000	166.51	145.76	8.49	69.57	113.99	274.58	738.99

TABLA 3.2. ESTADÍSTICAS DESCRIPTIVAS DE LAS DISTANCIAS DEL EXPERIMENTO 1.

El algoritmo Lawnmower es el que más distancia, en promedio, recorre por iteración dado que hace un barrido completo de Ω , mientras que Heurística miope y Expanding son lo que menos tardan en encontrar el objetivo porque se trata de un caso céntrico, donde ambos se fortalecen de la situación. En la Figura 3.17 se puede ver esa comparativa, tanto en distancia como en pasos que, como es de esperar, están correlados, pero de las ejecuciones exitosas, es decir, que han encontrado el objetivo.




Fig. 3.17. Promedio de la distancia y pasos por algoritmo.

En términos generales, se puede decir que los algoritmos utilizados son eficaces, con el 98 % de los casos exitosos. La fuerza bruta y la búsqueda voraz son dos técnicas consistentes y robustas que sirven para encontrar el objetivo en los problemas.



Fig. 3.18. Porcentaje de casos de éxitos y fracasos por algoritmo.

Aunque la eficacia es alta, cada tipo de trayectoria tiene sus características. En consecuencia, también es conveniente conocer la distribución de los pasos para cada algoritmo en todas sus ejecuciones, que se muestra en la Figura 3.19.

El algoritmo Expanding tiene una mediana relativamente baja, con algunos valores atípicos (*outliers*), por lo que en algunos casos el algoritmo requiere de más pasos. Además, la dispersión no es muy grande, por lo que se puede decir que es un algoritmo consistente para este caso de uso.

El algoritmo Lawnmower, en cambio, tiene una mediana más alta, por lo que, en promedio, necesita más pasos para completar su tarea. Su distribución es más amplia que la de Expanding y refleja una mayor variabilidad en su rendimiento.

Por otro lado, el algoritmo de Heurística Miope es el que tiene la mediana más baja de todas las estrategias; es el método más eficiente en términos de pasos requeridos. Su dispersión es también bastante reducida, que indica un comportamiento consistente y predecible y, a pesar de ello, se observan algunos *outliers* que podrían representar iteraciones poco favorables para esta estrategia.

Finalmente, la Heurística es el algoritmo con mayor variabilidad debido a su gran dispersión, a pesar de que su mediana es inferior a la de Lawnmower. Además, se observa un valor atípico extremadamente alto que supera los 5000 pasos y, en consecuencia, es no encuentra el objetivo y se vuelve un algoritmo ineficiente.




Fig. 3.19. Boxplots de los pasos dados para cada uno de los algoritmos.

Para verlo más en detalle, en la Figura 3.20 se muestran las distribuciones desglosadas, en histogramas, por cada tipo de trayectoria:




Fig. 3.20. Histogramas con la distribución de los pasos para cada algoritmo.

Otra forma de representar los datos es con la función de distribución acumulada (*Cumulative Distribution Function* en inglés) de una variable aleatoria X , donde $F(x)$ devuelve la probabilidad acumulada de que la variable aleatoria tome un valor menor o igual a x (ver 3.19. En otras palabras, una CDF calcula qué porcentaje de los valores están por debajo de un umbral.

$$F(x) = P(X \leq x) \quad (3.19)$$

Esas funciones se muestran en la Figura 3.21:




Fig. 3.21. Función de distribución acumulada por algoritmo.

El comportamiento de las funciones sigue las conclusiones sacadas de los boxplots anteriores. En el caso de Expanding, la curva crece de manera escalonada y menos pronunciada que otras estrategias, que revela una mayor variabilidad en la cantidad de pasos requeridos. A pesar de esto, cerca del 80 % de sus ejecuciones terminan antes de los 2000 pasos; en términos computacionales no es excesivamente costoso en términos computacionales.

El algoritmo Lawnmower muestra una CDF con una pendiente progresiva que indica una distribución más amplia de los tiempos de ejecución. Su curva se estabiliza más tarde que otras estrategias y refleja que, para algunos escenarios, tarda significativamente más en completarse.

Por otro lado, la Heurística Miope tiene una curva muy empinada desde el inicio, es decir, la gran mayoría de los experimentos requieren muy pocos pasos. De hecho,

cerca del 80 % de las ejecuciones terminan antes de los 500 pasos y, en este sentido, se convierte en la estrategia más eficiente.

En cambio, la Heurística muestra una curva menos empinada y con una cola larga, lo que significa que en algunos casos el número de pasos puede aumentar considerablemente. Aunque en ciertos escenarios alcanza el objetivo con rapidez, su alta variabilidad lo convierte en una opción menos predecible y, en algunos casos, ineficiente (cuando llega al límite del horizonte temporal establecido).

- **Experimento 2:** la posición inicial del dron se calcula en los bordes del espacio de búsqueda, y el objetivo se fija en una posición dentro de la parcela de indicios.




Fig. 3.22. Experimento 2: posición inicial del dron aleatoria y del objetivo fija en (20, 30).

Análisis del Experimento 2

Para este segundo experimento, se comienza comparando la distancia con los pasos que se dan en promedio por algoritmo:

Strategy	Count	Mean	Std	Min	25 %	50 %	75 %	Max
Expanding	1000	404.36	83.03	25.04	355.97	458.83	466.28	475.25
Lawnmower	1000	1033.04	183.26	1.00	874.41	1034.91	1204.41	1261.41
Heurística	1000	319.48	422.92	24.04	107.87	162.74	297.00	3099.54
Heurística Miope	1000	407.82	481.54	24.04	100.34	225.91	517.99	3335.61

TABLA 3.3. ESTADÍSTICAS DESCRIPTIVAS DE LAS DISTANCIAS DEL EXPERIMENTO 2.




Fig. 3.23. Promedio de la distancia y pasos por algoritmo.

Los resultados siguen la misma línea que en el Experimento 1, excepto que el algoritmo de Heurística tiene una notable diferencia: es el que menos distancia recorre. Ante escenarios más amplios, donde se tiene que buscar desde el límite de Ω , este algoritmo se convierte en el más eficiente por su cómputo global de la trayectoria, es decir, su capacidad para, en cada instante t , calcular el siguiente punto de paso considerando sus implicaciones futuras.

En consecuencia, y también debido a la robustez de los algoritmos, se puede justificar que el 99,9 % de los escenarios tienen éxito:



Fig. 3.24. Porcentaje de casos de éxitos y fracasos por algoritmo.

Aún así, la distribución de los pasos para cada algoritmo es distinta a la del Experimento 1. Se puede ver, tanto en los boxplots de la Figura 3.25, como en los histogramas en la Figura 3.26, la variabilidad de la distribución según el experimento.




Fig. 3.25. Boxplots de los pasos dados para cada uno de los algoritmos.




Fig. 3.26. Histogramas con la distribución de los pasos para cada algoritmo.

El algoritmo de Expanding muestra una distribución con un pico muy pronunciado en torno a los 400 y 500 pasos, por lo que la mayoría de los escenarios planificados se completan en ese tiempo. Sin embargo, también se aprecian algunos valores atípicos más elevados que se extienden hasta los 3000 pasos.

El cortacésped presenta una forma bimodal con dos picos alrededor de los 1000 pasos, similares y menores que en el experimento anterior. Es bimodal porque se producen resultados para dos escenarios de manera consistente.

El algoritmo con Heurística tiene una distribución más dispersa, aunque la mayor densidad se concentra en valores bajos, alrededor de 100 a 300 pasos. Tiene una cola larga hacia la derecha que alcanza incluso los 3000 pasos, en ciertos casos específicos la estrategia se puede decir que es ineficiente.

Por su parte, la Heurística Miope también presenta una densidad inicial alta con un pico alrededor de los 100-200 pasos, pero igualmente tiene una cola extensa que muestra algunos casos atípicos donde se ha requerido muchos más pasos.




Fig. 3.27. Función de distribución acumulada por algoritmo.

Para el Expanding, la curva se eleva rápidamente y alcanza casi el 100 % antes de los 500 pasos. La pendiente inicial pronunciada indica que muchos experimentos se completan con pocos pasos. De manera similar, la curva del Lawnmower presenta un crecimiento rápido hasta cerca de los 1000 pasos y luego se aplanan, por tanto, confirma la tendencia bimodal observada en el histograma.

El algoritmo con Heurística tiene una curva que crece rápidamente al principio, alcanzando el 60 % de los casos en menos de 500 pasos, pero luego su pendiente se suaviza, que indica la presencia de casos mucho más costosos en términos de pasos. Con un comportamiento parecido, la Heurística Miope tiene un ascenso rápido en la parte inicial y luego un aplanamiento más prolongado.

- **Experimento 3:** tanto la posición inicial del dron como la del objetivo se calculan de manera aleatoria, una más allá de la parcela de indicios y la otra dentro de la misma, respectivamente.




Fig. 3.28. Experimento 3: posición inicial del dron y del objetivo aleatoria.

Análisis del Experimento 3

De la misma manera que para los experimentos anteriores, se ha hecho una análisis estadístico de los aspectos más relevantes para las trayectorias.

Strategy	Count	Mean	Std	Min	25 %	50 %	75 %	Max
Expanding	1000	562.00	398.88	2.41	247.00	473.30	858.67	1874.77
Lawnmower	1000	1165.68	541.96	1.41	736.19	1175.78	1590.80	2219.39
LDFS-Heur	1000	1389.46	2069.21	1.00	79.85	346.86	1639.94	7071.07
LDFS-Myop	1000	363.91	443.64	1.00	90.84	222.71	443.11	3110.51

TABLA 3.4. ESTADÍSTICAS DESCRIPTIVAS DE LAS DISTANCIAS DEL EXPERIMENTO 3.

Se puede ver que las distancia recorrida es parecida al primer caso, cuando la posición del dron era fija y la del dron aleatoria. Este experimento se trata de una generalización de ese caso, pero para mil instancias por algoritmo.




Fig. 3.29. Promedio de la distancia y pasos por algoritmo.

La tasa de éxito de este experimento está en el 97 %, similar a los otros dos aunque ligeramente inferior en eficacia.




Fig. 3.30. Porcentaje de casos de éxitos y fracasos por algoritmo.

Las distribuciones por algoritmo se pueden observar en las siguientes figuras.




Fig. 3.31. Boxplots de los pasos dados para cada uno de los algoritmos.

Steps Distribution by Strategy




Fig. 3.32. Histogramas con la distribución de los pasos para cada algoritmo.

En términos generales, se puede ver una cola hacia la derecha en las distribuciones, o sea que tiene una asimetría positiva, donde la mayoría de los datos se encuentran hacia la izquierda y, el resto, en casos atípicos, se desplazan hacia la derecha.




Fig. 3.33. Función de distribución acumulada por algoritmo.

Con respecto a la función de distribución acumulada, la estrategia Expanding muestra una alta eficacia, resolviendo la mayoría de los casos con menos de 1500 pasos. Su curva empinada indica poca variabilidad entre ejecuciones. En comparación, el algoritmo Lawnmower tiene una mayor dispersión y un número de pasos significativamente más alto, aunque mantiene una mayor regularidad en su comportamiento.

Por otro lado, las estrategias de las heurísticas presentan comportamientos opuestos. La Heurística Miope destaca por su eficiencia y estabilidad, ya que completa casi todos los casos rápidamente, y, en cambio, la Heurística es más variable porque cuenta con una proporción considerable de ejecuciones que requieren un número elevado de pasos.

- **Comparación de experimentos:** por último, se han comparado las estadísticas de ambos experimentos, que se pueden ver en la Figura 3.34:




Fig. 3.34. Número de pasos requeridos por algoritmo y experimento.

El algoritmo Expanding mantiene un rendimiento constante a lo largo de los tres experimentos. Aunque hay una ligera dispersión adicional en los experimentos 1 y 3, puesto que el 2 es invariable, la mayoría de los casos siguen concentrándose en un rango medio de pasos. Se puede decir que es un algoritmo bastante robusto frente a la aleatoriedad en las posiciones iniciales del dron y el objetivo. El caso de uso de estudio, al ser céntrico, favorece la uniformidad de los pasos por este algoritmo.

El Lawnmower también conserva una distribución estable entre experimentos, aunque con una diferencia más marcada entre el experimento 1 y los otros dos. En los experimento 1 y 3 existe un notable incremento en los pasos requeridos y una mayor dispersión, es decir, es una estrategia sistemática más sensible cuando se introduce aleatoriedad completa. Esto se debe al barrido completo de Ω que realiza. Aún así, su rendimiento sigue siendo predecible y estructurado porque siempre traza el mismo camino.

La Heurística presenta la mayor variabilidad entre los tres experimentos. En el experimento 1 muestra una acumulación de pasos en ciertos niveles, mientras que en

el experimento 3 hay una dispersión mucho más amplia, con múltiples ejecuciones que alcanzan valores extremos. Se demuestra que es muy sensible a las condiciones iniciales y puede ser ineficiente en configuraciones completamente aleatorias.

Por su parte, la Heurística Miope ofrece un comportamiento más controlado que la Heurística, pero también refleja un aumento en la variabilidad en el experimento 3. A pesar de que sigue siendo eficiente en muchos casos, la dispersión en los pasos crece a medida que se introduce aleatoriedad total, o sea que aún depende del conocimiento inicial del entorno para mantener un rendimiento óptimo.

3.3. Entorno de simulación

Después de la planificación de la trayectoria, esta se plasma sobre el simulador de AirSim, cuyo flujo se describe en la Figura 3.35:




Fig. 3.35. Esquema del flujo de trabajo de la Simulación de algoritmos en AirSim.

La simulación se inicia con el fichero .plan generado por el bloque de la planificación anterior. Se utilizan las coordenadas de los puntos de paso según el algoritmo y se crean los *waypoints* que va a seguir el dron en el simulador. Esta distinción entre el cálculo teórico de la misión del dron y su implementación en un entorno realista permite ver la robustez de algoritmo y la factibilidad de efectuar el vuelo.

Existe una diferencia importante con respecto al módulo anterior, y es que, al iniciar la simulación, el dron realiza la trayectoria de los N pasos definidos. Si, durante el recorrido,

encuentra la zona de aterrizaje, cuya detección se encuentra modelada como un código ArUco, el dron se para y aterriza en esa posición. Una vez en tierra, la misión se da por finalizada y se puede decir que ha llegado a su objetivo. En otras palabras, el sistema planificador se encarga de generar una trayectoria teórica con todos los pasos declarados, por lo que es independiente de si encuentra el objetivo o no. En cambio, al simulador se traslada esa ruta que sigue el dron, y es aquí donde ocurre la verdadera detección, cuando encuentra el código.

3.3.1. Herramientas de la simulación

Para esta tercera parte, se han utilizado dos herramientas fundamentales que permiten replicar la trayectoria generada en la planificación:

- **AirSim:** es el simulador de vehículos aéreos y terrestres desarrollado por Microsoft creado con Unreal Engine. Es un entorno con el potencial de crear texturas, físicas y visualizaciones a un gran detalle.



Fig. 3.36. Simulador AirSim con Unreal Engine en el Campus de Colmenarejo.



Fig. 3.37. Dron de vuelo en AirSim.

Cesium es una plataforma de código abierto que crea mapas 3D geoespaciales, que actualmente es un plugin del motor gráfico de Unreal Engine. En este trabajo se ha utilizado para renderizar los edificios en la parcela de indicios dentro del espacio de búsqueda.

Para la detección del objetivo en el simulador, se hace uso de un marcador ArUco, que se coloca en la posición en que se encuentra el objetivo. Se trata de una imagen en blanco y negro, parecido a un código QR, que tiene un patrón binario utilizado para su detección. Es de gran utilidad para la simulación en un espacio tridimensional como el de AirSim, donde se puede definir un criterio de parada para que, a una cierta altura, el dron puede detectar la posición en que quiere aterrizar [29]. Con las capas de Cesium se puede crear un objeto, como un cuadrado, y sobre el que se añada la textura de la imagen del ArUco.



Fig. 3.38. Ejemplo de ArUco.

- **QGroundControl:** es la estación de control terrestre (CGS) con la que se puede planificar y monitorizar la trayectoria de uno de los vehículos anteriores compatibles con el protocolo MAVLink (como PX4). Cuenta con la interfaz gráfica para definir rutas, puntos de interés, alturas de vuelo, velocidades, etc, y muestra la telemetría en tiempo real.




Fig. 3.39. Interfaz gráfica de la estación de control terrestre QGroundControl.

Entrando más en detalle sobre el funcionamiento del dron, MAVLink (*Micro Air Vehicle Link*) es un protocolo de comunicación dedicado a los vehículos no tripulados. Permite la comunicación entre el controlador que se utiliza en este trabajo, el PX4, y la estación de control, QGC. Su principal ventaja es la eficiencia y ligereza con la que comunica dos o más sistemas entre sí, es decir, la reducción del tamaño del mensaje transmitido, que se debe a su ancho de banda limitado. Además, se considera fiable para la comunicación de una gran variedad de vehículos, y es compatible con muchos lenguajes de programación y microcontroladores o sistemas operativos [30].





Fig. 3.40. Arquitectura de MAVLink con PX4 [31].

En la siguiente imagen se muestra la distribución de los campos que componen un mensaje MAVLink.



Byte Index	Content	Value	Explanation
0	Packet start sign	v1.0: 0xFE (v0.9: 0x55)	Indicates the start of a new packet.
1	Payload length	0 - 255	Indicates length of the following payload.
2	Packet sequence	0 - 255	Each component counts up his send sequence. Allows to detect packet loss
3	System ID	1 - 255	ID of the SENDING system. Allows to differentiate different MAVs on the same network.
4	Component ID	0 - 255	ID of the SENDING component. Allows to differentiate different components of the same system, e.g. the IMU and the autopilot.
5	Message ID	0 - 255	ID of the message - the id defines what the payload "means" and how it should be correctly decoded.
6 to (n+6)	Data	(0 - 255) bytes	Data of the message, depends on the message id.
(n+7) to (n+8)	Checksum (low byte, high byte)	ITU X.25/SAE AS-4 hash, excluding packet start sign, so bytes 1..(n+6) Note: The checksum also includes MAVLINK_CRC_EXTRA (Number computed from message fields. Protects the packet from decoding a different version of the same packet but with different variables).	

Fig. 3.41. Estructura de un mensaje MAVLink [32].

Se hace uso del *Software in the Loop* (SITL), un método que permite ejecutar el *firmware* de un dron en un ordenador. PX4 se ejecuta en como SITL como si fuese un dron físico, mientras que la interacción con el entorno se simula. MAVLink, por su parte, actúa como agente de comunicación entre el PX4 y otras herramientas externas, como QGC o AirSim. Esta técnica de simulación ha permitido crear el sistema donde hacer las pruebas de la trayectoria planificada del dron sin correr riesgos físicos.

Todos los simuladores se comunican con PX4 a través de la API de MAVLink, que se encarga de transmitir los mensajes de los sensores y actuadores del UAV al controlador. A su vez, este manda los mensajes al motor y a los actuadores del dron simulado.




Fig. 3.42. Intercambio de mensajes entre el simulador y el flight stack de PX4 [33].

La conexión se realiza a través de puertos UDP entre el sistema SITL y el controlador PX4. El simulador se comunica a través de la API de MAVLink, mientras que el resto a través del módulo estándar del protocolo.




Fig. 3.43. Componentes de un sistema SITL [33].

En el contexto del proyecto es, por tanto, importante conocer PX4, un *software* de control para drones y otros vehículos no tripulados. Está diseñado para funcionar con el *hardware* Pixhawk y se encarga de la navegación autónoma y comunicación con las estaciones de tierra, entre otros. Además, su arquitectura permite ejecutar simulaciones SITL y usar protocolos de comunicación, como MAVLink, para intercambiar mensajes entre el dron y QGC. [34]. Entre sus características, destacan:

- **Código abierto:** se trata de un proyecto libre de uso, por lo que desarrolladores y empresas forman una comunidad que sustenta el código.
- **Compatibilidad:** con una amplia gama de hardware (Pixhawk, Holybro, CUAV, etc.).

- **Simulación integrada:** se integra fácilmente con herramientas como Gazebo o Air-Sim, sin riesgo físico, además de que es uno de los más reconocidos en la industria para diferentes aplicaciones (investigación, comercial, etc.).
- **Modularidad:** se adapta a distintos controladores y sensores según sea necesario para el proyecto.




Fig. 3.44. Configuración del *firmware* con QGC [35].

4. EVALUACIÓN DE LA PROPUESTA

En este trabajo se distingue entre el entorno de planificación y el de simulación, cada uno con sus propias características, objetivos y limitaciones. La planificación se lleva a cabo en un entorno abstracto, donde se representa el espacio de búsqueda mediante una matriz de probabilidades. En esta fase, se han aplicado algoritmos que determinan trayectorias eficientes sin tener en cuenta las restricciones físicas del dron, y se han evaluado los algoritmos para el caso de uso.

En cambio, en el siguiente paso, la simulación se desarrolla en un entorno físico y tridimensional con AirSim. El dron ejecuta la trayectoria previamente planificada, pero sometido a las condiciones realistas comentadas en el capítulo anterior. El vuelo generado se convierte en un fichero .plan compatible con QGroundControl, que permite su carga directa en el microcontrolador del dron. La trayectoria calculada se simula en AirSim y se sitúa en la posición del objetivo un detector ArUco para que, cuando el dron lo sobrevuele y detecte, pueda aterrizar en esa posición. En este sentido, se define un criterio de parada para la simulación, mientras que en la planificación venía dado por el número de pasos por algoritmo.

Para hacer esa comparativa, se va a utilizar el algoritmo DTW (*Dynamic Time Warping*) con la trayectoria teórica y la simulada. Este algoritmo permite medir la similitud entre dos series temporales que pueden variar en el tiempo o en la velocidad según su desarrollo. Su principal característica es que permite comparar deformaciones no lineales con respecto al tiempo, es decir, dos trayectorias que tienen una forma similar pero que han sido ejecutadas a velocidades distintas.[36].




Fig. 4.1. Configuración del *firmware* con QGC [37].

Es un algoritmo desarrollado en los años 70 para el reconocimiento de voz con ondas como fuente, aunque más adelante se ha utilizado para el emparejamiento de sonido, lenguaje de signos y gestos, series temporales, entre otras aplicaciones [38]. En la figura anterior se puede observar que, para la distancia euclidiana, se obtiene una similitud poco precisa. En cambio, con DTW, genera deformaciones en las funciones en forma de expansiones y contracciones que las alinea a pesar del desfase temporal.

Entrando más en detalle, sean $X = (x_1, x_2, \dots, x_n)$ y $Y = (y_1, y_2, \dots, y_m)$ dos secuencias temporales de longitudes n y m , respectivamente, el objetivo es encontrar la mejor alineación entre estas dos secuencias que minimice una función de coste acumulado. La matriz de coste acumulado $D \in \mathbb{R}^{n \times m}$ se puede definir como:

$$D(i, j) = d(x_i, y_j) + \min \begin{cases} D(i-1, j), \\ D(i, j-1), \\ D(i-1, j-1) \end{cases} \quad (4.1)$$

donde $d(x_i, y_j)$ representa una métrica de distancia local entre los elementos x_i e y_j , comúnmente la distancia euclídea:

$$d(x_i, y_j) = \|x_i - y_j\|_2 \quad (4.2)$$

Aunque también es necesario incluir dos restricciones. La condición inicial es:

$$D(1, 1) = d(x_1, y_1) \quad (4.3)$$

Y donde los casos límite se representan como:

$$D(i, 1) = d(x_i, y_1) + D(i - 1, 1), \quad D(1, j) = d(x_1, y_j) + D(1, j - 1) \quad (4.4)$$

La distancia DTW final, por tanto, es:

$$DTW(X, Y) = D(n, m) \quad (4.5)$$

Dado que existen muchos caminos posible, $D(n, m)$ se puede construir con la minimización de los costes de alineamiento global.



Fig. 4.2. Matriz de coste para minimizar la distancia acumulada entre dos series temporales[39].

4.1. Comparación de algoritmos

Cada ejecución para cada uno de los algoritmos genera dos *logs* con los que luego se calcula el mínimo coste de la distancia.

- **Fichero de referencia:** tiene guardada toda la información de la trayectoria planificada.

```
step,X,Y,Z
0,-6.735532598424347e-11,0.0,20.0
1,9.9991828926669,-10.000816946203386,20.0
2,19.999999838606563,-0.0016340550136003662,20.0
3,19.999999838606563,-0.0016340550136003662,20.0
4,29.999999755686176,-0.002451083582573732,20.0
5,39.99999967129663,-0.003268112151547098,20.0
6,40.000816700178255,9.99673180477475,20.0
7,40.00163373060323,19.99673171886859,20.0
8,50.00245067648573,29.99591460085287,20.0
9,50.003267709892775,39.99591451423859,20.0
10,40.0032677958811,39.9967315491806,20.0
11,30.004084915074667,49.99754849821645,20.0
12,40.0032677958811,39.9967315491806,20.0
13,50.003267709892775,39.99591451423859,20.0
```

Fig. 4.3. Datos de la trayectoria planificada en coordenadas locales.

- **Fichero de *ground truth*:** contiene los datos del escenario real.

```
1 time,latitude_deg,longitude_deg,absolute_altitude_m,relative_altitude_m,north_m_east_m_s,down_m_east_m_s,state
2 13:12:42,48.5423267,-4.0091588,-3.0499002632141113,-0.013000000125169754,-0.0016406751237809568,0.000267963478108868,-0.0016952484625002146,
3 13:12:43,48.5423267,-4.0091588,-3.0499002632141113,-0.0200000001415610313,-0.0019305722566863298,0.0004081742822505138,-0.0017805361150950393,
4 13:12:43,48.5423267,-4.0091588,-3.0499002632141113,-0.0200000001415610313,-0.0018226217964175005,0.00034680357202887535,-0.0012453189959727773,
5 13:12:44,48.5423267,-4.0091588,-3.0500001987348633,-0.0200000001415610313,-0.00175018222095680742,0.0014866426164276154,-0.00045845828192783574,HOLD
6 13:12:45,48.5423267,-4.0091588,-3.0500001987348633,-0.0200000001415610313,-0.001309646204188465,0.00393273298112408335,0.00010083875923196108,HOLD
7 13:12:45,48.5423267,-4.0091588,-3.0500001987348633,-0.0210000001579523887,-0.0018740221858024937,0.0018095504374146461,0.00054395688625427,HOLD
8 13:12:46,48.5423267,-4.0091588,-3.0500001987348633,-0.0210000001579523887,-0.0009546871863909864,0.002571898978203535,0.00091928621402176234,HOLD
9 13:12:47,48.5423267,-4.0091588,-3.0510001182556152,-0.0210000001579523887,0.000178827822713554,0.002290226286377175,0.0013615634438199862,HOLD
10 13:12:47,48.5423267,-4.0091588,-3.0510001182556152,-0.0210000001579523887,0.0006420151912607253,0.002445643180184758,0.00133917522732973,HOLD
11 13:12:48,48.5423267,-4.0091588,-3.0510001182556152,-0.0210000001579523887,0.0010765932966023684,0.002463128650560975,0.002064688270382415,HOLD
12 13:12:49,48.5423267,-4.0091588,-3.0510001182556152,-0.022000000174343586,0.0011801256941705942,0.0028113804827901125,0.0022894199937982036,HOLD
13 13:12:49,48.5423267,-4.0091588,-3.052000045776367,-0.022000000174343586,0.0015958781586959958,0.0028329393826425076,0.0025375764816999435,HOLD
14 13:12:50,48.5423267,-4.0091588,-3.052000045776367,-0.0230000001907348633,0.0018597871538881858,0.0026578460820019245,0.002080657942518502,HOLD
15 13:12:51,48.5423267,-4.0091588,-3.0530002117156982,-0.0230000001907348633,0.0022441284637289047,0.0036535311555958685,0.0023622626984398203,HOLD
16 13:12:51,48.5423268,-4.0091588,-3.0530002117156982,-0.0230000001907348633,0.0019336498880811572,0.003668817924335593,0.0026515845777638806,HOLD
17 13:12:52,48.5423269,-4.0091588,-3.0530002117156982,-0.024000000200816257,0.00079378763975208464,0.003938818445117527,0.000489345238000531,HOLD
18 13:12:53,48.5423268,-4.0091588,-3.05400013923645,-0.024000000200816257,0.000540084386958731,0.0038404849776676504,0.003274982463978539,HOLD
19 13:12:53,48.5423268,-4.0091588,-3.05400013923645,-0.02500000037252903,0.0008056501392275895,0.004504747688770394,0.003759595326672316,HOLD
20 13:12:54,48.5423268,-4.0091588,-3.05400013923645,-0.02500000037252903,0.0009282842046441335,0.00432859653921233,0.00368079567455387115,HOLD
21 13:12:55,48.5423268,-4.0091588,-3.055000066757202,-0.02500000037252903,0.0011306207161386742,0.0039089916021153593,0.0031706501126289368,HOLD
22 13:12:55,48.5423268,-4.0091588,-3.055000066757202,-0.026000000536441803,0.000401911284558475,0.0036637193183600903,0.0020447567819611597,TAKEOFF
23 13:12:56,48.5423268,-4.0091588,-3.055000066757202,-0.026000000536441803,-7.6036492828279736-05,0.003990692552179088,0.0036465647448185677,TAKEOFF
24 13:12:57,48.5423268,-4.0091588,-3.056000232696533,-0.026000000536441803,-0.0003323962655697465,0.00406462571957707405,0.004669539088836956,TAKEOFF
25 13:12:57,48.5423268,-4.0091588,-3.056000232696533,-0.026000000536441803,-0.0002155956082399508,0.003968597389757653,0.0046747326951473951,TAKEOFF
26 13:12:57,48.5423268,-4.0091588,-3.056000232696533,-0.026000000536441803,0.0003173868711836485,0.003950865473598262,0.0043864595655328035,TAKEOFF
27 13:12:58,48.5423268,-4.0091588,-3.056000232696533,-0.027000000700354576,0.000405997823690956,0.0037765852145195087,0.003262735749566553,TAKEOFF
28 13:12:59,48.5423268,-4.0091588,-3.056000232696533,-0.027000000700354576,0.00058068428658125257,0.004148992144154215,0.003658876091904664,TAKEOFF
29 13:12:59,48.5423268,-4.0091588,-3.057000168217285,-0.027000000700354576,0.00045939393234582614,0.0041424987613695512,0.00444595426318881,TAKEOFF
30 13:12:59,48.5423267,-4.0091588,-3.057000168217285,-0.027000000700354576,0.0011473982168335223,0.0023886833231606228,0.00456236789451877,TAKEOFF
31 13:13:00,48.5423267,-4.0091588,-3.057000168217285,-0.027000000700354576,0.0005440624158068117,0.0030039115808390417,0.003613559728159388,TAKEOFF
32 13:13:01,48.5423267,-4.0091588,-3.057000168217285,-0.027000000700354576,0.0005088561523482203,0.002161765471200807,0.003251299262046814,TAKEOFF
```

Fig. 4.4. Datos del *ground truth* de una misión.

Existe una diferencia importante entre ambos ficheros anteriores. Por un lado, se tiene la información del planificacón de la trayectoria, conocida como referencia, y que define el vuelo que el dron realizaría con el horizonte temporal como límite. Y, por otro, se obtiene el valor fundamental (o *Ground Truth* en inglés) de la trayectoria que tiene lugar en el simulador. Se comparan ambas trayectorias para estimar la diferencia entre la localización espacial entre lo teórico y lo real.

Cabe destacar que para todas las ejecuciones se ha conseguido aterrizar con éxito en la zona donde se encontraba el objetivo, es decir, se ha podido cargar cada fichero .plan al simulador con el horizonte temporal predefinido, y es en la simulación cuando se ha detectado el objetivo. En este sentido, el fichero de referencia contiene más información acerca de la localización de los puntos con los que cuenta la trayectoria de vuelo, mientras que el fichero de *Ground Truth* sólo contempla la información hasta el momento de detección. Además, este fichero, dado que se trata de una tarea asíncrona, captura, al menos, una medida por cada segundo de ejecución de vuelo, que se traduce en un mayor número de registros en el fichero .csv. El resultado, para cada uno de los algoritmos probados, es que el fichero de la verdad fundamental tiene más información temporal que el de referencia, mientras que este cuenta con más información espacial.

En consecuencia, y dado que se quiere comparar la localización del dron a lo largo del vuelo, es necesaria una interpolación de las trayectoria de referencia, esto es, el ajuste de puntos intermedios entre las posiciones de las trayectorias que se están comparando. Como es posible que las trayectorias no tengan el mismo número de puntos, es conveniente crear la secuencia de puntos intermedios para que tengan una representación uniforme, de manera que se puedan alinear mejor en la comparación.

La comparación se basa en los ejes espaciales horizontales, es decir, Norte y Este (NE-D/ENU). Se busca el mínimo del sumatorio entre todas los emparejamientos de puntos, o lo que es lo mismo, de la distancia total acumulada de las diferencias entre las dos trayectorias.

A continuación, se va a hacer un análisis de los algoritmos que ya se han descrito en el capítulo anterior. Para cada uno se ha utilizado una posición inicial del dron y del objetivo aleatoria con el fin de incluir aleatoriedad en las ejecuciones. Además, todos parten de unos parámetros comunes, donde los más importantes se pueden ver en la siguiente tabla:

Parámetro	Valor	Explicación
size	700	Dimensión total del espacio de búsqueda, en metros.
num_agents	1	Número de drones implicados en la misión.
height	20	Altura constante de vuelo del dron, en metros.
init_pos	-	Posición inicial del dron. Depende de la ejecución concreta del algoritmo.
obj_pos	-	Posición del objetivo. También varía según la ejecución de cada algoritmo.
num_steps	2000	Número máximo de pasos de simulación o decisiones temporales.
reference_system	ENU	Sistema de referencia East-North-Up usado para posicionamiento.
init_map	-	Matriz de 70x70 celdas que representa las probabilidades iniciales del mapa de búsqueda.

TABLA 4.1. PARÁMETROS COMUNES UTILIZADOS EN LA COMPARACIÓN DE ALGORITMOS

4.1.1. Heurística Miope

La posición inicial del dron se encuentra en (61, 55) y la del objetivo en (32, 23), o sea que el dron se lanza desde la parte superior derecha de Ω y debe aterrizar en lado derecho del jardín del campus.



Fig. 4.5. Planificación y simulación de vuelo de la Heurística Miope.

Como se puede ver en las imágenes, se trata de una trayectoria con muchos puntos de paso porque la naturaleza del algoritmo no concibe el cómputo global de la trayectoria, sino que sólo se mueve bajo la influencia de las casillas vecinas. En términos generales, se

puede decir que la simulación de vuelo sigue fielmente la planificación anterior y aterriza con éxito.



Fig. 4.6. Aterrizaje con éxito de la Heurística Miope.

El efecto de la trayectoria real sobre la planificada se puede ver en la Figura 4.7:




Fig. 4.7. Comparación de la trayectoria teórica y la real con la Heurística Miope.

En concreto, la mínima distancia acumulada, esto es, la medida del algoritmo DTW está entorno a 10.000 metros. Es importante tener en cuenta que la alineación por cada emparejamiento se encuentra en 1.5 metros. Ambas trayectorias se encuentra solapadas dado que siguen el mismo vuelo. Debido a la cantidad de puntos y la alineación de las trayectorias, se considerable razonable el error de cálculo estimado. Por temas de visualización, se ha optado por incluir algunas de las líneas (negras) que representan el emparejamiento.




Fig. 4.8. Dynamic Time Warping de la Heurística Miope.

4.1.2. Heurística

En este caso, la posición inicial del dron se encuentra en (53, 6) y la del objetivo en (19, 38), empieza en la zona inferior derecha y tiene que llegar hasta la residencia.




Fig. 4.9. Planificación y simulación de vuelo de la Heurística.

A este caso concreto, se le ha añadido una heurística extra, que es la de no pasar por la misma zona dos veces. A simple vista se puede ver cómo no repite ninguna zona de vuelo y barre todo el área de indicios. Es un algoritmo más inteligente que el anterior que ha necesitado menor tiempo para aterrizar en el objetivo.



Fig. 4.10. Aterrizaje con éxito de la Heurística.

Donde la comparación entre ambas trayectorias da lugar a la siguiente Figura:




Fig. 4.11. Comparación de la trayectoria teórica y la real con la Heurística.

En la siguiente imagen se puede ver el resultado del DTW, unos 2.000 metros de distancia acumulada y casi 1 metro de distancia por cada alineación de puntos. Se puede ver, por tanto, que la alienación entre las trayectorias es plena y que se ha cumplido con lo esperado.




Fig. 4.12. Dynamic Time Warping de la Heurística.

4.1.3. Lawnmower

El dron empieza en la posición (5, 65) y el objetivo se encuentra en (13, 23).




Fig. 4.13. Planificación y simulación de vuelo del Lawnmower.

Se trata de uno de los algoritmos de fuerza bruta que recorre todo el espacio de búsqueda. Es el menos eficiente en este caso porque sobrevuela zonas por las que no hay indicios, pero se asegura de llegar siempre al objetivo.



Fig. 4.14. Aterrizaje con éxito del *Lawnmower*.

Siendo uno de los algoritmos clásicos y predecibles, se puede ver en la Figura 4.15 la superposición de ambas trayectorias:

Drone trajectory



Fig. 4.15. Comparación de la trayectoria teórica y la real con el *Lawnmower*

Por su parte, este algoritmo ha sufrido un desplazamiento de las coordenadas que le ha hecho aumentar el coste acumulado hasta los 125.000 metros en total. Si bien es cierto que la trayectoria es prácticamente la misma, existe un desfase entre ambas que se debe a los 10 metros en promedio de diferencia que existen por emparejamiento.




Fig. 4.16. Dynamic Time Warping del *Lawnmower*.

4.1.4. Expanding

Por último, en esta ejecución el dron empieza en (4, 3) y el objetivo está en (18, 30).




Fig. 4.17. Planificación y simulación de vuelo del Expanding.

Es una situación bastante favorable para este caso de uso, dado que el dron acude al centro de Ω para empezar la búsqueda, y el objetivo se encuentra relativamente céntrico.




Fig. 4.18. Aterrizaje con éxito del Expanding.

Por otro lado, el solapamiento entre las dos trayectorias se puede ver en la Figura 4.19:



Fig. 4.19. Comparación de la trayectoria teórica y la real con el *Expanding*.

Con un coste acumulado de 140.000 metros y una distancia promedio de 13,5 metros. Se puede ver una mayor densidad de emparejamientos en el centro de la imagen, probablemente porque el *ground truth* tiene más puntos distribuidos densamente en una zona donde la referencia tiene pocos, por lo que se generan algunos emparejamientos que tratan de minimizar la distancia total.




Fig. 4.20. Dynamic Time Warping del *Expanding*.

4.2. Observaciones generales

Se puede observar, por tanto, que las trayectorias simuladas se representan con bastante precisión a las teóricas, o sea existe una gran similitud con el comportamiento esperado del dron. Sin embargo, también hay algunas diferencias entre los algoritmos heurísticos y voraces que han marcado un mayor o menor coste en la trayectoria. En la siguiente Tabla se recoge un resumen de los resultados obtenidos.

Algoritmo	Coste acumulado	Distancia promedio
Heurística Miope	10 180,27	1,59
Heurística	2 061,37	0,93
Lawnmower	125 355,04	10,36
Expanding	141 217,57	13,47

TABLA 4.2. COMPARATIVA DE DISTANCIA DTW ENTRE ALGORITMOS Y DISTANCIA PROMEDIO POR EMPAREJAMIENTO.

5. CONCLUSIONES

En este trabajo se han mostrado las tres fases de un sistema que permite generar y simular trayectorias a partir del nombre de una calle mediante diferentes algoritmos. Las conclusiones del documento surgen por el cumplimiento de los objetivos planteados en un inicio y los resultados obtenidos

Con respecto al primer bloque, que recoge la captura de coordenadas de distintas fuentes de información, se puede decir que se ha completado con éxito esa captura de coordenadas que representan distintas fuentes para modelar el problema. A través de la API Overpass se tiene acceso a una gran cantidad de recursos geoespaciales en línea que han otorgado la base sobre la que se construye el sistema entero.

Por su parte, en la planificación se ha podido crear una trayectoria en base a unos algoritmos de prueba (dos voraces y dos por fuerza bruta) y un mapa de probabilidades iniciales que está centrado en el mismo lugar que el utilizado en el bloque anterior, todo transformando y trabajando en coordenadas locales y globales. Esta parte del sistema ha podido validar que las trayectorias definidas son aptas para materializarlas en un vuelo simulado en el siguiente bloque, por lo que se constituye como un pilar fundamental del sistema.

Y, por último, en el último bloque se ha podido llevar a la situación más realista posible, dadas las circunstancias del caso de uso. Se ha podido comprobar el grado de similitud entre el vuelo, para cada uno de los algoritmos, con su trayectoria planificada. Resulta muy útil para el problema que se achaca en este trabajo porque corrobora que las trayectorias teóricas son posibles en el mundo real, bajo la influencia de ciertos factores físicos (como la velocidad, condiciones climatológicas, movimiento del UAV, etc.)

Por lo tanto, se puede decir que en este trabajo se ha conseguido de manera satisfactoria los objetivos planteados en un inicio para poder construir el sistema de generación y simulación de trayectorias. Este trabajo ha permitido crear un *pipeline* de ejecución que se divide en los tres bloques vistos a lo largo del trabajo.

Además, desde un punto de vista pedagógico, este trabajo ha permitido una familiarización con el mundo de los drones, desde la definición del problema que se quiere resolver hasta la viabilidad de la misión a través de una simulación. Por otro lado, también ha dado un gran conocimiento técnico sobre la gestión de trayectorias de vuelo del UAV, no sólo porque se haya escrito código, sino porque es necesario un entendimiento de la física del dron y todos los factores que afectan en su vuelo.

5.1. Futuras líneas de trabajo

Dado que el trabajo abarca tres grandes secciones, existen numerosos frentes por los que se podría continuar en un futuro este trabajo de investigación. Entre otras, se podría des-

tacar:

- Añadir más fuentes de información a la planificación de la trayectoria, además de la parcela de indicios. Cuanto mejores sean las fuentes más rápido y eficiente será el algoritmo y su representación.
- Añadir más de un dron (un enjambre) o múltiples objetivos al sistema. Cada dron podría recorrer un tramo del espacio de búsqueda y aterrizar en cuanto uno detectase un objetivo.
- Distintas modelizaciones de la probabilidad del espacio de búsqueda. En vez de ser equiprobable, se podrían construir distribuciones gaussianas multivariantes que se superpongan según la cantidad de objetivos.
- Considerar otros algoritmos sobre los que hacer la planificación y simulación de vuelo. Del mismo modo, contemplar otras métricas en el análisis de trayectorias de vuelo.
- Implementación de un módulo en Python de aterrizaje de precisión, donde el dron aterrice exactamente donde se encuentra el objetivo. Introduce a un nivel más avanzado el ángulo de detección de la cámara del sensor.
- Vuelo en la vida real de la trayectoria teórica. En un caso de uso similar al de este trabajo, se podría plantear un vuelo autónomo, aunque siempre cumpliendo las restricciones de vuelo [40].

5.2. Gestión del proyecto

A lo largo del último año se ha podido realizar el trabajo en tres fases distintas:

- **Contacto y definición del problema:** el primer mes y medio se utilizó para ponerse en contacto con el tutor, la selección del tema, estudio de su estado del arte y definición del caso de uso.
- **Experimentación:** abarca las tres fases de experimentación que se han llevado a cabo en todo el trabajo. Es la fase más larga que incluye el desarrollo del sistema.
- **Documentación:** es la última fase y posterior a la experimentación, y consiste en la escritura de todo lo realizado en esta memoria en el tiempo.

En el siguiente diagrama se muestra toda la planificación del trabajo durante su tiempo de desarrollo:




Fig. 5.1. Diagrama de Gantt del trabajo realizado.

6. ANEXO

6.1. Anexo 1

La consulta a la API Overpass con la que se obtienen las coordenadas iniciales, y a partir de las que se desencadena el resto del sistema, es:

```
1 def coordenadas_calle(pais: str, municipio: str, calle: str) -> dict
2 :
3     """Obtiene y guarda las coordenadas de la calle inicial en un
4     JSON"""
5
6     overpass_url = "https://overpass-api.de/api/interpreter"
7     consulta = f"""
8     [out:json];
9     // Definir el área de la zona
10    area["name"="{pais}"]["boundary"="administrative"]->.pais;
11    area["name"="{municipio}"]["boundary"="administrative"](area.
12    pais)->.municipio;
13    // Seleccionar una calle
14    (
15    way["highway"]["name"="{calle}"](area.municipio);
16    );
17    out geom;
18    """
19    response = requests.get(overpass_url, params={'data': consulta})
20
21    archivo_json = f"{calle}.json"
22    with open(archivo_json, 'w', encoding='utf-8') as file:
23        file.write(response.text)
24    print(f"Archivo JSON guardado como: {archivo_json}")
25
26    return archivo_json
```

6.2. Anexo 2: Declaración de uso de IA Generativa en el TFG

He usado IA Generativa en este trabajo.

Marca lo que corresponda:

SI **NO**

Si has marcado **SI**, completa las siguientes 3 partes de este documento:

Parte 1: Reflexión sobre comportamiento ético y responsable

Ten presente que el uso de IA Generativa conlleva unos riesgos y puede generar una serie de consecuencias que afecten a la integridad moral de tu actuación con ella. Por eso, te pedimos que contestes con honestidad a las siguientes preguntas (Marca lo que corresponda):

Pregunta 1

En mi interacción con herramientas de IA Generativa he remitido datos de carácter sensible con la debida autorización de los interesados:

- SÍ, he usado estos datos con autorización
- NO, he usado estos datos sin autorización
- **NO, no he usado datos de carácter sensible**

Pregunta 2

En mi interacción con herramientas de IA Generativa he remitido materiales protegidos por derechos de autor con la debida autorización de los interesados:

- SÍ, he usado estos materiales con autorización
- NO, he usado estos materiales sin autorización
- **NO, no he usado materiales protegidos**

Pregunta 3

En mi interacción con herramientas de IA Generativa he remitido datos de carácter personal con la debida autorización de los interesados:

- SÍ, he usado estos datos con autorización
- NO, he usado estos datos sin autorización
- **NO, no he usado datos de carácter personal**

Mi utilización de la herramienta de IA Generativa ha respetado sus términos de uso, así como los principios éticos esenciales, no orientándola de manera maliciosa a obtener un resultado inapropiado para el trabajo presentado, es decir, que produzca una impresión

o conocimiento contrario a la realidad de los resultados obtenidos, que suplante mi propio trabajo o que pueda resultar en un perjuicio para las personas.

SI NO

Si NO has contado con la autorización de los interesados en alguna de las preguntas 1, 2 o 3, explica brevemente el motivo:

Parte 2: Declaración de uso técnico

Declaro haber hecho uso del sistema de IA Generativa (Nombre del sistema/herramienta IA y versión: ChatGPT) para:

Documentación y redacción

- Soporte a la reflexión en relación con el desarrollo del trabajo: proceso iterativo de análisis de alternativas y enfoques utilizando la IA.

He solicitado una primera guía sobre cómo abordar el trabajo, y luego lo he adaptado al esquema que tenía planteado, según me pareciese relevante.

- Revisión o reescritura de párrafos redactados previamente

He solicitado una guía sobre cómo estructurar los párrafos para mantener la coherencia del argumento.

Búsqueda de información o respuesta a preguntas concretas

Las preguntas realizadas se orientaban a explicaciones sobre algoritmos u otra teoría necesaria para el desarrollo del TFG (regulación de los UAVs, modelo probabilístico, DTW, etc.)

Búsqueda de bibliografía

He solicitado una búsqueda de bibliografía, sólo para el contexto económico del trabajo, donde pude ver el estado del mercado de los drones.

Resumen de bibliografía consultada

No he solicitado un resumen de la bibliografía consultada. He accedido directamente a la fuente de información proporcionada y he utilizado lo que he considerado más relevante

para mi trabajo, siempre citando la referencia.

Traducción de textos consultados

No he solicitado la traducción de ningún texto.

Desarrollar contenido específico

- Asistencia en el desarrollo de líneas de código (programación)

He pedido explicaciones sobre un código en lenguaje Python para entenderlo mejor y, a partir de ahí, modificar lo que fuese necesario.

- Generación de esquemas, imágenes, audios o vídeos

No he generado ningún esquema, imagen, audio o vídeo para el TFG con IA Generativa. Ha sido toda elaboración propia o referencias a trabajos ya realizados.

- Procesos de optimización

He solicitado ayuda para corregir y explicar errores de un código que no funcionaba correctamente.

- Tratamiento de datos: recogida, análisis, cruce de datos...

He pedido una guía para hacer un análisis de los datos a partir de unos gráficos que he elaborado yo previamente.

- Inspiración de ideas en el proceso creativo

No he solicitado ninguna inspiración de ideas en el proceso creativo.

Otros usos vinculados al desarrollo específico del trabajo

Si crees necesario incluirlo, añade, en cada uno de los casos:

Empleando el prompt:

Teniendo como interacción:

Ejemplo: Declaro haber hecho uso del sistema de IA Generativa ChatGPT 3.5 para buscar información empleando el prompt: “Dime un ejemplo concreto que ilustre la aplicación de la propuesta urbanística de la Ciudad de los 15 minutos en España” teniendo como interacción la proposición del ejemplo concreto del distrito de Chamartín que se ha reflejado en la memoria.

Parte 3: Reflexión sobre utilidad

Creo que la principal fortaleza de la IA Generativa es la concisión con la que responde ante cualquier pregunta. Me parece que responde exactamente a lo que estás preguntando, y resulta muy útil para hacerte una idea rápida de un tema. Sin embargo, no me parece que se pueda hacer un trabajo entero con esta herramienta porque es propensa a cometer errores y, en ocasiones, no es capaz de adaptarse al contexto de una nueva pregunta.

BIBLIOGRAFÍA

- [1] UAV Drone. “El impacto de los drones en la logística y entrega de paquetes.” Consultado el 6 de mayo de 2025. (s.f.), [En línea]. Disponible en: <https://uavdrone.es/el-impacto-de-los-drones-en-la-logistica-y-entrega-de-paquetes/>.
- [2] M. Intelligence. “Tamaño del mercado de drones y análisis de participación tendencias de crecimiento y pronósticos (2024-2029).” Accedido el 6 de mayo de 2025. (2024), [En línea]. Disponible en: <https://www.mordorintelligence.com/es/industry-reports/drones-market#:~:text=An%C3%A1lisis%20del%20mercado%20de%20drones,espacio%20a%C3%A9reo%20de%20ciertos%20pa%C3%ADses..>
- [3] AESA. “Normativa de UAS.” Accedido el 6 de mayo de 2025. (2025), [En línea]. Disponible en: <https://www.seguridadaerea.gob.es/es/ambitos/drones/normativa-de-uas-drones>.
- [4] ENAIRE. “Restricción geográfica de vuelo.” (2025), [En línea]. Disponible en: <https://drones.enaire.es/>.
- [5] I. Bardón. “Máquinas voladoras de Leonardo da Vinci.” (), [En línea]. Disponible en: <https://aertecsolutions.com/2019/10/14/maquinas-voladoras-de-leonardo-da-vinci/>.
- [6] ZTFNews. “George Cayley y la historia de la aviación.” (), [En línea]. Disponible en: <https://ztfnews.wordpress.com/2013/12/27/george-cayley-y-la-historia-de-la-aviacion/>.
- [7] Wikipedia. “George Cayley.” (), [En línea]. Disponible en: https://es.wikipedia.org/wiki/George_Cayley.
- [8] L. Holzwarth. “The story of the Kettering Bug, the World’s First Aerial Drone.” (), [En línea]. Disponible en: <https://historycollection.com/the-story-of-the-kettering-bug-the-worlds-first-aerial-drone/>.
- [9] Aviation Group. “¿Quién inventó los drones?” Consultado el 6 de mayo de 2025. (s.f.), [En línea]. Disponible en: <https://www.aviationgroup.es/actualidad/drones-quien-invento/>.
- [10] El Confidencial. “Así funciona el reparto con drones en España: pruebas, normativas y futuro.” Consultado el 6 de mayo de 2025. (2024), [En línea]. Disponible en: <https://www.pressreader.com/spain/el-confidencial/20240912/281646785518195>.
- [11] Drone y Más. “Clasificación y tipos de drones: según su uso, forma y características.” Consultado el 6 de mayo de 2025. (s.f.), [En línea]. Disponible en: <https://droneymas.es/clasificacion-tipos-de-drones/>.

- [12] Grupo ACRE. “ACRE, distribuidor oficial JOUAV, líder en drones de ala fija de alta autonomía y capacidad de carga.” Consultado el 7 de mayo de 2025. (s.f.), [En línea]. Disponible en: <https://grupoacre.es/acre-distribuidor-oficial-jouav-lider-en-drones-de-ala-fija-de-alta-autonomia-y-capacidad-de-carga/>.
- [13] IDC - APD Drones. “Tipos de drones y sus diferencias.” Consultado el 7 de mayo de 2025. (s.f.), [En línea]. Disponible en: <https://idc.apddrones.com/drones/tipos-de-drones-y-sus-diferencias/>.
- [14] La Razón. “Qué tipos de drones militares existen y cómo se están usando en la guerra de Ucrania.” Consultado el 7 de mayo de 2025. (2023), [En línea]. Disponible en: <https://www.larazon.es/internacional/20230201/mboyxapbxzg5rljhmrrsoredoy.html>.
- [15] El País. “Los mejores drones para niños y niñas.” Consultado el 7 de mayo de 2025. (2021), [En línea]. Disponible en: <https://elpais.com/escaparate/2021-12-27/los-mejores-drones-para-ninos-y-ninas.html>.
- [16] P. Lanillos, J. Yanez-Zuluaga, J. J. Ruz y E. Besada-Portas, “A bayesian approach for constrained multi-agent minimum time search in uncertain dynamic domains,” en *Proceedings of the 15th annual conference on Genetic and evolutionary computation*, 2013, pp. 391-398.
- [17] S. Pérez-Carabaza, E. Besada-Portas, J. A. López-Orozco y G. Blasco, “Modelado y optimización de misiones de búsqueda de objetivos mediante UAVs,” en *XL Jornadas de Automática*, Universidade da Coruña, Servizo de Publicacións, 2019, pp. 574-581.
- [18] E. Besada-Portas, J. L. Risco-Martín, J. A. López-Orozco y J. J. Navarro-Corcuera, “Análisis y planificación de misiones de búsqueda y rescate en el entorno marítimo,” en *XL Jornadas de Automática*, Universidade da Coruña, Servizo de Publicacións, 2019, pp. 8-15.
- [19] Ø. Breivik y A. A. Allen, “An operational search and rescue model for the Norwegian Sea and the North Sea,” *Journal of Marine Systems*, vol. 69, n.º 1-2, pp. 99-113, 2008.
- [20] T. M. Kratzke, L. D. Stone y J. R. Frost, “Search and rescue optimal planning system,” en *2010 13th International Conference on Information Fusion*, IEEE, 2010, pp. 1-8.
- [21] S. Pérez-Carabaza, J. Scherer, B. Rinner, J. A. López-Orozco y E. Besada-Portas, “UAV trajectory optimization for Minimum Time Search with communication constraints and collision avoidance,” *Engineering Applications of Artificial Intelligence*, vol. 85, pp. 357-371, 2019.
- [22] S. Pérez-Carabaza, E. Besada-Portas, J. A. Lopez-Orozco y G. Pajares, “Minimum Time Search in Real-World Scenarios Using Multiple UAVs with Onboard Orientable Cameras,” *Journal of Sensors*, vol. 2019, n.º 1, p. 7 673 859, 2019.

- [23] S. P. Carabaza, “Título de la tesis doctoral,” Tesis doctoral, Universidad Complutense de Madrid, 2023. [En línea]. Disponible en: <https://docta.ucm.es/entities/publication/ae52ef42-42cb-4e76-a399-f5dca6685813>.
- [24] S. Thrun, W. Burgard y D. Fox, *Probabilistic robotics*. MIT Press, 2005.
- [25] K. Ghanizadegan y H. A. Hashim, “Unscented Particle Filter for Visual-inertial Navigation using IMU and Landmark Measurements,” *arXiv preprint arXiv:2504.19318*, 2025.
- [26] N. E. M. Shawky, “Accuracy Enhancement of GPS for Tracking Multiple Drones Based on MCMC Particle Filter,” *International Journal of Security and Privacy in Pervasive Computing*, vol. 12, n.º 1, pp. 1-16, 2020. doi: [10.4018/IJSPPC.2020010101](https://doi.org/10.4018/IJSPPC.2020010101).
- [27] Wikipedia contributors, *Geographic coordinate conversion — Wikipedia, The Free Encyclopedia*, Accedido el 8 de mayo de 2025, 2025. [En línea]. Disponible en: https://en.wikipedia.org/wiki/Geographic_coordinate_conversion.
- [28] Wikipedia contributors, *Local tangent plane coordinates — Wikipedia, The Free Encyclopedia*, Accedido el 8 de mayo de 2025, 2025. [En línea]. Disponible en: https://en.wikipedia.org/wiki/Local_tangent_plane_coordinates.
- [29] J. P. Llerena Caña, J. García Herrero y J. M. Molina López, “Error Reduction in Vision-Based Multirotor Landing System,” *Sensors*, vol. 22, n.º 10, 2022. doi: [10.3390/s22103625](https://doi.org/10.3390/s22103625). [En línea]. Disponible en: <https://www.mdpi.com/1424-8220/22/10/3625>.
- [30] “MAVLink Developer Guide.” Consultado el 7 de mayo de 2025. (2025), [En línea]. Disponible en: <https://mavlink.io/en/>.
- [31] “MAVLink Implementation | PX4/PX4-Autopilot | DeepWiki.” Consultado el 7 de mayo de 2025. (2025), [En línea]. Disponible en: <https://deepwiki.com/PX4/PX4-Autopilot/5.1-mavlink-implementation>.
- [32] “MAVLink Basics — Dev documentation - ArduPilot.” Consultado el 7 de mayo de 2025. (2025), [En línea]. Disponible en: <https://ardupilot.org/dev/docs/mavlink-basics.html>.
- [33] “Simulation | PX4 Guide (main).” Consultado el 7 de mayo de 2025. (2025), [En línea]. Disponible en: <https://docs.px4.io/main/en/simulation/>.
- [34] “Software Overview - PX4 Autopilot.” Consultado el 7 de mayo de 2025. (2025), [En línea]. Disponible en: <https://px4.io/software/software-overview/>.
- [35] “Frame Selection | PX4 User Guide (v1.11).” Consultado el 7 de mayo de 2025. (2025), [En línea]. Disponible en: https://docs.px4.io/v1.11/en/getting_started/frame_selection.html.
- [36] M. Stent. “Dynamic Time Warping: An Introduction.” Consultado el 8 de mayo de 2025. (2025), [En línea]. Disponible en: <https://medium.com/@markstent/dynamic-time-warping-a8c5027defb6>.

- [37] “Understanding Dynamic Time Warping.” Consultado el 8 de mayo de 2025. (2019), [En línea]. Disponible en: <https://www.databricks.com/blog/2019/04/30/understanding-dynamic-time-warping.html>.
- [38] P. Senin. “Dynamic Time Warping Algorithm Review.” Consultado el 8 de mayo de 2025. (2025), [En línea]. Disponible en: https://www.researchgate.net/publication/228785661_Dynamic_Time_Warping_Algorithm_Review.
- [39] “Dynamic Time Warping — pyts 0.7.0 documentation.” Consultado el 8 de mayo de 2025. (2025), [En línea]. Disponible en: https://johannfaouzi.github.io/pyts/auto_examples/plot_dtw.html.
- [40] “Restricciones de vuelo de UAVs.” Consultado el 8 de mayo de 2025. (2025), [En línea]. Disponible en: <https://www.seguridadaerea.gob.es/es/ambitos/drones/zonas-geograficas-de-uas>.