

Grado Universitario en Ingeniería Informática
2024-2025

Trabajo Fin de Grado

“Simulación hiperrealista para evaluación de estrategias de búsqueda en espacios con incertidumbre”

Álvaro Gómez Lázaro

Tutor/es

Jesús García Herrero

Juan Pedro Llerena Caña



Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento - No Comercial - Sin Obra Derivada**

RESUMEN

La búsqueda de objetivos en entornos donde su ubicación es incierta, pero se dispone de indicios provenientes de una o varias fuentes de información, se conoce como búsqueda en espacios con incertidumbre. Este tipo de problemas se ha abordado principalmente desde la perspectiva de la teoría de búsqueda bayesiana, cuyos orígenes se remontan al *Anti-Submarine Warfare Operations Research Group* (ASWORG) durante la Segunda Guerra Mundial. Este grupo tenía como objetivo desarrollar herramientas eficaces para interceptar submarinos enemigos, en contextos donde la información era parcial e incierta.

Los enfoques bayesianos abordan de forma explícita la incertidumbre inherente a múltiples fuentes de información. Esto incluye los indicios utilizados en la búsqueda, el comportamiento esperado de los objetivos, la dinámica de los sensores empleados para su detección y las características del movimiento de los vehículos o agentes que llevan a cabo la búsqueda. El objetivo común de estas metodologías es maximizar la probabilidad de localizar los objetivos y, al mismo tiempo, reducir el tiempo necesario para su identificación.

Para modelar la dinámica de los rastreadores ya sean agentes autónomos o vehículos equipados con sensores, es habitual emplear modelos deterministas que aproximan su comportamiento a partir de acciones de control. Estos modelos permiten planificaciones más realistas, pero en muchos casos no consideran las desviaciones que pueden producirse en sistemas reales, lo que introduce una fuente adicional de incertidumbre que aún no se integra de forma habitual en los planificadores.

En este Trabajo de Fin de Grado se propone la evaluación de distintas estrategias de búsqueda en espacios con incertidumbre, utilizando un conjunto de métricas de calidad. Las estrategias se implementan en un vehículo aéreo no tripulado (UAV- *Unmanned Aerial Vehicle*) dentro de un entorno de simulación hiperrealista de SITL (*Software in The Loop*), en el que se incorporan las dinámicas asociadas a un controlador de vuelo real, con el objetivo de analizar su rendimiento de manera más precisa.

Los resultados obtenidos muestran que, dependiendo de la estrategia utilizada, la misión ejecutada se aproxima mejor o peor a la misión planificada, lo cual sienta precedentes para emplear una estrategia u otra en una misión de búsqueda en espacios con incertidumbre dependiendo del vehículo o agente utilizado.

Palabras clave: Algoritmos de Búsqueda, espacios con incertidumbre, UAV, SITL, AirSim, Px4, MAVLink.

DEDICATORIA

En primer lugar, agradecer a mi familia todo el apoyo que me han mostrado durante estos años de estudio; sin ellos no estaría ahora mismo escribiendo este trabajo y terminando mi etapa como estudiante.

A los amigos de mi ciudad de origen, con sus bromas y tonterías que hacen que me sienta feliz en mi día a día y que me olvide de los altibajos que he podido encontrar a lo largo de mi vida. También a las personas que he conocido en la universidad, gente que me ha acogido muy bien y que ha hecho mucho más llevadero este camino, creando un recuerdo que nunca olvidaré.

Por último, agradecer a Jesús García Herrero y Juan Pedro Llerena Caña, mis tutores durante este proyecto, los cuales me han descubierto un mundo fascinante que nunca hubiera imaginado y, sobre todo, por su paciencia a pesar de lo holgazán que puedo llegar a ser en algunos momentos. Ha sido un placer haber trabajado con vosotros y haber adquirido tanto conocimiento a vuestro lado.

ÍNDICE GENERAL

1. INTRODUCCIÓN.	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Entorno socio-económico	3
1.3.1. Presupuesto	3
1.4. Marco regulador	4
1.5. Estructura	5
2. ESTADO DEL ARTE.	6
3. FORMULACIÓN DEL PROBLEMA DE BÚSQUEDA	9
3.1. Modelo Probabilístico de la Posición Inicial del Objetivo	9
3.2. Dinámica del UAV	9
3.3. Modelo del objetivo:	10
3.4. Modelo de Sensor	10
3.5. Fusión de Información.	11
3.6. Notación	12
4. PROPUESTA	14
4.1. Software In The Loop (SITL).	14
4.2. Planificación de la misión	16
4.2.1. Algoritmos de búsqueda.	16
4.2.2. Plan de misión	20
4.3. Sistemas de Referencia y Transformaciones.	20
4.4. Controlador de vuelo.	24
4.4.1. MAVSDK.	24
4.4.2. Envío de misión a dron	25
5. EXPERIMENTACIÓN	26
5.1. Preparación de los escenarios	28
5.2. Escenario 1	29
5.3. Escenario 2	52

5.4. Escenario 3	61
6. CONCLUSIONES	65
6.1. Conclusiones finales	65
6.2. Futuros trabajos	66
BIBLIOGRAFÍA	68

ÍNDICE DE FIGURAS

4.1	Estructura del Sistema	14
4.2	Ejecución de misión en Airsim con Cesium	15
4.3	Algoritmo BF-Lawnmower	17
4.4	Algoritmo BF-Expanding	18
4.5	Algoritmo Ldfs-Miope	19
4.6	Algoritmo Ldfs-Heur	20
4.7	Marcador Aruco utilizado en el proyecto	22
4.8	Sistema de coordenadas WGS84 [26]	23
4.9	Flujo de envío de una misión	25
5.1	Diferentes escenarios diseñados para la experimentación	26
5.2	Escenario primera misión	30
5.3	Interfaz QGC donde se ha cargado una misión	31
5.4	Reproducción de trayectorias con algoritmo de fuerza bruta de corta césped primer escenario	32
5.5	Error por coordenadas entre referencia y gt en algoritmo de corta césped primer escenario	34
5.6	Alineamiento de trayectorias utilizando DTW en Bf-lawnmower primer escenario	35
5.7	Distribución y frecuencia de la distancia DTW en algoritmo Bf-lawnmower primer escenario	36
5.8	Reproducción de trayectorias con algoritmo Bf-expanding primer escenario	37
5.9	Error por coordenadas entre referencia y gt en algoritmo Bf-expanding primer escenario	38
5.10	Alineamiento de trayectorias utilizando DTW en Bf-expanding primer escenario	39
5.11	Distribución y frecuencia de la distancia DTW en algoritmo Bf-expanding primer escenario	40
5.12	Reproducción de trayectorias con algoritmo Ldfs-heur primer escenario	41

5.13	Error por coordenadas entre referencia y gt en algoritmo Ldfs-heur primer escenario	42
5.14	Alineamiento de trayectorias utilizando DTW en Ldfs-heur primer escenario	43
5.15	Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-heur primer escenario	44
5.16	Reproducción de trayectorias con algoritmo Ldfs-miope primer escenario	45
5.17	Error por coordenadas entre referencia y gt en algoritmo Ldfs-miope primer escenario	46
5.18	Alineamiento de trayectorias utilizando DTW en Ldfs-miope primer escenario	47
5.19	Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-miope primer escenario	48
5.20	Función de distribución acumulada de todos los algoritmos primer escenario	50
5.21	Distribución de la distancia DTW por algoritmo primer escenario	51
5.22	Distribución y frecuencia de la distancia DTW en algoritmo Bf-lawnmower segundo escenario	53
5.23	Muestra de patrón de movimiento del dron en el segundo escenario	55
5.24	Distribución y frecuencia de la distancia DTW en algoritmo Bf-expanding segundo escenario	56
5.25	Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-heur segundo escenario	57
5.26	Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-miope segundo escenario	58
5.27	Función de distribución acumulada de todos los algoritmos segundo escenario	60

ÍNDICE DE TABLAS

1.1	PRESUPUESTO COMPONENTES HARDWARE	4
1.2	COSTE HUMANITARIO	4
1.3	PRESUPUESTO TOTAL DEL PROYECTO	4
4.1	NOMENCLATURA DE LOS ALGORITMOS DE BÚSQUEDA UTILIZADOS	16
5.1	ERROR (RMSE) ALGORITMO BF-LAWNMOWER PRIMER ESCENARIO	34
5.2	ESTADÍSTICOS DESCRIPTIVOS DTW EN BF-LAWNMOWER PRIMER ESCENARIO	36
5.3	ERROR (RMSE) ALGORITMO BF-EXPANDING PRIMER ESCENARIO	38
5.4	ESTADÍSTICOS DESCRIPTIVOS DTW EN BF-EXPANDING PRIMER ESCENARIO	40
5.5	ERROR (RMSE) ALGORITMO LDFS-HEUR PRIMER ESCENARIO	42
5.6	ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-HEUR PRIMER ESCENARIO	44
5.7	ERROR (RMSE) ALGORITMO LDFS-MIOPE PRIMER ESCENARIO	46
5.8	ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-MIOPE PRIMER ESCENARIO	48
5.9	ERROR (RMSE) POR COORDENADAS DE CADA ALGORITMO DE BÚSQUEDA PRIMER ESCENARIO	49
5.10	COMPARACIÓN DE RESULTADOS DWT DE LOS DISTINTOS ALGORITMOS PRIMER ESCENARIO	50
5.11	RESULTADOS DISTANCIA Y TIEMPO MEDIO PRIMER ESCENARIO	51
5.12	ERROR (RMSE) ALGORITMO BF-LAWNMOWER SEGUNDO ESCENARIO	53
5.13	ESTADÍSTICOS DESCRIPTIVOS DTW EN BF-LAWNMOWER SEGUNDO ESCENARIO	54
5.14	ERROR (RMSE) ALGORITMO BF-EXPANDING SEGUNDO ESCENARIO	55

5.15	ESTADÍSTICOS DESCRIPTIVOS DTW EN BF-EXPANDING SEGUNDO ESCENARIO	56
5.16	ERROR (RMSE) ALGORITMO LDFS-HEUR SEGUNDO ESCENARIO	57
5.17	ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-HEUR SEGUNDO ESCENARIO	57
5.18	ERROR (RMSE) ALGORITMO LDFS-MIOPE SEGUNDO ESCENARIO	58
5.19	ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-MIOPE SEGUNDO ESCENARIO	59
5.20	ERROR (RMSE) POR COORDENADAS DE CADA ALGORITMO DE BÚSQUEDA SEGUNDO ESCENARIO	59
5.21	COMPARACIÓN DE RESULTADOS DWT DE LOS DISTINTOS ALGORITMOS SEGUNDO ESCENARIO	60
5.22	TIEMPO Y DISTANCIA MEDIA HASTA DETECCIÓN DEL MARCADOR SEGUNDO ESCENARIO	61
5.23	COMPARACIÓN DISTANCIA MEDIA REAL Y PLANIFICADA EN METROS TERCER ESCENARIO	62
5.24	TASA DE ACIERTO TERCER ESCENARIO	63
5.25	TIEMPO MEDIO HASTA DETECCIÓN DEL MARCADOR EN TERCER ESCENARIO	64

1. INTRODUCCIÓN

1.1. Motivación

En el contexto del salvamento y rescate, los drones pueden resultar grandes aliados como vehículos de intervención rápida. Bajo estos escenarios, la entrega de un chaleco salvavidas, un botiquín o incluso un sistema de comunicación puede significar la diferencia entre la vida o la muerte. Sin embargo, cuando suceden accidentes o catástrofes, la posición exacta de las víctimas suele ser incierta. En este trabajo se exploran estrategias de búsqueda en espacios con incertidumbre para la búsqueda de objetivos, trabajando en un entorno hiperrealista de “Software In The Loop” (SITL) basado en Unreal Engine y el controlador de vuelo PX4. El objetivo es integrar diferentes sistemas de detección de objetos basados en visión por computador en un dron y evaluar el comportamiento de la misión utilizando diferentes estrategias de búsqueda y entornos simulados (condiciones meteorológicas de visión).

En el año 1966 se produce un accidente entre dos aviones del ejército norteamericano en la localidad española de Palomares, que lleva a que tres bombas termonucleares que estos portan caigan al suelo y una se pierda en el mar Mediterráneo. El hecho de que una bomba termonuclear se encontrase perdida en el mar y el temor de que los rusos pudiesen hacerse con el artefacto, hizo que la Armada estadounidense iniciase una búsqueda desafiante que se puede considerar como uno de los primeros usos de búsquedas en espacios con incertidumbre.

La búsqueda de objetivos dentro de un cierto espacio en el que no se sabe con exactitud la posición del objetivo, por el estado del entorno o por la variación de posición del objetivo, es un problema que se ha estudiado desde la Segunda Guerra Mundial por sus diversas aplicaciones tanto en operaciones militares como en misiones de búsqueda y rescate tras un desastre natural. El proyecto que se ha desarrollado toma un enfoque más humano, aplicando las diferentes estrategias a la búsqueda de supervivientes y prestación de ayuda tras accidentes, donde el tiempo juega un papel fundamental, pero se decide no tenerlo en cuenta para el desarrollo de la solución.

La búsqueda de objetivos en espacios en los que hay incertidumbre hace referencia al procedimiento en el cual un agente realiza una búsqueda de un objetivo en un entorno o escenario donde la información no es exacta y puede estar sujeta a cambios. En estos escenarios se puede no tener conocimiento sobre la posición real del objetivo, pudiendo este moverse durante el proceso de buscarlo, lo que supone tener que desarrollar un sistema que simule el movimiento de este para actualizar las acciones del agente en tiempo real. También se puede desconocer el entorno; el agente puede no conocer la posición en la que se encuentra y los elementos que hay en el escenario pueden ser inciertos o desconocidos.

Estos problemas se basan principalmente en un modelo probabilístico que predice dónde puede encontrarse el objetivo a partir de un primer indicio y, en algunos casos, actualizar esta ubicación en función de los datos que se obtienen durante su ejecución, en nuestro caso, el sensor que tiene el dron acoplado.

1.2. Objetivos

Este trabajo tiene como objetivo llevar a cabo un estudio del rendimiento de un sistema planificador de trayectorias de búsqueda en un entorno donde encontramos incertidumbre. Las pruebas se realizan en un entorno hiperrealista simulado, por lo que otro de los objetivos que se deben abordar es ver si la trayectoria que describe el dron en este entorno se corresponde con la planificada en nuestro sistema o, por el contrario, se encuentran errores o anomalías provenientes de esta simulación. Para saber si los resultados que se obtienen acerca del rendimiento son válidos, es necesario ver con antelación esa fidelidad entre simulación y planificación.

Para poder alcanzar este objetivo principal de evaluar el rendimiento del planificador de misiones de búsqueda mediante diferentes estrategias, se definen una serie de metas que se deben superar durante el desarrollo del proyecto:

1. **Meta 1:** definir una planificación detallada de la misión a realizar, es decir, obtener una trayectoria de referencia generada por el planificador utilizando el algoritmo que se desee y diseñar un archivo que incluya toda la información, y que sirva para el futura análisis.
2. **Meta 2:** desarrollar un sistema de transformación de coordendas, que nos permita transformar de un sistema a otro en cualquier momento y de la manera mas precisa posible, ya que un error puede variar en gran medida la trayectoria que define el dron durante el vuelo.
3. **Meta 3:** asegurar que el dron sea capaz de leer y ejecutar las misiones que se generan, por lo que sera diseñar un controlador de vuelo que pueda modificar el formato de la misión almacenada para que sea compatible con el sistema del dron, es decir el formato establecido en MAVLink.
4. **Meta 4:** por último se debe diseñar un sistema que permita obtener datos en tiempo real sobre el comportamiento del dron, la información del sensor acoplado y la simulación, y posteriormente almacenarla en diferentes archivos, ya que es importante para poder realizar el futuro análisis de la coherencia entre la planificación y la simulación

1.3. Entorno socio-económico

El trabajo se ha realizado completamente en un ordenador personal sin necesidad de comprar nada más, lo cual indica un bajo costo de realización, siendo el único problema la potencia de este debido a que debe ser capaz de ejecutar simulaciones en Unreal Engine de manera fluida. Los programas y librerías utilizados durante el proyecto no han supuesto costo alguno, pues eran todos gratuitos y en ocasiones de código abierto, haciendo más entendible lo que permiten realizar.

Los sistemas de simulación como el que se ha utilizado en este proyecto suponen un gran beneficio debido a que permiten a estudiantes, investigadores y pequeñas empresas realizar avances en tecnología sin la necesidad de invertir una gran cantidad de capital. Aun así, no nos aseguran que todas las pruebas que se realicen sean fieles al mundo real; se pueden obviar factores importantes, en este caso aquellos que tienen que ver con la meteorología o el entorno físico.

El reciente aumento de popularidad de los drones y el estudio de estrategias o metodologías que abordan el problema de búsquedas con incertidumbre puede suponer un gran avance en un gran número de áreas. Permiten realizar tareas difíciles y que pueden presentar un gran riesgo de manera automática y sin la necesidad de que personas se expongan a riesgos innecesarios, como pueden ser la extinción de incendios, rescate de personas en áreas catastróficas o entrega de material en zonas de acceso complicado.

Los drones también pueden ser utilizados con un fin poco ético como puede ser en conflictos bélicos; hemos visto en los últimos años, sobre todo en el conflicto entre Rusia y Ucrania, que se han utilizado drones en los campos de batalla aunque hasta ahora la gran mayoría son controlados de manera remota. El uso de estos algoritmos puede hacer que la tarea que hasta ahora era realizada por personas de forma remota se convierta en una tarea automática y más eficiente, lo que puede suponer un aumento del uso de drones para estos fines.

1.3.1. Presupuesto

A continuación se muestran los gastos del proyecto desarrollado, los cuales podemos dividir en diferentes grupos: gastos de software, gastos de hardware y gastos humanos. Los programas software utilizados en este proyecto no han supuesto ningún coste añadido, debido a que el uso de estos es gratuito, por lo cual se establece que el gasto ha sido cero en total.

Como se indica anteriormente, el ordenador utilizado debe ser potente ya que tiene que ser capaz de ejecutar varios sistemas a la vez, entre los que se encuentra una simulación hiperrealista. Como el ordenador no fue comprado por componentes, sino que se compró ya montado, el precio es de la computadora completa.

TABLA 1.1. PRESUPUESTO COMPONENTES HARDWARE

Detalles	Unidades	Precio	Subtotal
Equipo ensamblado	1	1275.85€	1275.85€
Logitech G413 SE	1	94.99 €	94.99 €
M720 Triathlon	1	79.99 €	79.99 €
QHD Dell Pro 27 Pro	1	278.78 €	278.78 €

De la tabla 1.1 obtenemos que el total gastado en hardware es 1729.61 €.

En cuanto al coste humano, suponemos un ingeniero informático con un salario por horas. Se realiza una estimación de las horas necesarias para el desarrollo, obteniendo un total de 500 horas, que si multiplicamos por el salario medio en España de un ingeniero informático a día de publicación de este proyecto, 13.59 €, obtenemos el coste total 1.2.

TABLA 1.2. COSTE HUMANITARIO

Detalles	Unidades	Precio	Subtotal
Ingeniero informático	500	13.59 €	6795 €

Sabiendo todo esto, se puede calcular el costo total del proyecto desarrollado, obteniendo el resultado que vemos en la siguiente tabla 1.3.

TABLA 1.3. PRESUPUESTO TOTAL DEL PROYECTO

Detalles	Subtotal
Coste software	0 €
Coste hardware	1729.61 €
Coste humano	6795 €
Total	8524.61 €

1.4. Marco regulador

El trabajo ha sido realizado en su totalidad con un ordenador personal, haciendo uso de software, simuladores y entornos especiales para el desarrollo de una simulación realista de un entorno real para volar drones. Al utilizar estas herramientas, estamos obligados a cumplir con las licencias indicadas.

Si las pruebas de este proyecto se realizasen con un dron fuera de la simulación se deberían tener en cuenta una serie de normativas de cada país respecto al vuelo de drones. En 2020, la Unión Europea estableció una nueva normativa para regular el uso de drones en los países miembros, basada en el Reglamento de Ejecución (UE) 2019/947 y el Reglamento Delegado (UE) 2019/945, estableciendo que los operadores de drones con sensor o

cuyo peso sea superior a 250 gramos deben estar registrados en la Agencia Estatal de Seguridad Aérea (AESA). Además, los drones deben estar correctamente identificados con un número de registro y, desde enero de 2024, deben disponer de identificación a distancia directa (DRI)

Otro factor importante que debemos tener en cuenta es el sensor acoplado al dron, el cual obtiene imágenes en tiempo real. La Ley Orgánica 3/2018 de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales, es una normativa que garantiza a los ciudadanos el derecho a la intimidad y la protección de sus datos.

1.5. Estructura

Este trabajo se divide en diferentes capítulos que permiten dar respuesta a los objetivos planteados:

1. **Introducción:** sirve de primera toma de contacto con el tema que se va a desarrollar, mostrando una pequeña introducción a este además de los objetivos principales y el motivo de haber decidido realizar el trabajo.
2. **Estado del arte:** en este capítulo se realiza una revisión de otros trabajos relacionados con el problema de búsqueda espacios con incertidumbre, mostrando algunos de los avances que se han realizado en este campo.
3. **Formulación del problema:** donde se explica el problema definiendo sus características y la implementación de ciertos aspectos adicionales.
4. **Propuesta:** en este capítulo se expone lo que se se desarrolla en el proyecto, la metodología utilizada y el por que se utilizan.
5. **Experimentación:** se muestra la estructura el procedimiento seguido a la hora de realizar pruebas, analizando los resultados que se obtienen en los escenarios descritos.
6. **Conclusiones:** finalmente se plantean las conclusiones, explicando qué objetivos se han completado además de algunas posibles líneas de investigación para futuros trabajos en este campo.

2. ESTADO DEL ARTE

El problema de estrategias de búsqueda y la toma de decisiones en entornos con incertidumbre son temas que surgen para tratar de resolver problemas donde no se sabe a ciencia cierta el estado del entorno, que puede estar sujeto a cambios comunes. Las primeras apariciones de estas preguntas se remontan a los primeros intentos de resolver desafíos en partidas de ajedrez o en la resolución de laberintos de manera autónoma, incitando así al desarrollo de modelos que permitan resolver estos problemas.

Uno de los primeros enfoques de este tema se lo podemos atribuir a Richard Bellman [1], quien introduce al mundo la programación dinámica. Aborda el problema de un entorno en el que el agente debe tomar una serie de decisiones, donde cada una de estas decisiones afecta el estado del sistema, haciendo que lo importante no sea decidir la mejor acción siguiente, sino pensar a futuro viendo el conjunto de acciones óptimas.

Para ello, Bellman introdujo la idea del principio de optimalidad, el cual establece que, una vez se llega a un estado concreto, las decisiones que se tomen en el futuro deben ser las más óptimas, sin importar el pasado, es decir, cómo se ha llegado a ese estado. A partir de esta idea, se desarrolla la ecuación de Bellman 2.1, la cual nos da una visión matemática de este principio.

$$V(s) = \max_a \left(R(s, a) + \gamma \sum_{s'} P(s, a, s') V(s') \right) \quad (2.1)$$

Donde $V(s)$ es el valor del estado, $R(s, a)$ es el coste de realizar la acción a en el estado s , $P(s, a, s')$ es la probabilidad de ir al estado s' y γ es el factor de descuento.

A la par que Bellman desarrolla su trabajo, comienzan a surgir una serie de algoritmos que intentan dar una solución a problemas de búsqueda. Al igual que la programación dinámica, estos algoritmos tratan de dar una solución a aquellos escenarios donde hay que recorrer todos los estados para encontrar las decisiones más óptimas e introducen el término heurística, que hace referencia a una función que evalúa el coste restante hasta alcanzar el objetivo desde el estado actual, basado en ciertas características o por conocimiento previo.

Uno de los principales algoritmos es A* que surge como una mejora de Dijkstra, el cual une dos ideas importantes como son el coste real acumulado hasta un nodo y una nueva estimación del coste hasta el objetivo, eliminando de esta manera el problema de tener que recorrer estados innecesarios [2].

Aunque estos algoritmos son aceptados para diferentes problemas de búsqueda, en nuestro caso no son de mucha ayuda debido a que estos conocen de antemano la posición del objetivo y simplemente comprueban el camino con menor costo hasta éste. Esto lleva a que años más adelante se desarrollen nuevos modelos que muestran mejoras notables a la

hora de tomar decisiones en entornos con incertidumbre. Estos mismos problemas que se intentan resolver mediante programación dinámica o utilizando heurísticas, se comienzan a probar mediante modelos de decisión de Markov.

Los modelos de decisión de Markov (MDP) obtienen su nombre de Anréi Márkov debido a que son una extensión de las cadenas de Markov, proceso estocástico el cual presenta un grupo de estados en los que la probabilidad de pasar a un nodo s' , depende únicamente del estado actual s , sin un agente que tome decisiones sobre la marcha, por lo que la ejecución del sistema es completamente automática.

Los MDP, a diferencia de las cadenas, agregan un agente el cual no solo se centra en observar el entorno, sino que es capaz de tomar decisiones buscando obtener la mayor recompensa durante la ejecución. Esta recompensa es uno de los nuevos factores que se agrega expresado como $R(s, a)$ e informa al sistema de qué tan acertada ha sido la acción realizada [3]. Vemos entonces un comportamiento muy similar al de la programación dinámica y es que esta es la que resuelve el problema y los modelos de Markov son el marco que lo modela.

Para llevar estos modelos a problemas realistas donde el agente no es capaz de observar de manera completa todo el entorno y cómo evoluciona el sistema de decisión, se plantea una evolución de los MDP conocidos como modelos de decisión de Markov parcialmente observables (POMDP). Estos permiten modelar escenarios en los que podemos incluir robots que tengan sensores y, mientras realizan la búsqueda, puedan tomar decisiones en función de lo que ven a través de las cámaras, aun sin saber su posición real, y no como en el caso de MDP, que el agente sabe en todo momento el estado del entorno [4].

La duda que nos surge a continuación es cómo el agente es capaz de conocer en todo momento el estado del escenario y qué acción es la mejor en el siguiente paso. Mediante el uso de la inferencia bayesiana se puede dar una explicación clara a esta duda que nos surge. Se trata de un tipo de método probabilístico que, a partir de observaciones realizadas del entorno, permite actualizar el conocimiento que se tiene sobre el escenario en el que se realiza la búsqueda. Este proceso parte de una predicción previa que se conoce y, a medida que el agente obtiene información, realiza nuevos ajustes al mapa de probabilidades anterior para así realizar una búsqueda más eficiente y óptima.

Las probabilidades se calculan mediante el teorema de Bayes [5], formulado en 1763, el cual permite calcular la probabilidad de un nuevo estado A partiendo de una evidencia anterior B y combinándola con la probabilidad condicionada $P(B|A)$.

Un ejemplo conocido del uso de inferencias bayesianas en la búsqueda en un entorno con incertidumbre es en la localización del submarino USS Scorpion de los Estados Unidos, el cual no vuelve a enviar señales cerca de la base naval de Rota y se da como desaparecido. La búsqueda se inicia cerca de la zona donde comienza su viaje, por lo que este es el primer mapa de probabilidades que se obtiene. Posteriormente, tras escuchar una grabación hidroacústica, establecieron la zona de desaparición cerca de las islas

Azores, dado así un nuevo mapa de probabilidad, el cual fue bastante acertado ya que el submarino eclosionó a escasos kilómetros de la zona indicada.

Búsquedas como las que se mencionan donde el tiempo juega un papel fundamental hacen que no sea suficiente con tener una estrategia capaz de encontrar el objetivo, siendo necesario también reducir al máximo el tiempo que le toma al agente llegar al estado final. Es aquí donde toman protagonismo los algoritmos en tiempo mínimo, que al combinarse con los modelos probabilísticos explicados, dan lugar a soluciones bastante robustas para problemas de búsqueda.

En el estudio desarrollado por Pablo Lanillos [6], se combinan filtros bayesianos para la estimación del objetivo junto con procesos de decisión de Markov parcialmente observables (POMDP) para la toma de decisiones más óptimas y se aplican en diferentes casos que varían la naturaleza del espacio de búsqueda. De esta manera, demuestra que es posible desarrollar estrategias de búsqueda que minimizan el tiempo y aumentan la probabilidad de acierto si se combinan de manera correcta los modelos de probabilidad bayesiana y una planificación continua.

Sara Pérez Carabaza parte del trabajo anterior y, en lugar de utilizar procesos de decisión de Markov, propone el uso de un algoritmo de optimización de colonia de hormigas (ACO) el cual se basa en la colaboración de los agentes para hallar una solución óptima [7]. A partir de este estudio y con el objetivo de gestionar los múltiples agentes de manera más robusta, propone una mejora al hacer que los agentes eviten colisiones entre ellos y con los obstáculos del entorno, aunque manteniendo la misma metodología [8].

En este trabajo se opta por seguir un enfoque centrado en la estimación de la posición del objetivo mediante la utilización de modelos bayesianos y una dinámica en la que se aplican modelos de Markov, dejando a un lado la minimización del tiempo estimado y centrándose en la detección del objetivo.

3. FORMULACIÓN DEL PROBLEMA DE BÚSQUEDA

Para el problema de búsqueda en espacios con incertidumbre que se plantea en este trabajo, se considera un conjunto de U UAVs que sobrevuelan un área de búsqueda Ω , discretizada en una cuadrícula G_Ω de celdas cuadradas de dimensiones $w_x \cdot w_y$, con el objetivo de detectar la presencia de un único objetivo ubicado dentro de ella. La resolución de la cuadrícula determina el nivel de detalle en la representación de la posición del objetivo.

Debido a la incertidumbre asociada con la posición y la dinámica del objetivo, así como con las mediciones del sensor a bordo de cada UAV, el problema de búsqueda se formula dentro del marco probabilístico introducido en [9].

3.1. Modelo Probabilístico de la Posición Inicial del Objetivo

El *mapa de probabilidades del objetivo*, denotado como $b(v^k) = P(v^k)$, contiene toda la información disponible sobre la ubicación del objetivo en el paso k . Este mapa asigna a cada posición dentro del área de búsqueda Ω una probabilidad que refleja la creencia de que el objetivo se encuentra en esa ubicación. El mapa inicial de creencias $P(v^k = 0)$ es la inicialización del sistema. Se asume como hipótesis que el objetivo se encuentra dentro de Ω y que el mapa de creencias cumple que $\sum_{v_0 \in G_\Omega} P(v_0) = 1$.

La posición del objetivo paso k se representa como una variable aleatoria v_k . Esta variable indica que la posición del objetivo no es fija ni conocida con certeza, sino que está distribuida probabilísticamente en el espacio de búsqueda Ω .

Para definir el mapa de probabilidad inicial $b(v_0) \equiv P(v_0)$, se discretiza uniformemente el área de búsqueda rectangular Ω , quedando ésta dividida en una red G_Ω de $w_x \cdot w_y$ celdas. Una vez discretizada Ω , se asigna a cada celda del mapa una probabilidad de que el objetivo se encuentre en ella. Además, se asume que el objetivo se encuentra dentro de Ω , por lo que:

$$\sum_{v_0 \in G_\Omega} b(v_0) = 1. \quad (3.1)$$

3.2. Dinámica del UAV

Los UAVs realizan movimientos de decisión en pasos discretos k . El modelo determinista de la dinámica de los UAVs está definido por (3.2):

$$s_u^{k+1} = f(s_u^k, c_u^k), \quad (3.2)$$

donde s_u^{k+1} es la posición del UAV u en el paso $k + 1$, s_u^k representa la posición previa del UAV u en el paso k , y c_u^k es la acción de control aplicada en ese instante.

El uso de modelos dinámicos de UAV permite a los algoritmos de búsqueda probabilística (*PS*, *Probabilistic Search*) definir las trayectorias de los UAVs ya sea mediante las posiciones $s_{1:U}^{0:k}$ de los UAVs, o mediante las posiciones iniciales $s_{1:U}^0$ de los UAVs y la secuencia de acciones de control $c_{1:U}^{1:k}$. Esto habilita tomar como variables de decisión las trayectorias de búsqueda o las secuencias de acciones de control, aprovechando la posibilidad de obtener indirectamente trayectorias que cumplen con las restricciones dinámicas implícitas en (3.2).

3.3. Modelo del objetivo:

La información disponible sobre la dinámica del objetivo se modela mediante el modelo dinámico del objetivo $P(v^k | v^{k-1})$, que describe la probabilidad de que el objetivo se desplace de una celda v^{k-1} a otra v^k en un solo paso. Este modelo permite actualizar el mapa de probabilidad utilizando la información dinámica del objetivo modelada por $P(v^k | v^{k-1})$. Por ejemplo, esta información puede derivarse de las corrientes marinas en el caso de un objetivo perdido en el mar o de los posibles movimientos de un vehículo en una red vial.

Esta dinámica puede modelarse mediante un modelo Markoviano [10], o modelos de difusión [11]-[13]. En el caso de una misión de búsqueda con múltiples objetivos, el algoritmo de objetivo único puede utilizarse para múltiples objetivos homogéneos utilizando como creencia inicial la probabilidad conjunta de todos ellos y realizando la búsqueda hasta encontrar todos los objetivos.

3.4. Modelo de Sensor

Considerando que la posición del sensor coincide con la posición del UAV, el modelo del sensor se describe mediante la función de verosimilitud $P(z_k^u | v^k, s_u^k)$, que representa la probabilidad de obtener una medición z_k^u dada la posición del objetivo v^k y la ubicación del UAV u en el momento k , s_u^k . Este modelo permite actualizar el mapa de probabilidad con la información proporcionada por las nuevas mediciones del sensor.

Para el nuestro problema, se consideran dos posibles resultados de medición del sensor: detección del objetivo ($z_k^u = D$) o no detectar ($z_k^u = \bar{D}$) un objetivo ubicado en v^k , dado el estado del UAV u y la orientación del sensor s_u^k . Estas probabilidades son complementarias, donde uno ocurre si y solo si el otro no, por lo que la probabilidad de que se detecte viene definida por (3.3):

$$P(z_u^k = D|v^k, s_u^k) = 1 - P(z_u^k = \bar{D}|v^k, s_u^k) \quad (3.3)$$

Este enfoque probabilístico permite incorporar las observaciones del sensor de manera sistemática en la actualización del mapa de probabilidad, maximizando la eficacia de la búsqueda.

En el estudio de Pérez-Carabaza [14], se propone un nuevo concepto como es la huella del sensor y es que si el sensor que utilizamos es una cámara, esta proyectará una huella sobre la zona a la que está apuntando $huella(s_u^k)$. Se define $|v^k|$ como el área de la celda en la que se encuentra el dron, $|v^k \cap huella(s_u^k)|$ el área de la zona que tienen en común la celda y la huella que proyecta el sensor, y $P_{\text{cámara}}$ como la probabilidad de detectar el objetivo. Si a esto le unimos que la huella se obtiene a partir de la posición del UAV descrita por (x_u^k, y_u^k, z_u^k) , la altitud h_u^k , el ángulo de elevación de la cámara γ y el azimut de la cámara α , o también conocido como el ángulo formado entre el eje norte y el punto observado, se obtiene un modelo del sensor descrito por (3.4):

$$P(z_u^k = D|v^k, s_u^k) = \frac{|v^k \cap huella(s_u^k)|}{|v^k|} P_{\text{cámara}} \quad (3.4)$$

3.5. Fusión de Información

Para integrar las fuentes de información de las que disponemos procedentes de indicios, sensores y el comportamiento de los objetivos, se sigue una metodología similar a la utilizada por Pablo Lanillos en su estudio [15] utilizando un sistema que es capaz de fusionar toda esta información. Hablamos de un filtro recursivo bayesiano, que permite estimar el estado del objetivo en un paso k de la ejecución $b(\tau^k)$, mediante el conocimiento en el paso anterior $b(\tau^{k-1})$, las observaciones a través de sensores $z_{1:U}^k$ y los modelos de transición y medición.

El cálculo de estas estimaciones se comienza con la creencia inicial, la que se tiene antes de observar el entorno y se compone de dos pasos esenciales. El primer paso a realizar, conocido como el de predicción, permite obtener una probabilidad acerca de la posición del objetivo $P(\tau^k|z_u^{k-1}, s_u^k, \epsilon)$ únicamente utilizando el conocimiento que se tenía en el paso anterior y el modelo del objetivo que se menciona en este documento. El cálculo se lleva a cabo mediante la siguiente ecuación (3.5):

$$P(v^k|z_u^{k-1}, s_u^k) = \sum_{v^{k-1} \in \Omega} P(v^k|v^{k-1})b(v^{k-1}) \quad (3.5)$$

Donde $P(v^k|v^{k-1})$ es la probabilidad condicionada del modelo del objetivo.

El segundo paso en cada iteración es el de actualización, donde entran en juego las observaciones realizadas por el agente a través de los sensores. En este proceso se calcula

la creencia de un objetivo en un momento k , teniendo la información suministrada por el sensor y la probabilidad que se obtiene en el paso de predicción anterior. Este cálculo viene definido por (3.6):

$$b(v^k) = \xi^{-1} \prod_{i=1:u} P(z_i^k | v^k, s_i^k) P(v^k | z_u^{k-1}, s_u^k) \quad (3.6)$$

Donde ξ normaliza el resultado para que la probabilidad no sea mayor que uno.

A continuación se muestra la estructura principal de este algoritmo y los pasos que se deben seguir en cada una de las iteraciones, diferenciando entre el paso de predicción y el de actualización.

Algorithm 1 Filtro recursivo bayesiano

Require: $s_{1:u}^k$	▷ Posición del UAV
Require: $z_{1:u}^k$	▷ Medición del sensor
Require: $b(v^{k-1})$	▷ Creencia del paso anterior
Require: $P(z_u^k v^k, s_u^k)$	▷ Modelo del sensor
Require: $P(v^k v^{k-1})$	▷ Modelo del objetivo

1: $P(v^k z_u^{k-1}, s_u^k) = \sum_{v^k=1 \in \Omega} P(v^k v^{k-1}) b(v^{k-1})$	▷ Predicción
2: $b(v^k) = \xi^{-1} \prod_{i=1:u} P(z_i^k v^k, s_i^k) P(v^k z_u^{k-1}, s_u^k)$	▷ Actualización

3.6. Notación

A continuación, se presenta la notación utilizada a lo largo del trabajo, ordenada por orden de aparición:

- Ω : Área de búsqueda.
- G_Ω : Conjunto de celdas que representan la cuadrícula (malla) del área de búsqueda Ω .
- $w_x \cdot w_y$: Dimensiones de la malla G_Ω .
- U : Número de UAVs que participan en la búsqueda.
- v^k : Posición del objetivo en un paso k , modelada como una variable aleatoria.
- $b(v^k) = P(v^k)$: Mapa de probabilidad que describe la creencia sobre la ubicación del objetivo en un paso k .
- $b(v_0)$: Probabilidad inicial del objetivo en cada celda, combinando diferentes fuentes de información.

- $b_j(v_0)$: Capa de probabilidad de la fuente de información j .
- w_j : Peso asignado a la fuente de información j según su fiabilidad.
- $P(v^k|v^{k-1})$: Modelo dinámico del objetivo, que describe la probabilidad de transición del objetivo de v^{k-1} a v^k .
- $P(z_k^u|v^k, s_u^k)$: Modelo del sensor, que describe la probabilidad de obtener una medición z_k^u dada la posición del objetivo v^k y la ubicación del UAV s_u^k .
- z_k^u : Medición del sensor a bordo del UAV u en el paso k , con valores $z_k^u = D$ (detección) o $z_k^u = \bar{D}$ (no detección).
- $huella(s_k^u)$: Área observable por el sensor desde la posición s_k^u del UAV.
- $P_{\text{cámara}}$: Probabilidad base de detección del sensor a bordo del UAV.
- s_u^k : Posición del UAV u en un paso k .
- c_u^k : Acción de control aplicada al UAV u en el paso k , que determina su dirección de movimiento.
- $c_u^k \in \{N, NE, E, SE, S, SW, W, NW\}$: Conjunto de direcciones cardinales y diagonales que el UAV puede tomar como acciones de control.
- $b(v^k)$: Creencia predicha sobre la ubicación del objetivo en el paso k .
- ξ : Factor de normalización que asegura que $\sum_{v^k \in G_\Omega} b(v^k) = 1$.
- P_{kernel} : Kernel bidimensional que representa las probabilidades de transición hacia celdas vecinas.
- γ : Ángulo de elevación de la cámara del sensor.
- α : Ángulo de azimut de la cámara del sensor.
- h_u^t : Altitud del UAV u en el instante t .

4. PROPUESTA

El trabajo tiene como objetivo analizar el comportamiento de distintos algoritmos de planificación en un entorno con incertidumbre simulado mediante la utilización de un dron, pero antes de poder analizar esto, se realiza una comparación entre la trayectoria definida por el planificador y la que realmente ejecuta el dron en la simulación, evaluando el error y la desviación con respecto al plan original. Se utilizan distintos sistemas para el simulador como AirSim, MAVSDK o QGroundControl, entre otros, junto con sistemas de obtención de datos para el posterior análisis.

Además, al dron se le incorpora un sensor que permite obtener información visual del entorno y así poder obtener conclusiones acerca de cuán operativo es el planificador en entornos cercanos a la realidad.




Fig. 4.1. Estructura del Sistema

En la figura 4.1 se muestra la estructura del sistema y sus componentes principales, detallando cómo se conectan entre sí y cuál es su flujo de trabajo desde que se inicia la planificación de la misión hasta que se termina de ejecutar esta misma. A continuación, se proporciona una explicación detallada de cada uno de los componentes, indicando cuál es su función dentro de este sistema, facilitando la comprensión de cómo interactúan los módulos para cumplir con el objetivo.

4.1. Software In The Loop (SITL)

En este trabajo se emplea una simulación hiperrealista en *software in the loop* (SITL), que hace referencia a técnicas que permiten la simulación de, en nuestro caso, escenarios en los que podemos realizar vuelos con drones aplicando los algoritmos que se analizan. Estas herramientas facilitan el trabajo y reducen en gran medida el costo del proyecto, ofreciendo al usuario un entorno en el que puede realizar un elevado número de pruebas,

repitiendo si es necesario un escenario concreto y en un tiempo menor gracias a que el tiempo dentro de la simulación puede acelerarse [16]. En la siguiente imagen se observa un UAV llevando a cabo una misión en el simulador desarrollado 4.2.



Fig. 4.2. Ejecución de misión en Airsim con Cesium

AirSim [17] es una plataforma de simulación de código abierto orientada al campo de la inteligencia artificial que permite simular el comportamiento de drones y vehículos de manera realista, basándose en la gravedad, la densidad del aire y el campo magnético. Ofrece la posibilidad de incorporar distintos sensores al dron, obteniendo una gran variedad de datos sobre el estado de este [18]. Su uso está disponible en Unreal Engine y en Unity.

Complementario a AirSim encontramos PX4, un firmware de código abierto que se emplea en los controladores de Pixhawk [19] como sistema de control de vehículos no tripulados. Además, conforma un ecosistema que se sustenta por una comunidad muy amplia y activa, por lo que está en continua mejora.

Como estación de tierra o de control se utiliza QGroundControl [20] (QGC), herramienta desarrollada por los mismos desarrolladores que PX4 que emplea protocolos de comunicación MAVLink. Permite la planificación de misiones para vehículos de manera manual mediante archivos de plan o la agregación de puntos de paso (*waypoints*) en la propia interfaz. También permite llevar un seguimiento de los vehículos a través del mapa integrado en la interfaz y se puede obtener un archivo con la telemetría del dron durante la misión. A pesar de esto, esta herramienta solo se usa para la visualización debido a que es necesario definir la misión manualmente y en este proyecto lo que se busca es que todo esté automatizado [21].

La comunicación entre los diferentes elementos del ecosistema se realiza mediante el protocolo MAVLink [22], el cual es un protocolo de comunicación muy ligero y se

basa en el patrón de publicación-suscripción. MAVSDK [23] es una API (*application programming interface*) compuesta de un conjunto de bibliotecas que facilitan el uso de MAVLink y, además, permite generar misiones automatizadas sin necesidad de crearlas manualmente, necesario para generar misiones a partir de un sistema de planificación.

4.2. Planificación de la misión

Antes de iniciar la misión, se debe tener el escenario y la estrategia bien definidos, es por esto que se ha desarrollado un paquete en el que encontramos un planificador para cada algoritmo de búsqueda. Estos planificadores, además de proporcionar la trayectoria que debe definir el dron, nos proporcionan también información sobre el entorno, como la posición en la que se debe encontrar el marcador en cada escenario generado.

Aunque tener un planificador propio puede facilitar tareas previas a la ejecución de la misión, es posible realizar toda la planificación directamente en QGroundControl. Este programa, que funciona como una estación de tierra, destaca por su interfaz sencilla y su potencia, permitiendo generar archivos de misión de forma manual y automática, los cuales puedes enviarse directamente al dron para que éste ejecute las acciones descritas.

4.2.1. Algoritmos de búsqueda

Para la generación de estrategias se utilizan cuatro algoritmos diferentes que son variaciones de algoritmos más conocidos como: búsqueda por fuerza bruta y búsqueda en profundidad acotada.

Como no se dispone de una manera de nombrar a los algoritmos que se muestran a continuación de modo que permita diferenciarlos de una manera más sencilla, se opta por dar un nombre a cada uno de estos que se utiliza durante todo el documento para que se pueda comprender de manera más simple y facilite la lectura. En la siguiente tabla 4.1 se expone la nomenclatura asignada a cada algoritmo, así como el tipo de búsqueda que realizan, pudiendo ser local si se centra en una sola zona del espacio o global si realiza un barrido por todo el escenario.

TABLA 4.1. NOMENCLATURA DE LOS ALGORITMOS DE BÚSQUEDA UTILIZADOS

NOMBRE	TIPO	DESCRIPCIÓN CORTA
Bf-lawnmower	Global	Barrido similar al que describe un corta césped
Bf-expanding	Global	Barrido en expansión en forma de cuadrado
Ldfs-heur	Local	Búsqueda en la que se realiza corrección miópica
Ldfs-miope	Local	Búsqueda con miopía, no ve mas allá del siguiente estado.

El primer algoritmo es BF-Lawnmower o brute force lawnmower, variación del algo-

ritmo de fuerza bruta, el cual realiza un barrido en la zona de búsqueda describiendo un patrón similar al que forma un cortacésped, evitando la repetición de coordenadas. La trayectoria que genera este algoritmo no se ve influida por la posición en la que se encuentra el marcador en el área de búsqueda, sino que los parámetros que varían su comportamiento son la distancia entre cada zona de barrido, haciendo que se expanda de una manera u otra a lo largo de la coordenada norte.




Fig. 4.3. Algoritmo BF-Lawnmower

El siguiente algoritmo también está basado en el de fuerza bruta, BF-Expanding o brute force expanding, el cual genera una trayectoria que describe cuadrados en todo el plano. El comportamiento es sencillo, en primer lugar viaja hasta el centro de la zona de búsqueda y a partir de ahí se va expandiendo, describiendo cuadrados que tienen el tamaño que nosotros le indiquemos, evitando la repetición de puntos. Este tamaño se obtiene modificando el mismo parámetro de distancia entre zonas de búsqueda que también se utiliza en el algoritmo anteriormente expuesto.




Fig. 4.4. Algoritmo BF-Expanding

Los siguientes dos algoritmos se caracterizan por ser una variante de la búsqueda voraz en los que cada decisión que se toma depende de qué tan prometedor sea ese nuevo nodo según la heurística que utilicemos, y es que la única diferencia entre ambos es el tipo de heurística que se calcula.

El primero de ellos es Ldfs-Miope o limited depth-first search miope, el cual es un tipo de búsqueda que utiliza una heurística conocida como miópica, es decir, el algoritmo toma decisiones teniendo en cuenta el estado actual sin dar importancia a cómo van a afectar sus decisiones al futuro. Este tipo de heurísticas puede dar lugar a problemas durante su ejecución, como quedar atrapada en un bucle si se encuentra en una zona poco informativa y dejar de lado rutas potencialmente mejores por no ser capaz de ver más allá [24].




Fig. 4.5. Algoritmo Ldfs-Miope

Por último, encontramos el segundo algoritmo que utiliza heurísticas para generar trayectorias y, en este caso, vemos un enfoque no miópico, el cual no toma decisiones según el resultado del nodo inmediato, sino que evalúa el resultado de la acción tomada y lo acumula para el horizonte de búsqueda que se elija. Esto se hace mediante la aplicación de rollouts, término que hace referencia a una técnica que permite predecir las consecuencias futuras de la toma de una decisión. Con respecto al algoritmo anterior, este es mucho más robusto y suele encontrar el objetivo si el horizonte de búsqueda lo permite, evitando bucles y visitas a nodos innecesarios.




Fig. 4.6. Algoritmo Ldfs-Heur

4.2.2. Plan de misión

Una vez se obtiene la trayectoria que define el dron, se debe almacenar para que pueda leerse por el programa que ejecuta la misión. La estructura definida para su almacenamiento es un archivo plan propio de QGC, el cual puede cargarse directamente en este programa para la ejecución. En este archivo se debe definir el área de búsqueda acotada, los puntos por los que debe pasar e información relevante sobre el vehículo.

El sistema de coordenadas que utiliza QGC no es el mismo que el de las coordenadas que obtenemos del planificador de misiones, por lo que es necesario hacer una transformación entre estas para que, aunque la misión no se vaya a ejecutar en QGC, tenga el formato adecuado.

4.3. Sistemas de Referencia y Transformaciones

Por sistema de referencia, nos referimos a componentes que permiten describir posición, orientación y el estado del entorno que rodea a un vehículo en todo momento. Estos sistemas tienen un origen de posición y de orientación a partir de los cuales se expresan las distintas magnitudes espaciales, lo cual es esencial para no terminar cometiendo errores a la hora de medir posición y movimiento, debido a que un punto puede estar representado de distinta manera dependiendo de qué sistema de referencia se observe.

Cada uno de estos sistemas tiene sus propias magnitudes espaciales ya definidas como posición, orientación, velocidad o aceleración, expresadas en función de su propia manera de medir, usando un sistema de coordenadas propio. Por esto es que podemos encontrar que una misma posición en el espacio de búsqueda puede tener una representación diferente dependiendo del sistema que estemos consultando, lo que hace necesario especificar el componente asociado a cada dato.

En este trabajo utilizamos tres sistemas de referencia diferentes que nos ayudan a conocer el estado del vehículo en todo momento y la posibilidad de realizar un análisis más exacto de cada una de las misiones ejecutadas.

El primero que utilizamos es el sistema de telemetría del propio dron, administrado por la librería MAVSDK. Este nos permite obtener información relativa a la posición, orientación, aceleración o estado del propio vehículo durante la ejecución de la misión. No todas las magnitudes que podemos obtener de este sistema nos interesan realmente; la posición y orientación nos son útiles para el análisis de trayectorias y el estado del vehículo para realizar comprobaciones en tiempo real. En cuanto al sistema de coordenadas utilizado, es WGS84, sistema global que expresa las coordenadas en latitud, longitud y altitud sobre el nivel del mar.

El siguiente sistema de referencia utilizado es Ground Truth, que hace alusión a los datos reales de la simulación administrados directamente por AirSim durante el vuelo del dron y que son utilizados como referencia para comparar estimaciones de otros sistemas, como puede ser el de telemetría. Los datos que obtenemos principalmente son la posición y orientación del dron, los cuales no tienen errores de sensores, convirtiéndolos así en una referencia perfecta. En este caso, las coordenadas de posición vienen en sistema de coordenadas tangente local, conocido como NED, que expresa las coordenadas en norte, este, abajo.

Por último, encontramos el sensor, que es una cámara que lleva el dron instalada en la parte de abajo y que nos muestra el dron y el entorno que lo rodea en todo momento durante la simulación. Esta cámara obtiene imágenes que va mostrando por pantalla y tiene un sistema detrás que permite detectar el objetivo en tiempo real, incorporando a la imagen información importante cuando éste ha sido detectado. Como vemos, la función principal de este sistema de referencia es la captura de imágenes con el principal objetivo de detectar el objetivo en el espacio de búsqueda. Cada una de las imágenes que obtiene el sensor es procesada por el sistema y, mediante la librería Aruco, podemos identificar si hay un marcador y si éste es el que estamos buscando, en el caso de que haya varios en el espacio de búsqueda, obteniendo a su vez información sobre su posición y orientación en el espacio.

Cuando hablamos de marcador Aruco, hacemos referencia a la representación de un ID mediante un patrón en blanco y negro similar a los códigos QR, que, además de permitir su identificación, se puede obtener información sobre la posición y orientación de este. Son muy usados en visión artificial debido a lo sencillo que es identificarlos. En la

siguiente figura 4.7 se muestra el marcador que se ha utilizado en este proyecto con ID igual a 65 y un tamaño de 5x5 unidades.




Fig. 4.7. Marcador Aruco utilizado en el proyecto

Todos estos componentes trabajan de manera asíncrona y coordinada para proporcionar un seguimiento completo de la simulación y del vehículo en todo momento, sin necesidad de que estos esperen por que otro sistema termine su ejecución o realice una función en específico. Todos los datos que se obtienen gracias a los sistemas que se mencionan son almacenados en diferentes archivos para poder realizar un análisis completo de las trayectorias y poder obtener una conclusión acerca del planificador.

Cada uno de los sistemas que se muestran describe las coordenadas de una manera diferente, lo cual puede complicar el análisis de los resultados posteriores si no se trata con cuidado cada una de las mediciones.

Desde la planificación de la misión hasta el análisis final de los algoritmos, se producen en múltiples ocasiones transformaciones entre distintos sistemas de coordenadas. Herramientas como AirSim o QGC se rigen por un sistema geodésico que permite localizar cualquier lugar de la Tierra con mucha precisión. En cambio, en la planificación de la misión y en el análisis final, con el fin de que sea más legible y sencillo de representar, se utiliza un sistema de coordenadas proyectado. La transformación entre sistemas se ha realizado siguiendo los principios descritos por John P. Snyder [25], que estableció técnicas de conversión utilizando proyecciones cartográficas.

El sistema de coordenadas global utilizado es World Geodetic System 84 (WGS84), el cual representa la Tierra como un elipsoide, el cual se define por los siguientes parámetros: R_e (semieje mayor), R_p (semieje menor), ε (primera excentricidad, que mide cuánto se desvía de una esfera perfecta) y ε' (segunda excentricidad). Los valores de estos parámetros son $R_{\max} = 6378137$ metros, $R_{\min} = 6356752,31$ metros, $\varepsilon = 0,0818191$ y $\varepsilon' = 0,08209441$, donde estos dos últimos se calculan siguiendo las siguientes ecuaciones

4.1 y 4.2.

$$\varepsilon = \sqrt{1 - \frac{b_f^2}{r_b^2}} \quad (4.1)$$

$$\varepsilon' = \sqrt{\frac{r_b^2}{b_f^2} - 1} \quad (4.2)$$

Este sistema de coordenadas nos permite describir cualquier punto de la Tierra mediante tres unidades: latitud, longitud y altitud.

La latitud se define como el ángulo que hay entre el plano ecuatorial y la línea que atraviesa el punto, siendo el ecuador la línea imaginaria que divide la Tierra en dos hemisferios, norte y sur. La unidad de medida son los grados, minutos y segundos, y puede oscilar entre 90° y -90° .

La longitud es el ángulo entre el meridiano de referencia y el meridiano que corta al punto, entendiendo como meridiano de referencia el que pasa por el observatorio de Greenwich, que divide la Tierra en dos hemisferios este y oeste. La unidad de medida son los grados, minutos y segundos, y puede variar entre 180° y -180° .

Por último, la altitud representa la distancia entre un punto y el nivel del mar en metros.




Fig. 4.8. Sistema de coordenadas WGS84 [26]

En el sistema utilizado para la representación de las trayectorias descritas por el dron, conocido como sistema de coordenadas tangente local, los puntos se representan en un plano que es tangente a la superficie de la Tierra. Este sistema tiene tres coordenadas, las cuales representan la distancia respecto al eje norte, la distancia respecto al eje este y la distancia vertical, todas ellas en metros.

Podemos encontrar dos variantes diferentes en este sistema diferenciando únicamente el orden en el que se representan las coordenadas: este, norte, arriba (ENU) y norte, este, abajo (NED). De estas dos variantes, la utilizada en este proyecto es el sistema ENU.

4.4. Controlador de vuelo

El controlador o módulo de coordinación es el principal componente del sistema desarrollado, encargado, entre otras cosas, de gestionar las comunicaciones entre los distintos componentes, garantizando su correcto funcionamiento y su sincronización en todo momento.

Se encarga de procesar el plan de misión generado en el planificador, gestionar su envío a la estación de tierra y asegurar que el dron recibe correctamente la información y comandos necesarios para el inicio de la misión. En el transcurso de esta, el controlador mantiene comunicadas las distintas herramientas en funcionamiento como QGC, AirSim o SITL; y obtiene datos relacionados con el estado del dron.

Otra de sus funciones es la de mantener una comunicación con el sensor del dron, obteniendo imágenes en tiempo real de la simulación, procesando estas para comprobar si se detecta el objetivo o no, evaluando el comportamiento del sistema de planificación en entornos realistas.

La importancia de este módulo es notable y es por esto que se describen en el trabajo sus elementos principales y las funciones que cumplen estos en el sistema.

4.4.1. MAVSDK

En primer lugar, explicamos qué es MAVSDK y por qué es importante en nuestro sistema. Se trata de una biblioteca o herramienta software que permite controlar drones de manera más simple, facilitando la comunicación entre el sistema y el dron, permitiendo automatizar tareas como despegue, ejecución de misiones o incluso toma de imágenes, sin necesidad de que el usuario esté pendiente en todo momento.

La comunicación entre el dron y el sistema se realiza mediante MAVLink. Este es un protocolo ligero y rápido que envía mensajes al dron en el lenguaje que éste entiende y nos permite obtener información clave en todo momento, como puede ser el estado del vehículo, la posición o el nivel de batería restante.

Por simplificar la tarea de envío de mensajes al dron es por lo que se utiliza MAVSDK junto con MAVLink, ya que en lugar de que el usuario escriba el mensaje directamente en lenguaje MAVLink y tenga que enviarlo manualmente, MAVSDK permite indicar el comando a realizar y es este el que lo traduce al lenguaje correspondiente y se encarga del envío al dron. Poniendo un ejemplo, imaginemos que un usuario quiere hacer que el dron se mueva a un punto específico del plano; este acudirá a la documentación detallada de MAVSDK en la que buscará cómo se escribe el comando y, posteriormente, esta herramienta genera el mensaje adecuado y lo envía al dron.

Pueden surgir preguntas como por qué no se utiliza directamente QGC para la planificación y ejecución de misiones en lugar de generar un sistema que utilice MAVSDK, y

es principalmente porque, como se explica en este documento, QGC, a pesar de realizar la comunicación de manera automática, la planificación es manual y el usuario debe estar pendiente de cargar archivos y pulsar el botón de enviar y ejecutar, mientras que el sistema genera y ejecuta de manera automática la misión simplemente pulsando un botón.

4.4.2. Envío de misión a dron

Al disponer de un planificador de misiones independiente del controlador de vuelo, se pueden generar misiones en cualquier momento sin iniciar todo el sistema y, una vez definidas y almacenadas en un archivo, se procesan y envían correctamente al dron.




Fig. 4.9. Flujo de envío de una misión

Como vemos en la figura 4.9, el controlador o componente principal de nuestro sistema obtiene la misión del archivo generado en el planificador y se la envía al dron, generando por el camino otro archivo de referencia que se usa en el análisis de resultados.

Este envío de la misión al dron se realiza mediante el protocolo MAVLink, el lenguaje que entiende el dron, lo cual se consigue mediante el uso de la biblioteca MAVSDK, una librería que nos permite generar misiones de manera sencilla. Estas misiones tienen una estructura ya establecida en la que se debe generar un elemento o ítem por cada punto de la trayectoria que el dron debe visitar e indicar en cada uno de estos información relevante, como puede ser la posición en coordenadas globales, la velocidad que debe llevar o si el sensor debe realizar alguna acción, entre otros. Una vez se tienen todos los puntos establecidos, se puede enviar o cargar la misión en el dron.

Para enviar la misión al dron no es necesario utilizar siempre el sistema que se ha desarrollado en este proyecto, la herramienta QGC permite planificar y realizar el envío de la misión al vehículo viendo en la interfaz de ésta la trayectoria que se define. El sistema que desarrollamos para la planificación de misiones genera un archivo en un formato legible por QGC, por lo que se puede cargar directamente en el programa para su ejecución.

5. EXPERIMENTACIÓN

El objetivo principal de este proyecto es analizar el rendimiento de distintas estrategias de búsqueda llevadas a un entorno en el que encontramos incertidumbre. Para conseguir llegar a ese fin, es necesario saber si disponemos de un grado de coherencia elevado entre el sistema planificador y la simulación, observando la similitud entre trayectorias y posibles anomalías o errores provenientes del simulador.

Sabiendo esto, en esta sección de experimentación, se evalúa el grado de coherencia entre la trayectoria generada por el planificador y la ejecución de la misma llevada a cabo mediante SITL, con el fin de saber si los resultados finales que se obtienen del rendimiento del planificador son adecuados o no.

Los diferentes escenarios que se diseñan para la reproducción de misiones nos ayudan a comparar la correspondencia entre la trayectoria planificada y el trazado final descrito por el dron, lo que permite en gran medida analizar el rendimiento del planificador y el grado de fiabilidad de este en escenarios donde aparece la incertidumbre como elemento destacado.

Mientras se estudia el rendimiento del planificador, el hecho de implementar distintos algoritmos de búsqueda con un comportamiento muy diferenciado nos ofrece la posibilidad de poder analizar el desempeño de cada uno de ellos en los distintos escenarios diseñados. Esta variedad de características y el análisis de comportamiento que se realiza, permite reconocer limitaciones y fortalezas, además de ver cuál de ellos es el que mejor adaptación tiene a cada uno de los escenarios.

Se plantean tres escenarios diferentes de dificultad incremental que añaden niveles de aleatoriedad a la misión. Estos escenarios pueden variar desde situaciones donde todos los elementos se tienen controlados hasta supuestos donde varía desde el indicio hasta el propio objetivo, lo que hace que cada uno de estos sea más aleatorio que el anterior. A continuación se explican en profundidad cada uno de los supuestos diseñados.




Fig. 5.1. Diferentes escenarios diseñados para la experimentación

En la figura 5.1 podemos observar los tres escenarios diferentes que se han decidido diseñar para la evaluación del objetivo. Cada uno de estos supuestos añade un grado

de aleatoriedad y variabilidad, cambiando, como vemos, la posición del objetivo o los indicios, con el objetivo de estudiar el rendimiento del planificador.

En el primer caso 5.1a nos encontramos en un escenario en el que tenemos todos los elementos controlados con la posición inicial del dron fija, así como la del indicio y el marcador durante todas las ejecuciones que se realizan. Esta configuración sirve como toma de contacto con el comportamiento del planificador y de los algoritmos de búsqueda en un entorno controlado donde las variaciones entre ejecuciones se deben a imprecisiones en el simulador.

El segundo escenario 5.1b añade un nivel de variabilidad donde el marcador cambia de posición dentro de un mismo indicio de manera aleatoria, mientras que la posición del dron inicial se mantiene constante. Este caso hace que podamos analizar la capacidad del planificador de encontrar el objetivo, comprobando además cuál de las estrategias elegidas es más eficaz.

Por último, en el tercer caso 5.1c nos encontramos con escenarios donde la posición del dron inicial no varía, pero los indicios y la posición del objetivo varían constantemente. Este es el supuesto que mayor aleatoriedad aporta de todos los mostrados, lo cual nos ayuda a comprobar la robustez y flexibilidad del planificador.

Para este proyecto se describen una serie de métricas cuantitativas que facilitan el análisis del rendimiento del planificador y de los algoritmos en los escenarios que se describen en el documento. Como ya sabemos, estas métricas nos van a ayudar con dos aspectos fundamentales: medir la correspondencia entre las trayectorias ejecutadas y las de referencia, y por otro lado, qué tan eficientes son los algoritmos y el planificador en cada escenario, midiendo aspectos de tiempo o distancia, así como el acierto a la hora de encontrar el objetivo.

Para la evaluación de la correspondencia entre trayectorias, acudimos a la raíz del error cuadrático medio (RMSE), la cual permite estimar de manera precisa la desviación entre los puntos de la trayectoria de referencia y la ejecutada por el dron. En este proyecto nos decantamos por este cálculo del error debido a que presenta una mayor penalización de errores grandes y que se encuentra en las mismas unidades que las trayectorias, a diferencia del error cuadrático medio (MSE) que nos proporciona un valor elevado al cuadrado. A partir de los valores obtenidos en el cálculo del error, se puede obtener una función de distribución acumulada (CDF) del error que nos muestra el modo en el que se distribuyen estos valores que hemos calculado y su frecuencia.

Para ayudar con el análisis de desviación de trayectorias se utiliza el cálculo de la distancia dinámica de tiempo (DTW), la cual nos ayuda a comparar trazados que tienen distinta distancia y duración, sin importar las variaciones de velocidad del dron durante la ejecución [27]. Este indicador proporciona una medida en la que la sincronización temporal no es tan relevante y da más importancia a la comparación de la forma de los trazados.

De los datos que se obtienen en el cálculo del DTW, se pueden calcular estadísticos descriptivos que ayuden a reforzar el análisis de esta métrica. Entre estos datos que se calculan encontramos la media, la mediana o el valor central del conjunto de datos; el mínimo y máximo del conjunto; la desviación estándar (STD) que mide la dispersión de los datos; y el rango intercuartílico, que indica el comportamiento del 50 % central de los datos, aquellos que se encuentran entre el cuartil 1 y el cuartil 3.

El cálculo de estas métricas nos ayuda a ver la fidelidad del entorno simulado con el sistema de planificación y a poder ver de manera más sencilla el comportamiento durante la ejecución y los valores anormales que puedan aparecer.

Para evaluar la eficiencia, disponemos del tiempo medio de detección del objetivo y la distancia que recorre de media. Estas dos métricas reflejan tanto si el algoritmo utilizado es especialmente rápido a la hora de realizar la búsqueda, como si la ruta que describe es realmente eficaz y tiene una mejor utilización del espacio. Para el escenario donde mayor aleatoriedad encontramos, se decide calcular también la tasa de acierto de cada uno de los algoritmos, dependiendo de si este localiza el objetivo en la misión o no.

5.1. Preparación de los escenarios

Es preciso, antes de iniciar cualquier tipo de experimento, definir el escenario en el que se va a llevar a cabo la misión de manera exacta y consistente, lo cual es fundamental si se desea tener todas las variables controladas y poder evaluar el planificador en entornos con incertidumbre. Esto, además, nos permite entender si los errores que se encuentran a lo largo de la ejecución se deben a problemas en el planificador inicial o a otros aspectos no definidos correctamente.

En primer lugar, es necesario establecer la posición inicial del dron, la ubicación de los indicios así como la posición exacta del objetivo. Esto es primordial, ya que constituye la base sobre la cual el planificador genera toda la trayectoria que seguirá nuestro dron y, al definir todo esto en el simulador de acuerdo a cómo nos lo genera el planificador, podemos obtener conclusiones acerca de la coherencia entre el planificador de misiones y el simulador o el entorno real.

Para ello, primero se debe definir la relación de escala que hay entre el escenario de nuestro planificador y Unreal Engine. Un metro de nuestro planificador equivale a cien unidades en el motor gráfico; además, la coordenada este equivale a la coordenada y en Unreal y la norte a la x. Entonces sabemos que si queremos posicionar un marcador en la posición (11, 14), debemos multiplicar por cien y cambiar el orden de las coordenadas, obteniendo lo siguiente (1400, 1100).

En cuanto a los sistemas de referencia, es necesario que estos tengan una sincronización bastante alta, siendo una marca temporal la que hace que todos estos se mantengan unidos y se puedan combinar las acciones u observaciones detectadas en cada uno de ellos. El no disponer de una sincronización entre los sistemas supone que no se pueda

realizar un análisis correcto de la coherencia, encontrando errores o desviaciones que no son reales, haciendo que no se puedan obtener conclusiones finales sobre qué factores producen los errores que se observan.

Una vez se tiene todo bien establecido, es momento de iniciar la misión y empezar con la obtención de datos.

5.2. Escenario 1

Este primer escenario está caracterizado por mostrar una única instancia del problema de búsqueda, con condiciones completamente determinadas. En este caso, el dron siempre despegue del mismo punto inicial, los indicios se encuentran en una ubicación invariable y el objetivo se mantiene siempre en la misma posición dentro de los indicios. El escenario se mantiene sin ninguna variación para todos los algoritmos de búsqueda aplicados.

Con este caso podemos tener una primera toma de contacto con los algoritmos de búsqueda y ver las diferencias en la manera en la que cada uno de estos interpreta y resuelve una instancia concreta del problema, analizando eficiencia y precisión, localizando el objetivo en un tiempo determinado. También nos es útil ya que, al ser el mismo caso siempre, nos podemos centrar más en la trayectoria de cada uno de los algoritmos de búsqueda, buscando cuál de ellos es más ineficiente o contiene patrones que no ayudan con el problema.

Como sabemos, antes de iniciar la ejecución del sistema para la búsqueda de objetivos, es necesario tener definido el escenario correctamente en el planificador y en el simulador. En este caso, tenemos un escenario de tamaño medio de 50 metros de alto por 50 metros de ancho, en el que tenemos un solo indicio en la posición 35 metros este, 28 metros norte, y un solo agente que va a realizar la búsqueda, el cual inicia la misión en el origen de coordenadas. En cuanto al tamaño total del horizonte de búsqueda, lo definimos en un total de 200 pasos con una separación entre cada uno de ellos de 4 metros, lo cual nos permitirá encontrar el objetivo que se encuentra en el punto, generado de manera aleatoria a partir de una semilla, 37 metros este, 25 metros norte. En la figura 5.2 se ve de manera gráfica el escenario que se ejecuta en este apartado y nos ayuda a visualizar en definitiva, cómo se estructura una misión y sus elementos más destacados.




Fig. 5.2. Escenario primera misión

Una vez se tiene bien estructurado todo, obtenemos del sistema planificador la trayectoria que debe realizar el dron y que podemos enviar directamente debido a que se encuentra en el formato adecuado. Esta misión, como sabemos, se puede cargar y ejecutar directamente en QGC o, como es el caso de este proyecto, se desarrolla un sistema de control de vuelo que se encargue de esto. En la siguiente figura 5.3 vemos la interfaz de QGC, donde se ha cargado la misión anteriormente descrita y en la que se aplica el algoritmo de búsqueda bf-lawnmower.




Fig. 5.3. Interfaz QGC donde se ha cargado una misión

Tras definir y enviar la misión al dron, entramos en la fase de monitorización del comportamiento del dron en tiempo real, donde vamos a registrar los datos de los distintos sistemas de referencia. La información que obtenemos se utiliza para llevar a cabo un análisis del transcurso de la misión, permitiendo observar la correspondencia entre planificación y simulación. Como ya sabemos, los sistemas de referencia que tenemos son: la telemetría del dron, que nos informa sobre la posición local y el estado del dron; el simulador AirSim, que proporciona información real sobre la posición dentro del entorno simulado; y los sensores instalados en el dron que nos ayudan a obtener datos sobre el marcador.

Los datos que obtenemos en la simulación, posibilitan el realizar una reproducción precisa de las distintas trayectorias definidas, de la cual podemos analizar el nivel de exactitud entre estas mismas y poder ver posibles anomalías que surgen durante la ejecución de la misión y que no se tienen en cuenta antes.

La mejor representación de estos datos es mediante la superposición de todas las trayectorias implicadas en una misma representación gráfica. A continuación se disponen distintas figuras en las que observamos representaciones de la misión definida en la que se han aplicado los distintos algoritmos de búsqueda para poder comprobar el grado de coincidencia entre la referencia y la simulación, y en qué casos encontramos errores o desviaciones. En todas ellas se representan las trayectorias del mismo modo: la trayectoria obtenida de la telemetría en color azul, la trayectoria definida a partir del ground truth en verde y la trayectoria de referencia en color naranja.




Fig. 5.4. Reproducción de trayectorias con algoritmo de fuerza bruta de corta césped primer escenario

Esta primera figura 5.4 representa el escenario descrito sobre el que se ha aplicado el algoritmo de fuerza bruta bf-lawnmower. A primera vista no se observan diferencias claras entre la referencia y el camino descrito por el dron en la ejecución, siguiendo el dron el recorrido previsto. Sin embargo, en las zonas donde se realiza el cambio de sentido, a la hora de girar el dron, encontramos unas pequeñas desviaciones que siguen un mismo patrón durante todo el vuelo. Esto se debe a que en la trayectoria planificada este giro es exactamente de 180° , el cual el dron en la simulación, si lleva una velocidad constante en todo momento, no puede realizar de manera exacta, y la rotación que éste ejecuta para realizar cambios de dirección puede afectar a la estabilidad y producir pequeñas desviaciones. En todo caso, podemos llegar a la conclusión de que, a simple vista, el dron realiza el camino deseado en todo momento.

A simple vista podemos destacar información relevante acerca del objetivo y si el dron es capaz de encontrarlo aplicando este algoritmo. Se observa en la figura que para este algoritmo, dónde esté el objetivo no es relevante ya que va a realizar un barrido siempre empezando cerca del origen y avanzando poco a poco hacia valores mayores de coordenada norte. Debido a la forma en la que realiza el barrido sobre el espacio de búsqueda, en este caso en concreto, si el objetivo se encuentra lo suficientemente alejado

hacia el norte, el dron va a tardar más en conseguir encontrar el marcador, e incluso si el horizonte que hemos definido de búsqueda es pequeño, puede que no llegue a encontrarlo nunca y vuelva al origen sin obtener un resultado satisfactorio. En consecuencia, el tiempo que puede tardar en detectar el objetivo es muy variable dependiendo de la distancia que este se encuentre de la zona de origen del dron. A pesar de esto, en situaciones donde el marcador no se encuentre cerca del indicio, este algoritmo sería capaz de detectarlo ya que el barrido que realiza no se ve afectado por la posición de los indicios, lo que puede hacer que sea más acertado que los que dependen de este factor como son los algoritmos en profundidad.

Para poder apreciar mejor el error entre los distintos trazados y así poder llevar a cabo un análisis más exhaustivo, gracias a los sistemas de referencia utilizados, podemos descomponer estas trayectorias por coordenadas y analizar cada una de ellas por separado. Al tener las rutas en el mismo sistema de coordenadas, se procede a analizar las coordenadas norte, este y altura por separado a lo largo del tiempo que dura la misión. El principal problema que encontramos es la trayectoria de referencia y es que esta, a diferencia de la telemetría o ground truth, no depende de la variable de tiempo, sino que está almacenada como una secuencia de pasos, es decir, cada registro es un paso del dron, lo que impide que se pueda analizar y comparar correctamente.

Para lograr el objetivo de llevar a cabo una comparación con sentido, se añade a la referencia la variable tiempo, tomando el tiempo total que el dron ha tardado en realizar el recorrido y posteriormente dividiéndolo entre el número total de puntos que hay en el trazado de referencia. Con esto lo que conseguimos es una trayectoria ideal en la que se supone que se tarda el mismo tiempo en recorrer todos los puntos, sin tener en cuenta la velocidad del dron o posibles frenazos. Aun así, esto nos sirve para poder visualizar las distintas coordenadas de ambos trazados y poder obtener un primer cálculo del error, aunque no sea realista.

Tras agregar el tiempo al recorrido planificado, para poder comparar conjuntos de datos de distinto tamaño, es necesario realizar una interpolación sobre el conjunto de referencia. Este proceso consiste en realizar estimaciones de posiciones entre los puntos conocidos, suponiendo que el movimiento que se describe entre estos es uniforme, pudiendo obtener así de una secuencia de datos discreta una trayectoria continua que depende de una marca temporal.

Una vez se tienen todos los datos en un formato correcto, se puede comenzar con la muestra de los trazados de ground truth y de referencia separados por coordenadas.




Fig. 5.5. Error por coordenadas entre referencia y gt en algoritmo de corta césped primer escenario

En la figura 5.5 se aprecia que ambos trazados son muy similares y no encontramos desviaciones muy pronunciadas, salvo en algunos puntos, como es el caso de los cambios de dirección, que ya se han mencionado en el documento. El hecho de haber realizado una interpolación puede dar lugar a anomalías, pero este no es el caso y los dos trazados se mantienen fieles a los originales, lo que permite un análisis adecuado.

Hasta ahora, el análisis y muestreo de datos se ha basado en una sola ejecución del escenario, cuyo principal objetivo es el de mostrar la misión, el comportamiento del algoritmo y los datos de la ejecución. No obstante, para el cálculo del error se opta por realizar un mayor número de repeticiones del mismo escenario con el objetivo de obtener un valor más acertado del rendimiento y, además, se utiliza como métrica principal la raíz del error cuadrático medio, cuyo resultado se muestra en la siguiente tabla.

TABLA 5.1. ERROR (RMSE) ALGORITMO BF-LAWNMOWER
PRIMER ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
0.168	0.965	0.018	0.383

Se observa en la tabla 5.1 que el mayor error lo encontramos en la coordenada norte, pudiéndose ver con claridad en la figura que representa el movimiento del dron 5.4, como cuando al finalizar los giros, el principal error está en que se desvía entre valores de esta coordenada. Además, aunque no se aprecie a simple vista, tras aplicar la interpolación puede parecer que los puntos se encuentran correctamente alineados, pero puede darse el caso de que un punto en la trayectoria de referencia se encuentre adelantado o retrasado

respecto a su homólogo en la trayectoria del dron, dando lugar a un pequeño desfase que puede dar valores en el error que no parezcan muy coherentes. A pesar de esto, el error no es muy elevado, por lo que no supone una gran preocupación.

Tras analizar los errores entre las dos trayectorias habiendo introducido tiempo en la de referencia, continuamos con una métrica que pretende analizar la forma de ambos trazados, a pesar de que puedan tener un tiempo de ejecución diferente, o incluso, en nuestro caso, no depender del tiempo. Se muestran a continuación los distintos resultados obtenidos en la aplicación de DTW para el algoritmo Bf-lawnmower que nos ayuda a ver qué tan fiel es el recorrido descrito por el dron respecto a la referencia, en cuanto a la forma de estos.




Fig. 5.6. Alineamiento de trayectorias utilizando DTW en Bf-lawnmower primer escenario

De la figura 5.6 que se muestra es posible obtener una gran cantidad de información que debe ser explicada para poder entender mejor qué es lo que se observa. En el título apreciamos un valor numérico que es la distancia media normalizada, que, como su nombre indica, es la distancia que encontramos de media entre las dos trayectorias estudiadas. El valor obtenido tras la aplicación de DTW es muy bajo, lo cual indica un mayor grado de coincidencia entre ambas trayectorias, siendo la desviación mínima. La diferencia entre ambos trazados se puede apreciar a simple vista, pero se ha añadido un trazo negro que une los pares de puntos de ambas trayectorias, indicando así la distancia que hay entre ambos.

A continuación se muestra un análisis estadístico para complementar este estudio del DTW aplicado en este escenario, mostrando dos diagramas, donde se observan la distribución de las distancias entre trayectorias y la frecuencia de éstas.




Fig. 5.7. Distribución y frecuencia de la distancia DTW en algoritmo Bf-lawnmower primer escenario

Las dos representaciones de datos pueden parecer muy similares, pero muestran datos un tanto diferentes. A la izquierda observamos un diagrama de violín el cual se centra en mostrar la distribución de las distancias de manera que aporte una visualización de la forma general y la dispersión de estos, mientras que, por otro lado, el histograma que se muestra a la derecha recoge los datos que cuantifican la frecuencia con la que aparecen los datos de distancia, haciendo que las dos representaciones de datos en conjunto permitan evaluar el comportamiento real del dron en toda la misión.

Para terminar con el estudio del DTW, mostramos valores estadísticos que se obtienen durante el cálculo y que se pueden contrastar si se observa la figura anterior 5.7. Los datos estadísticos nos permiten transformar observaciones cualitativas en valores numéricos, que añaden objetividad al análisis de desviación de trayectorias. En la siguiente tabla 5.2 se muestran los principales estadísticos descriptivos.

TABLA 5.2. ESTADÍSTICOS DESCRIPTIVOS DTW EN
BF-LAWNMOWER PRIMER ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.064	0.055	0.004	0.326	0.045	0.03

La media obtenida de desviación tiene un valor bajo y superior a la mediana, lo que indica una asimetría hacia la derecha, donde los valores más grandes arrastran la media consigo. El valor que se calcula para el IQR nos muestra que los valores centrales del

conjunto se encuentran muy concentrados, reforzando la idea obtenida de la media y mediana. Por último, vemos que el valor máximo es algo elevado con respecto al resto de los datos, que, unido al resultado de la desviación estándar, refleja la existencia de puntos donde la desviación puede ser algo notable. A pesar de esto, los valores son bastante bajos y, en general, no muestran un gran error entre ambas trayectorias.




Fig. 5.8. Reproducción de trayectorias con algoritmo Bf-expanding primer escenario

En este segundo caso se observa la aplicación del algoritmo de fuerza bruta Bf-expanding sobre el escenario de la misión. Al igual que en el primer caso, al tratarse de un camino en el que son en mayoría rectas y escasas curvas, el grado de coherencia es elevado, y no se encuentran desviaciones o errores destacados. A diferencia del primer caso, este tipo de trayectorias no realiza cambios de sentido o giros demasiado pronunciados, lo cual hace que no se vean discrepancias relevantes en las esquinas de los cuadrados.

Al tratarse también de un algoritmo de fuerza bruta, podemos notar que la posición del objetivo e indicios no es de importancia y el dron va a realizar el mismo movimiento de expansión. Respecto al primer caso, aquí no importa tanto qué tan lejos se encuentre el objetivo del inicio de la misión, sino la distancia con respecto al centro del espacio de búsqueda, por lo que, cuanto más lejos se encuentre de este centro, el dron va a tardar más tiempo e incluso, como en el primer caso, si el horizonte definido es muy pequeño puede ocurrir que el algoritmo no encuentre el marcador.

Se muestra a continuación la representación de las trayectorias por coordenadas de la

misión 5.9 donde observamos una pequeña desviación del trazado simulado con respecto a la referencia que en parte se puede deber a la aplicación de la interpolación del conjunto de datos. Aun así, podemos afirmar que la forma del movimiento es muy similar en ambos trazados.




Fig. 5.9. Error por coordenadas entre referencia y gt en algoritmo Bf-expanding primer escenario

Para el cálculo del error se mantiene el mismo procedimiento descrito anteriormente, utilizando como métrica principal la raíz del error cuadrático medio entre las trayectorias de referencia y simulación. En la siguiente tabla 5.3, se muestran los distintos valores obtenidos para varias ejecuciones del mismo escenario.

TABLA 5.3. ERROR (RMSE) ALGORITMO BF-EXPANDING
PRIMER ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
1.609	1.548	0.022	1.06

Los resultados que se muestran en la tabla 5.3 son mayores que en el primer supuesto y pueden parecer incluso desproporcionados si observamos de nuevo la figura en la que se representa la forma de los trazados 5.8. El hecho de añadir una marca temporal a la trayectoria de referencia, generando un conjunto de datos en el que el tiempo que se tarda en pasar de un punto a otro es siempre el mismo, y la posterior aplicación de la interpolación propicia la aparición de pequeños desfases que no son perceptibles a simple vista, pero que a la hora de calcular el error, hacen que estos valores no parezcan coherentes. Hasta ahora, después de haber visto los dos primeros casos, este es el que mayor error presenta.

A continuación se comienza con la aplicación del Dynamic Time Warping (DTW) para comprobar mediante esta métrica si los cálculos del error desarrollados son coherentes con la realidad.




Fig. 5.10. Alineamiento de trayectorias utilizando DTW en Bf-expanding primer escenario

En esta figura en la que se muestran las trayectorias y en negro la diferencia en cuanto a distancia de los puntos de cada uno de los trazados, no se aprecia una gran variación entre ambas. A primera vista se puede apreciar que los valores que se obtienen para la distancia entre trazados no son muy elevados, con algunas excepciones en algunas zonas donde el dron se desvía mínimamente.

Aunque de la figura se pueden obtener observaciones preliminares que pueden tener algo de cierto, se trata de datos subjetivos que no aportan un gran significado a las conclusiones del proyecto. Es por eso que se muestran a continuación diferentes métricas estadísticas que convierten este análisis en objetivo y pueden dar lugar a resultados destacables.




Fig. 5.11. Distribución y frecuencia de la distancia DTW en algoritmo Bf-expanding primer escenario

En la figura 5.11 se muestra la distribución y la frecuencia de las distancias obtenidas con el algoritmo DTW. Se aprecia de manera clara que los valores son relativamente bajos, indicando así que la diferencia entre los trazados es mínima; a pesar de esto, se identifican valores extremos que reflejan casos de mayor desviación respecto al algoritmo anterior, haciendo que, de los dos algoritmos de fuerza bruta, este sea el que más desviación tiene.

TABLA 5.4. ESTADÍSTICOS DESCRIPTIVOS DTW EN BF-EXPANDING PRIMER ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.084	0.078	0.004	0.651	0.039	0.047

Esta tabla nos sirve para reforzar aún más las observaciones hechas a partir de las figuras, indicando que la diferencia entre los trazados es mínima y que la simulación es bastante fiel al planificador en cuanto a la aplicación del algoritmo Bf-expanding. Algo a tener en cuenta es que en este segundo algoritmo la desviación estándar (STD) es menor que en el caso del algoritmo Bf-lawnmower, a pesar de que la media es mayor. Esto quiere decir que, aunque las desviaciones pueden ser mucho mayores, en promedio no se alejan demasiado de su valor medio, lo que indica que tiene un comportamiento más estable y consistente.

Hasta ahora, los valores del error calculado y los obtenidos de distancia media, aunque no coinciden ni se acercan el uno al otro, tienen un comportamiento similar, siendo el error y la distancia media de este algoritmo mayores que en el caso de Bf-lawnmower.




Fig. 5.12. Reproducción de trayectorias con algoritmo Ldfs-heur primer escenario

Nos encontramos ante el primer algoritmo de búsqueda en profundidad que utiliza una heurística para generar la trayectoria de la misión. A simple vista no es sencillo distinguir los distintos trazados en la figura 5.12, pero si nos fijamos bien, vemos que el dron realiza una gran cantidad de giros y la distancia entre estos es muy pequeña, lo que hace que la coincidencia entre las trayectorias de referencia y simulación tenga una gran diferencia y el error sea mayor.

Se aprecia que el dron viaja desde el inicio de la misión hacia el punto donde se indica el indicio y a partir de ahí, se va moviendo a puntos cercanos intentando buscar el objetivo. Esto de primeras puede parecer más sensato y que el dron va a tardar menos en encontrar el marcador, y en parte sí, ya que si la zona a localizar se encuentra cerca del indicio, es muy probable que lo detecte en poco tiempo. El problema viene cuando el indicio está muy alejado de la marca, lo que puede suponer que el dron no llegue a recorrer esa zona y no localice el punto marcado o tarde un mayor tiempo en ello. En el caso mostrado, como el objetivo está cerca del indicio, se puede suponer que va a ser identificado por el dron, ya que vemos incluso que pasa por encima de él.




Fig. 5.13. Error por coordenadas entre referencia y gt en algoritmo Ldfs-heur primer escenario

A simple vista, en la figura mostrada 5.12, se observa que este tipo de búsqueda realiza un mayor número de cambios de dirección, haciendo que la correspondencia entre ambos trazados no sea muy elevada. A pesar de esto, si mostramos las trayectorias separadas por coordenadas como en la figura 5.13, no se aprecia una gran diferencia en cuanto a la forma de ambas, pero lo que sí se puede ver es un claro desfase entre las dos, producido principalmente por la manipulación que se realiza en el preprocesado del conjunto de datos de referencia. Este desfase puede dar lugar a un valor de error mucho más elevado en algunas zonas.

TABLA 5.5. ERROR (RMSE) ALGORITMO LDFS-HEUR PRIMER ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
2.107	2.092	0.017	1.405

Los datos refuerzan la teoría de que el error en los algoritmos que utilizan funciones heurísticas para generar las misiones es mayor que en los de fuerza bruta. Aunque la coordenada altura mantiene un error bastante bajo, ya que no varía en ningún momento, las coordenadas norte y este presentan un error bastante elevado y con un valor bastante similar, debido a los numerosos cambios de dirección y de sentido que realiza durante toda la ejecución.

A pesar de esto, el error puede seguir pareciendo muy elevado para ser el real y es que, como sabemos, en este punto no estamos viendo realmente la desviación en la trayectoria en cuanto a la posición únicamente; al agregar la variable tiempo en nuestro conjunto,

estamos viendo en qué posición debería estar en un instante de tiempo, lo que hace que aparezcan los desfases que vemos constantemente y que aumentan el valor del error en general.




Fig. 5.14. Alineamiento de trayectorias utilizando DTW en Ldfs-heur primer escenario

La figura 5.14 nos muestra las desviaciones después de aplicar el algoritmo DTW sobre las trayectorias de las misiones generadas aplicando el algoritmo Ldfs-heur. No es posible obtener información relevante de ésta debido a que es complicado apreciar con claridad los distintos datos representados, aunque a primera vista no se ve una diferencia destacable entre los trazados. Es por esto que se muestra a continuación el análisis detallado de los conjuntos de datos.




Fig. 5.15. Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-heur primer escenario

A simple vista y sin ver los resultados de los datos estadísticos, vemos un rango total de valores elevado, con una mayor dispersión de estos, aunque con la mayor parte de los valores cercanos a cero y apreciando algunos muy alejados, indicando puntos con desviaciones notables. A diferencia de los casos vistos anteriormente, los datos se encuentran menos centralizados y esparcidos a lo largo del eje x, con una media notablemente superior.

TABLA 5.6. ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-HEUR
PRIMER ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.156	0.123	0.002	0.742	0.107	0.126

Estos resultados que obtenemos refuerzan lo que se viene suponiendo, encontrando una media de desviación mayor que en otros casos con un rango entre valores mínimos muy cercanos a cero y máximos que se acercan al metro de desviación. El valor de la desviación estándar es grande con respecto a la media, indicando así que hay una gran variedad de errores a lo largo del conjunto de datos. Por último, el valor del IQR establece que dentro de los valores más comunes, estos también tienen una gran dispersión, dejando caer que la precisión puede no ser tan buena en este caso.




Fig. 5.16. Reproducción de trayectorias con algoritmo Ldfs-miope primer escenario

En este último caso se aplica el algoritmo de búsqueda Ldfs-miope, que genera un recorrido en función de qué acción es la que parece ser mejor en el momento, sin evaluar el camino completo. Al igual que la prueba anterior, observamos que el dron realiza un gran número de cambios de dirección en un período corto de tiempo, lo cual hace que se puedan ver a simple vista zonas en las que las desviaciones entre planificación y simulación son notables.

El hecho de que este algoritmo recorra estados de una manera algo más aleatoria que Ldfs-heur, implica que si el indicio y objetivo se encuentran demasiado alejados, el algoritmo puede no encontrar el camino adecuado y perderse en bucles recorriendo estados que ya se visitan anteriormente. Esto que se explica, puede hacer que si el objetivo no se encuentra en la zona del indicio y se coloca en otra posición diferente cercana al inicio, si ocurre el caso de que el algoritmo se pierde, puede acabar detectándolo aunque no sea lo previsto.

Aun así, en el caso que describimos, observamos que sí lo detecta pasando por encima de él en un momento, aunque un poco más tarde que el primer algoritmo de búsqueda en profundidad, que se debe a que le cuesta más esfuerzo llegar a la zona donde se encuentra el indicio y el marcador.




Fig. 5.17. Error por coordenadas entre referencia y gt en algoritmo Ldfs-miope primer escenario

En la figura 5.17, se observan claramente cómo empieza realizando una búsqueda cerca del inicio hasta que se va acercando a la zona del objetivo y en cuanto a la desviación, encontramos algún que otro punto donde se hace notable al igual que en el caso anterior con el otro algoritmo de búsqueda con heurística. Como se viene viendo desde el primer algoritmo, agregar a la trayectoria de referencia una marca temporal y la posterior interpolación pueden jugar un papel fundamental aquí, ya que más que una desviación lo que se observa en esta figura es un pequeño desfase. Este desfase en momentos iniciales de la misión lo distinguimos porque en la figura observamos cómo el trazado descrito por el dron se adelanta a la referencia y al final de la ejecución ocurre lo opuesto, estando la referencia adelantada.

TABLA 5.7. ERROR (RMSE) ALGORITMO LDFS-MIOPE PRIMER ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
2.037	1.958	0.021	1.339

Estos resultados de error nos muestran que este algoritmo no tiene una desviación por coordenada elevada en general, con errores cercanos a los dos metros de media, que pueden asociarse a los numerosos cambios de dirección y de sentido que realiza en la misión, así como a la aplicación de la interpolación previa.

A continuación pasamos con la aplicación del DTW y la muestra de los resultados obtenidos a partir de este algoritmo.




Fig. 5.18. Alineamiento de trayectorias utilizando DTW en Ldfs-miope primer escenario

Al igual que en el algoritmo Ldfs anterior, en este apreciamos un mayor número de desviaciones, que se hacen más notables en los cambios de dirección, cuando el dron no consigue estabilizarse por completo.

Es necesario ver los resultados numéricos obtenidos tras la aplicación del DTW para poder obtener una conclusión con sentido. El siguiente histograma nos muestra que los valores de desviaciones se encuentran en valores bajos, aunque, como en todos los casos, encontramos errores algo elevados en algunos puntos. El diagrama de caja refuerza esta visualización y nos muestra de mejor manera hasta qué valores se extienden las desviaciones encontradas durante las ejecuciones.




Fig. 5.19. Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-miope primer escenario

En la siguiente tabla 5.8, se muestran los resultados numéricos que se obtienen en el DTW. En primer lugar, podemos destacar que la media es mayor que la mediana, lo que nos indica que hay errores elevados que empujan la media hacia un valor más alto. El valor mínimo nos indica que hay momentos en los que la simulación es muy precisa, y el máximo que hay al menos un punto donde la desviación es cercana a un metro. En cuanto al resto de los resultados, la desviación estándar es elevada con respecto a la media, lo que indica que hay una gran dispersión de datos; y el valor IQR también es algo alto, lo que significa que los valores más comunes también muestran una gran dispersión. Esto se puede contrastar con la figura 5.19, donde se ve claramente la inestabilidad de los datos.

TABLA 5.8. ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-MIOPE PRIMER ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.182	0.136	0.004	0.996	0.139	0.172

Una vez se analiza el comportamiento de cada uno de los algoritmos de manera individual, se continúa con una comparación en conjunto en la que se muestran las métricas obtenidas en cada uno de los casos que se presentan en el documento. Esta comparación es fundamental para poder analizar el rendimiento de los algoritmos de búsqueda aplicados en el proyecto.

TABLA 5.9. ERROR (RMSE) POR COORDENADAS DE CADA ALGORITMO DE BÚSQUEDA PRIMER ESCENARIO

ALGORITMO	NORTE	ESTE	ALTURA	TOTAL
Bf-lawnmower	0.168	0.965	0.018	0.383
Bf-expanding	1.646	1.583	0.026	1.086
Ldfs-heur	2.107	2.092	0.017	1.405
Ldfs-miope	2.037	1.958	0.021	1.339

La tabla que se muestra nos aporta información muy relevante sobre qué algoritmo es el que mayor correspondencia tiene entre referencia y simulación. El algoritmo que obtiene mejor calificación en este aspecto es el Bf-lawnmower, el cual es el que muestra menor error medio entre todas sus coordenadas. En cuanto al resto de algoritmos, vemos una desviación media superior a un metro y algo similar en los tres casos, siendo el que más valor presenta el algoritmo Ldfs-heur.

Para completar este análisis de errores de cada caso, se incluye una representación de las funciones de distribución acumulada de los errores obtenidos, que nos ayuda a observar el comportamiento de cada algoritmo, mostrando cómo se distribuyen los errores a lo largo de toda la ejecución.

La siguiente figura 5.20 refleja que los algoritmos Ldfs son los que presentan valores de desviación mucho más elevados que el resto de algoritmos, llegando a puntos cercanos a los diez metros de diferencia. Esto no se ve reflejado realmente en la representación de las trayectorias en dos dimensiones y se debe a la agregación de la variable de tiempo en la referencia y la aplicación de una interpolación sobre los conjuntos de datos, que agrega un desfase a las trayectorias y que, al comprobar el error en el tiempo, penaliza en gran medida.




Fig. 5.20. Función de distribución acumulada de todos los algoritmos primer escenario

Podemos mostrar también una comparativa entre los distintos cálculos de DTW aplicados a cada uno de los algoritmos de búsqueda para poder ver si los resultados se corresponden con el cálculo de error que se realiza en el proyecto. Para ello se muestra en la siguiente tabla 5.10 los estadísticos numéricos que venimos viendo hasta ahora.

TABLA 5.10. COMPARACIÓN DE RESULTADOS DWT DE LOS DISTINTOS ALGORITMOS PRIMER ESCENARIO

ALGORITMO	MEDIA	MEDIANA	MÁXIMO	MÍNIMO	STD	IQR
Bf-lawnmower	0.064	0.055	0.326	0.004	0.045	0.03
Bf-expanding	0.084	0.078	0.651	0.004	0.039	0.047
Ldfs-heur	0.156	0.123	0.742	0.002	0.107	0.126
Ldfs-miope	0.182	0.136	0.996	0.005	0.139	0.172

El algoritmo que menor desviación media tiene es Bf-lawnmower, que es algo que se puede suponer a partir del cálculo del error, donde este mismo algoritmo era el que menor valor presentaba. Aun así, no es el que menor dispersión de los datos presenta, siendo Bf-expanding el que tiene las desviaciones más concentradas en general. En cuanto a los últimos dos, los numerosos cambios de dirección y sentido que realizan, penalizan en gran medida la precisión y son los que muestran una mayor desviación media. Entre los dos, el peor en cuanto a correspondencia de trayectorias es Ldfs-miope, en el que se encuentran errores máximos muy elevados y una dispersión de datos grande.




Fig. 5.21. Distribución de la distancia DTW por algoritmo primer escenario

Esta figura refuerza la explicación anterior, viendo que el algoritmo de expansión es el que más concentrados tiene los valores de desviación, mientras que el que más se extiende por el histograma es el algoritmo Ldfs-miope. Se ve también a simple vista que el algoritmo corta césped es el que menor desviación tiene en general.

A continuación, se muestra el tiempo y la distancia media que recorre cada algoritmo hasta que detecta el marcador en este escenario concreto. Esto nos va a ayudar a comprobar en un escenario en el que todos son capaces de encontrar el estado final, cuál de ellos tiene un menor coste y lo hace en el menor tiempo posible.

TABLA 5.11. RESULTADOS DISTANCIA Y TIEMPO MEDIO
PRIMER ESCENARIO

ALGORITMO	TIEMPO	DISTANCIA
Bf-lawnmower	138.6	142.988
Bf-expanding	38.2	32.931
Ldfs-heur	39.2	34.704
Ldfs-miope	216.8	199.689

En la tabla observamos que el algoritmo que menos tiempo tarda de media en encontrar el objetivo es Bf-expanding, siguiéndole muy de cerca Ldfs-heur. Esto es algo normal y se explica de manera muy simple: el algoritmo de expansión, el primer punto que visita es el centro del espacio de búsqueda y al estar el marcador en una posición muy cercana, es normal que tarde tan poco tiempo en finalizar su misión. Lo mismo ocurre con el algoritmo Ldfs-heur, el cual la primera zona que visita es aquella en la que se encuentra

el indicio, lo cual debería dar como resultado un tiempo similar al de Bf-expanding, pero por alguna anomalía o evento puntual no ocurre.

El algoritmo Ldfs-miope es el que más tarda en encontrar el objetivo, lo cual se debe a que realiza una pequeña búsqueda cerca del inicio de la misión, debido a que no es capaz de encontrar el mejor camino hasta el objetivo, ya que no ve más allá del estado siguiente.

Con las distancias medias ocurre algo muy similar, siendo el algoritmo de expansión el que genera una trayectoria que produce una menor distancia media y el algoritmo con miopía el que recorre más distancia. Aun así, podemos ver algo que destaca y es que en el caso del algoritmo Bf-lawnmower, el dron recorre una mayor distancia en un menor tiempo, si lo comparamos con el resto de los casos. Esto se explica ya que en esta estrategia predominan las rectas de gran longitud, en las cuales el dron no necesita variar su velocidad salvo cuando llega a los cambios de sentido.

5.3. Escenario 2

En este segundo escenario se proponen una serie de casos en los que el dron comienza en una posición fija, los indicios también se encuentran siempre en la misma posición, pero el objetivo varía su posición dentro de estos indicios. Haciendo que el marcador cambie de posición dentro del indicio, agrega cierta aleatoriedad al escenario, permitiendo ver el rendimiento del planificador y el comportamiento de los distintos algoritmos, viendo el tiempo y la distancia que le toma al dron encontrar el objetivo, si es que realmente consigue encontrarlo.

Para este escenario se decide obtener un conjunto de diez ejecuciones diferentes, generadas de manera aleatoria. Estas misiones no son aleatorias para cada algoritmo, es decir, todos estos se evalúan sobre el mismo conjunto de ejecuciones, garantizando una comparación directa entre los algoritmos en la que las diferencias que encontremos se deban al propio comportamiento del algoritmo y no a la aleatoriedad del escenario. En estas misiones definidas, además de modificar la posición del marcador en cada una de ellas, se puede alternar otro tipo de factores que afectan a cómo se genera finalmente la trayectoria. Entre las variables que se modifican encontramos el número de pasos que realiza, la distancia entre estos pasos, el tamaño del espacio de búsqueda, la altura del dron y, para los algoritmos de fuerza bruta, la separación entre las zonas de búsqueda, es decir, en el caso de Bf-lawnmower, la distancia en la coordenada norte que debe aumentar la trayectoria en cada barrido y en Bf-expanding la distancia que habrá de separación entre los cuadrados que describe el dron. Estas modificaciones pueden llegar a afectar al rendimiento, aumentando o disminuyendo el tiempo o distancia recorrida hasta que el dron encuentra el objetivo e incluso pudiendo hacer que en algún caso no llegue a detectarlo.

Al igual que en el primer escenario, para facilitar la lectura y el análisis, se muestran los datos organizados por algoritmos y además se explica de qué manera afecta a cada uno las modificaciones realizadas en la planificación de las misiones. Empezamos, en

primer lugar, con el algoritmo Bf-lawnmower y analizando el error entre las trayectorias de referencia y simulación.

En este escenario se decide no mostrar las figuras en las que se observa el error entre coordenadas debido a que cada ejecución es diferente y puede no representar correctamente los datos, por eso se muestran directamente los resultados obtenidos de error medio para cada coordenada, habiendo introducido la variable tiempo en la trayectoria de referencia.

TABLA 5.12. ERROR (RMSE) ALGORITMO BF-LAWNMOWER
SEGUNDO ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
0.387	1.509	0.029	0.642

Como vemos, el error en este segundo escenario ha aumentado en exceso en la coordenada este, lo cual no quiere decir que en esta se haya desviado mucho realmente, ya que aquí lo comparamos con respecto al tiempo, es decir, que tanto se ha desfasado esa coordenada. En cuanto a la coordenada norte y la coordenada altura, aunque el error ha aumentado, no ha sido demasiado grande el cambio en general, siendo la que más penaliza al error medio la coordenada este.

Para poder ver cómo ha afectado los cambios a la hora de realizar la planificación de la misión, será más sencillo si aplicamos el algoritmo DTW a los resultados de las ejecuciones. Se muestra la figura con la distribución y la frecuencia de las desviaciones.




Fig. 5.22. Distribución y frecuencia de la distancia DTW en algoritmo Bf-lawnmower segundo escenario

A primera vista vemos que el rango ha aumentado significativamente, teniendo valores cercanos al metro de error, así como ha hecho también la distribución de los datos. No

mucha más información se puede obtener para destacar los cambios producidos entre escenarios, por lo que es necesario visualizar los estadísticos calculados.

TABLA 5.13. ESTADÍSTICOS DESCRIPTIVOS DTW EN
BF-LAWNMOWER SEGUNDO ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.109	0.073	0.001	0.963	0.111	0.055

Al igual que en el primer escenario, la media es mayor que la mediana, lo que indica una asimetría hacia la derecha con valores anormales elevados. El mínimo en este caso es bastante pequeño, con un milímetro de desviación, lo que indicaría una precisión elevada, si no fuera por que el máximo en este segundo escenario ha aumentado hasta cerca del metro de error. Finalmente, vemos que la dispersión de los datos es muy elevada y aquellos que se encuentran en el grupo medio presentan una concentración notable.

Los cambios realizados en la planificación de cada misión, alternando distintas variables para que la trayectoria varíe, han resultado en un mayor error entre la planificación y la simulación que se hace notar si observamos la tabla de error en función del tiempo y la tabla de resultados de aplicación del DTW. En el caso del algoritmo Bf-lawnmower, los casos que más le penalizan son aquellos en los que se disminuye el número de pasos y la distancia entre cada uno de ellos, haciendo que en algunos casos no llegue a recorrer la suficiente distancia para detectar el marcador. Además, si aumentamos la distancia entre zonas de búsqueda y la separación entre los puntos, al realizar curvas, el dron realiza el giro de manera errónea y aumenta la desviación media.




Fig. 5.23. Muestra de patrón de movimiento del dron en el segundo escenario

Para entender mejor esto, en la anterior figura se muestra un patrón en el movimiento del dron donde, al finalizar los movimientos en los que avanza en la dirección norte y comienza a moverse en el eje este, es decir, al finalizar los cambios de sentido, el dron realiza un movimiento similar en todos los casos, como si fuera una anomalía propia. Este patrón se hace más visible a medida que se aumenta la separación entre los espacios de búsqueda y la distancia entre los pasos que debe ejecutar el dron. Durante la ejecución de pruebas, se intenta encontrar este mismo comportamiento en otras estrategias sin obtener éxito y resultando en que solo es posible encontrar este tipo de anomalías en este algoritmo y siempre en los mismos puntos.

TABLA 5.14. ERROR (RMSE) ALGORITMO BF-EXPANDING
SEGUNDO ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
2.803	2.632	0.018	1.818

Al igual que el algoritmo anterior, en este segundo escenario, el valor del error obtenido entre la planificación y la simulación ha aumentado significativamente cerca de un metro en las coordenadas norte y este, lo cual no concuerda con lo que se puede apreciar en la siguiente figura 5.24 de la distribución y frecuencia de las desviaciones obtenidas

tras la aplicación del DTW. Los valores se distribuyen en general de la misma manera que en el primer escenario, lo que nos puede indicar que los nuevos cambios introducidos en los distintos parámetros no han penalizado en gran medida la precisión del dron.




Fig. 5.24. Distribución y frecuencia de la distancia DTW en algoritmo Bf-expanding segundo escenario

Viendo los valores de la siguiente tabla 5.15 reforzamos el pensamiento anterior de que la variación entre ambos escenarios no ha sido notoria para este algoritmo. La media y la mediana son menores, aunque indiquen entre ambas que es una distribución asimétrica, al igual que en el caso del escenario anterior. En cuanto al mínimo y el máximo, también han variado, disminuyendo el primero y aumentando el segundo, haciendo así que el rango de valores sea mayor. La distribución de estos es mucho menor que en el algoritmo Bf-lawnmower, viendo que la gran mayoría de datos se encuentran cercanos al valor de la media, a pesar de encontrar, como en todos los casos, valores donde se pierde cierta precisión.

TABLA 5.15. ESTADÍSTICOS DESCRIPTIVOS DTW EN
BF-EXPANDING SEGUNDO ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.081	0.071	0.002	0.733	0.054	0.055

Este algoritmo en este escenario no encuentra problemas notables en cuanto a rendimiento y precisión ya que, por mucho que se varíe el número de pasos o la distancia entre estos, como el marcador se encuentra en un punto cercano al medio del espacio de búsqueda, el cual es el primer punto que visita el dron, encuentra el objetivo en escasos segundos. La única penalización que puede tener es aumentar o disminuir el tamaño del área de búsqueda, lo que supone que el dron tenga que visitar un punto distinto a otros

casos y, si se combina bien con el número de pasos y distancias, puede llegar a provocar que no se detecte el objetivo.

TABLA 5.16. ERROR (RMSE) ALGORITMO LDFS-HEUR
SEGUNDO ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
2.394	2.411	0.018	1.607

El algoritmo Ldfs-heur, al igual que el resto, ha aumentado el error de posición con respecto al tiempo en este segundo escenario, aunque en general este aumento no ha sido muy elevado.




Fig. 5.25. Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-heur segundo escenario

Los diagramas nos muestran que los valores de distancia errónea se encuentran en gran medida bastante concentrados en valores que, aunque puedan parecer bajos, las marcas del eje de distancia del histograma tienen unos intervalos más amplios de lo que se ha mostrado en este documento. Además de todo esto, podemos destacar la aparición de distancias significativas que se acercan a los tres metros. Esta visualización se refuerza con los datos obtenidos en el cálculo del DTW que se muestran a continuación.

TABLA 5.17. ESTADÍSTICOS DESCRIPTIVOS DTW EN
LDFS-HEUR SEGUNDO ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.197	0.137	0.003	2.926	0.197	0.172

Al igual que en el error calculado, la distancia media obtenida en el DTW ha aumentado de manera suave, al igual que el resto de las métricas, viendo como única diferencia a destacar el máximo que ha aumentado hasta un valor cercano a tres metros.

En términos generales no es una desviación alta, con una distribución asimétrica y con un rango de valores elevado. En cuanto a la dispersión de estos valores, la desviación estándar nos indica que es elevada, al igual que la parte central de este patrón de datos.

Este algoritmo se podría decir que hasta ahora, en cuanto a rendimiento, es el mejor de los vistos debido a que, aunque muevas el marcador dentro de los indicios, modifiques en gran medida los pasos o la distancia entre estos, es muy poco probable que no detecte el marcador en todas las misiones que se planifiquen, ya que el primer punto al que viaja es al centro de los indicios y a no ser que el objetivo se encuentre muy lejos de estos, detecta el objetivo con facilidad.

TABLA 5.18. ERROR (RMSE) ALGORITMO LDFS-MIOPE
SEGUNDO ESCENARIO

NORTE	ESTE	ALTURA	TOTAL
3.342	3.512	0.023	2.292

Nos encontramos ante el último algoritmo a analizar en el segundo escenario, el cual, como vemos en la tabla 5.18, ha aumentado el error significativamente cerca de un metro en las coordenadas norte y este. Además, en la figura que se muestra a continuación, tras la aplicación de DTW a los conjuntos de datos, se ve que la diferencia media es superior en este caso, apreciando un aumento en la dispersión de los datos y apareciendo valores máximos que sobrepasan los tres metros.




Fig. 5.26. Distribución y frecuencia de la distancia DTW en algoritmo Ldfs-miope segundo escenario

Al visualizar los resultados del DTW, reforzamos la idea anterior. La media es algo elevada con respecto a la mediana, indicando así que hay varios extremos muy elevados que aumentan este valor considerablemente, lo cual vemos si hacemos hincapié en el máximo, el cual ha aumentado hasta los tres metros de diferencia entre trayectorias. Al igual que en el primer escenario, los datos tienen alta distribución y aquellos que representan la parte central de los datos presentan una alta dispersión con respecto al conjunto de datos que tenemos.

TABLA 5.19. ESTADÍSTICOS DESCRIPTIVOS DTW EN LDFS-MIOPE SEGUNDO ESCENARIO

MEDIA	MEDIANA	MÍNIMO	MÁXIMO	STD	IQR
0.243	0.168	0.003	3.189	0.256	0.22

El algoritmo Ldfs-miope es hasta ahora el peor en cuanto a rendimiento, siendo el que más tarda en encontrar el objetivo al tener que realizar una doble búsqueda en el escenario y, además, es en la segunda de estas en la que busca cerca de los indicios. Algo curioso sobre este algoritmo es que, si el número de pasos es lo suficientemente bajo, este algoritmo no llegará a barrer la zona de los indicios y, por ende, no encontrará el marcador.

En cuanto a precisión y fidelidad, en la siguiente tabla 5.20 se puede observar que es el que mayor error presenta de todos los algoritmos vistos en este punto. Al igual que en el primer escenario, el algoritmo Bf-lawnmower es el que presenta menor error medio entre las tres coordenadas y destacamos el claro aumento del desfase en el caso de Bf-expanding, a pesar de que en la aplicación del DTW no se ha visto reflejado.

TABLA 5.20. ERROR (RMSE) POR COORDENADAS DE CADA ALGORITMO DE BÚSQUEDA SEGUNDO ESCENARIO

ALGORITMO	NORTE	ESTE	ALTURA	TOTAL
Bf-lawnmower	0.387	1.509	0.029	0.642
Bf-expanding	2.803	2.632	0.018	1.818
Ldfs-heur	2.394	2.411	0.018	1.607
Ldfs-miope	3.342	3.512	0.023	2.292

El CDF nos ayuda a ver cómo se distribuyen estos errores a lo largo de la ejecución. A diferencia del primer escenario, en este los errores son mucho mayores y más dispersos a lo largo del eje, lo que indica la pérdida de precisión que se viene indicando durante todo el escenario, que se puede ver reflejada con facilidad en los errores de Ldfs-míoep, donde observamos un desfase de hasta veinticinco unidades. La forma escalonada de algunos algoritmos sugiere que los datos se encuentran más concentrados en ciertos valores específicos, como es el caso de Bf-expanding.




Fig. 5.27. Función de distribución acumulada de todos los algoritmos segundo escenario

Al igual que en el caso de los errores, los resultados que se obtienen tras la aplicación de DTW han aumentado en la gran mayoría de algoritmos, siendo el que peor media obtiene el algoritmo Ldfs-miope. Encontramos una excepción que es Bf-expanding; en este caso, la desviación media ha disminuido y los valores se encuentran más concentrados en torno a esta medida. Esto indica que en cuanto a error de posición espacial, este algoritmo es el que mejor puntuación obtiene hasta ahora ya que de los dos escenarios que hemos visto, por ahora no ha subido de los diez centímetros de desviación media. Estos datos se pueden ver en la tabla que se muestra a continuación 5.21

TABLA 5.21. COMPARACIÓN DE RESULTADOS DWT DE LOS DISTINTOS ALGORITMOS SEGUNDO ESCENARIO

ALGORITMO	MEDIA	MEDIANA	MÁXIMO	MÍNIMO	STD	IQR
Bf-lawnmower	0.109	0.073	0.963	0.001	0.111	0.055
Bf-expanding	0.081	0.071	0.733	0.002	0.054	0.055
Ldfs-heur	0.197	0.137	2.926	0.003	0.197	0.172
Ldfs-miope	0.243	0.168	3.189	0.003	0.256	0.22

Finalmente pasamos al análisis del rendimiento de cada uno de los algoritmos y, en definitiva, del planificador. Observamos en la siguiente tabla los valores medios obtenidos para el tiempo en segundos y la distancia en metros que necesita el dron para encontrar el objetivo. En este segundo escenario, el tiempo medio y la distancia que recorre el dron para Ldfs-heur se mantienen bastante similares al primer escenario, seguido por el

algoritmo Bf-expanding, el cual se ha visto penalizado por los cambios en los parámetros realizados en la planificación y ha aumentado tanto el tiempo medio como la distancia que recorre.

Como curiosidad, observamos que el algoritmo que más tarda en detectar el marcador es Ldfs-míope, pero no es el que más distancia recorre, sino que es Bf-lawnmower, lo cual tiene una explicación y es que este segundo, los movimientos que realiza son en gran medida rectas de varios metros, por lo que puede mantener una velocidad elevada durante un mayor porcentaje de la misión, recorriendo una mayor distancia en menor tiempo.

TABLA 5.22. TIEMPO Y DISTANCIA MEDIA HASTA DETECCIÓN DEL MARCADOR SEGUNDO ESCENARIO

ALGORITMO	TIEMPO	DISTANCIA
Bf-lawnmower	149.25	211.149
Bf-expanding	45.5	47.624
Ldfs-heur	38.37	36.698
Ldfs-miope	183	199.877

Una vez expuestos todos los resultados obtenidos en el segundo escenario, se puede afirmar que Ldfs-heur es el mejor en cuanto a rendimiento y a fidelidad entre planificador y simulación en este caso.

5.4. Escenario 3

Nos encontramos ante el tercer y último escenario diseñado para la experimentación de este proyecto. Este caso es el que presenta mayor aleatoriedad de los tres que se exponen, ya que en éste, aunque la posición del dron original se mantiene constante, la posición del indicio varía en cada ejecución y el objetivo dentro de estos indicios también cambia de ubicación. Esto que se explica nos permite tener escenarios que puedan parecerse más a un caso real en el que los datos que se obtienen en la planificación pueden ser erróneos o sujetos a grandes cambios.

Como en el caso anterior, los cambios que se realizan entre cada una de las ejecuciones no se limitan simplemente a variar la posición de marcador e indicio, se modifican el número de pasos, la distancia entre estos o, para los algoritmos de fuerza bruta, la distancia entre zonas de búsqueda. Esto nos asegura que las trayectorias que se generan sean aleatorias y diferentes en todos los casos que se ejecutan.

A diferencia del resto de escenarios, en este caos nos centramos en el análisis del rendimiento del planificador, comprobando tanto el tiempo como la distancia media que recorre el dron hasta detectar el objetivo, debido a que al tener éste una aleatoriedad superior, es el que mejor nos sirve para comprobar si el planificador es robusto o no.

Como sabemos, el planificador tiene la capacidad de ofrecer una estimación de la distancia que recorre el dron hasta que detecta el objetivo, por lo que mostramos una comparación de la distancia media real con la distancia media estimada del planificador. Esta comparación nos ayuda a evaluar qué tan preciso es nuestro sistema de planificación en misiones donde no hay condiciones externas que puedan afectar a la trayectoria del dron más que su propio comportamiento, viendo si de verdad el planificador depende mucho de que las condiciones sean completamente ideales.

TABLA 5.23. COMPARACIÓN DISTANCIA MEDIA REAL Y PLANIFICADA EN METROS TERCER ESCENARIO

ALGORITMO	REAL	PLANIFICADA
Bf-lawnmower	187.925	323.288
Bf-expanding	82.391	249,255
Ldfs-heur	74.526	125.085
Ldfs-miope	174.451	170,671

Observamos en la tabla 5.23 una clara diferencia en todos los algoritmos entre la distancia real y la estimada, la cual tiene una explicación. En general, la diferencia en la distancia se debe a que el planificador genera una trayectoria en la que él supone que el dron no es capaz de detectar el marcador, debido a que la simulación de las condiciones del sensor y el campo de visión que tiene este son difíciles de replicar, dando como resultado misiones en las que se supone que no se debe encontrar el objetivo, pero en la simulación sí que se detecta.

Si cogemos los casos en los que sí que se consigue encontrar el objetivo en la planificación, en los algoritmos de fuerza bruta que no realizan un gran número de giros, la estimación es bastante cercana a la realidad, por lo que podemos afirmar que en estos supuestos, el planificador calcula de manera adecuada la distancia de la trayectoria. En cambio, en los algoritmos que presentan heurística, se observan una gran cantidad de cambios de dirección, que, como ya sabemos, hacen que el dron recorra una cantidad de distancia superior, haciendo que la distancia real sea superior a la estimada en algunos casos.

Explicado esto, podemos volver a los datos mostrados en la tabla 5.23 donde se observa que en general las distancias reales son muy inferiores por el hecho de que en la planificación, la gran mayoría no detecta el objetivo, pero si observamos el caso del algoritmo ldfs-miope, es el único donde la estimada es inferior a la real, lo cual se debe a que, a pesar de mostrar una distancia correcta, esta es suponiendo una trayectoria ideal en la que los cambios de dirección se realizan de forma exacta y no se produce un aumento de distancia. Es por esto que en este algoritmo mencionado encontramos mayor distancia real.

Se menciona el hecho de que el sistema planificador falla a la hora de indicar si es posible detectar el objetivo o no y es por eso que se muestra a continuación 5.24 la tasa

de acierto real y estimada para cada uno de los algoritmos.

TABLA 5.24. TASA DE ACIERTO TERCER ESCENARIO

ALGORITMO	ACIERTO REAL	ACIERTO PLANIFICADO
Bf-lawnmower	0.7	0.2
Bf-expanding	0.8	0.5
Ldfs-heur	1	0.8
Ldfs-miope	0.6	0.5

Estos datos que se observan explican el porqué encontramos la amplia diferencia entre la distancia estimada y la real en algunos casos. El algoritmo Bf-lawnmower, como vemos, presenta 7 errores de cada diez ejecuciones realmente, mientras que el sistema planificado nos indica que solo acierta 2. El planificador, si no detecta el marcador, genera una trayectoria con todos los pasos indicados; en cambio, si lo detecta, solo genera la trayectoria hasta el primer punto donde lo encuentra, lo cual indica la elevada distancia estimada media en este escenario.

Los algoritmos que presentan un alto acierto real y la diferencia entre el acierto estimado y el simulado, presentan una menor diferencia entre las distancias que se muestran, como es el caso de Bf-expanding y Ldfs-heur.

Por último, el algoritmo Ldfs-miope tiene una tasa de acierto no muy elevada tanto en el caso de la real como de la estimada. Como ambas tienen un valor cercano, el valor que muestre el planificador de la distancia debería ser cercano al que realmente se observa en el simulador, pero como este algoritmo es muy poco preciso en los cambios de dirección, recorre más longitud y hace que, como en este caso que observamos, la distancia sea mayor en la realidad.

La explicación a estos valores de acierto se debe al diseño de las misiones ejecutadas en este escenario. Lo que se busca al planificar estas misiones es penalizar a todos los algoritmos por igual, aunque en algunos casos no sea posible del todo, modificando el número de pasos, separación entre ellos, tamaño del plano de búsqueda, posición de los indicios o la separación entre zonas.

El algoritmo Bf-lawnmower tiene dificultades para encontrar el objetivo si el número de pasos no es muy elevado y el marcador se encuentra lo suficientemente alejado en la coordenada norte, que combinado con la separación entre pasos y entre zonas de búsqueda, penaliza en gran medida este caso. Algo similar se observa en el caso de Bf-expanding, que cuando el marcador se encuentra alejado del centro del espacio de búsqueda y el horizonte de búsqueda, es decir, el número de pasos no es elevado, muestra claras dificultades para generar una trayectoria que consiga hallar el objetivo.

Para el algoritmo Ldfs-heur, la mayor penalización que se puede encontrar es que el marcador no se encuentre cerca del indicio, lo cual hace que el dron barra una zona equivocada sin tener acierto. Esto no se ha realizado en este proyecto, donde todas las

misiones tienen el objetivo en una zona cercana a los indicios. Otra manera en la que se puede obtener un resultado negativo es ubicar el marcador lo suficientemente alejado del origen del dron y disminuir en gran medida el número de pasos, aunque esto no solo penaliza a este algoritmo, sino a todos. Es por esto que no se ha conseguido un solo caso en el que el sensor no haya encontrado el marcador. Aun así, vemos que el planificador indica que en un 0.2 de las misiones no se detecta nada, pero es un pequeño fallo que se ha detectado durante las ejecuciones y es que, si el lugar a alcanzar se encuentra muy cercano a los bordes del mapa, el sistema no lo cuenta como detectado a pesar de que éste pasa en numerosas ocasiones por encima.

Al igual que el caso anterior, Ldfs-miope no encontrará bajo ningún concepto el marcador si este se encuentra muy alejado del indicio pasado como parámetro. Como sabemos que en nuestro caso no se pueden generar ejecuciones así, el hecho de tener un objetivo muy alejado del inicio del dron en un escenario grande hace que el planificador genere una trayectoria que parece perderse por todo el área de búsqueda, haciendo que recorra una gran longitud en vano alrededor del origen.

Para terminar con este análisis, mostramos el tiempo medio que tarda el dron en hallar la baliza en función del algoritmo que ha generado su trayectoria.

TABLA 5.25. TIEMPO MEDIO HASTA DETECCIÓN DEL MARCADOR EN TERCER ESCENARIO

ALGORITMO	TIEMPO
Bf-lawnmower	189.4
Bf-expanding	83.7
Ldfs-heur	89
Ldfs-miope	204.4

Observamos algo curioso y es que en el caso de los algoritmos de fuerza bruta parece que el dron avanza un metro por segundo ya que ambos resultados son bastante similares. En el caso de los algoritmos con heurística, esto no se cumple y sale un valor en el tiempo algo mayor, lo cual se debe al gran número de cambios de dirección que realizan.

6. CONCLUSIONES

A continuación se muestran las conclusiones que se obtienen tras realizar el proyecto y mostrar los resultados, comprobando si los objetivos que se establecen al inicio han sido abordados y superados con efectividad.

6.1. Conclusiones finales

Uno de las principales metas de este proyecto es generar misiones que puedan ser ejecutadas directamente en el sistema de control de vuelo, sin necesidad de hacer futuras modificaciones por problemas en el formato en el que se almacenan. Esto se ha conseguido gracias a la integración en el sistema de planificación de un módulo de guardado de misiones en el formato que acepta tanto el controlador de vuelo como estaciones de tierra como QGC.

En el caso del controlador de vuelo, se consigue crear un sistema capaz de leer los archivos de misiones que se generan, realizar el posterior tratamiento de los datos y enviar esta información al dron para que ejecute la trayectoria que se desea. El sistema creado es capaz también de obtener información sobre la propia simulación, datos relevantes sobre la posición del dron y su comportamiento, e imágenes del sensor que nos permiten comprobar si se detecta el objetivo durante la ejecución, almacenando todos estos datos en distintos archivos para que puedan analizarse posteriormente. Los resultados reflejan que este objetivo se ha completado con éxito, teniendo un sistema robusto el cual no presenta apenas fallos a lo largo de la realización del proyecto.

Uno de los objetivos fundamentales del proyecto es analizar el grado de fidelidad entre el sistema de planificación y la simulación ejecutada. Mediante la exhaustiva comparación de las trayectorias de referencia y los datos obtenidos sobre el dron del propio simulador se ha conseguido obtener un resultado cuantitativo a través del uso de métricas como RMSE o el cálculo del DTW. Estos resultados nos muestran una gran similitud entre planificación y simulación en general, siendo más notable en aquellos casos donde los cambios de dirección son más escasos. La estrategia que mejores resultados obtiene en cuanto a error y diferencia entre trayectorias en el primer escenario, calculadas a partir de DWT, es Bf-lawnmower, lo que se debe al número escaso de cambios de dirección. Este resultado no se repite en el segundo escenario, que, como se explica en el apartado de experimentación, la variación de los parámetros entre ejecuciones produce que aparezca un mayor error entre simulación y planificación debido a problemas del controlador de vuelo. Por ello, en el segundo escenario el algoritmo Bf-expanding es el que mayor grado de coherencia tiene, sin variar mucho su valor entre desde el primer caso.

Se debe destacar que durante el cálculo del error de posición en función del tiempo

se pueden encontrar algunas incongruencias. El hecho de hacer que la trayectoria de referencia dependa del tiempo, dividiendo el tiempo total de ejecución entre el número total de pasos, hace que se convierta en una trayectoria ideal en la que no existen cambios de velocidad y que al ser comparada con la trayectoria real, puede dar lugar a resultados que no pueden parecer correctos. Aun así, se encuentra un comportamiento similar al mostrado en el cálculo del DTW, lo que da a entender que, a pesar de lo que pueda parecer, obtiene de manera correcta las diferencias entre simulación y planificación.

La similitud y coherencia que se observa entre los dos sistemas afirma que la simulación ejecuta con gran acierto lo que se plantea en la planificación, dando así cierta solidez a los datos que se muestran sobre el rendimiento del planificador y de los algoritmos de búsqueda. Sabiendo que estos valores son acertados, se puede llevar a cabo una comparación de los distintos algoritmos mostrados, indicando cuál es más eficaz en los distintos escenarios en función de las diferentes métricas que se observan.

Los resultados muestran que el algoritmo Ldfs-heur es el que mejor se adapta a todo tipo de condiciones en los escenarios, detectando el marcador en todos los casos que se han planteado y es que el hecho de aplicar la corrección miope, nos aseguramos de que se encuentre una solución si el marcador se encuentra en una posición cercana al indicio. No obstante, en los resultados se observa que es de los peores en cuanto a coherencia entre planificación y simulación, lo cual se debe al gran número de cambios de dirección que realiza durante la ejecución.

Si bien el algoritmo Bf-expanding también presenta resultados prometedores, el hecho de que tenga menor tasa de acierto hace que el algoritmo con heurística sea más aceptable y es que en la gran mayoría de los casos, el objetivo se encontraba cerca del centro del espacio de búsqueda, que es la primera posición que visita esta estrategia.

Para finalizar, destacamos que durante la ejecución del trabajo se ha logrado desarrollar un sistema capaz de gestionar desde la planificación de una misión hasta su posterior ejecución, obteniendo información sobre el dron y su entorno en todo momento, y con un carácter sólido, que lo convierte en un sistema seguro para la evaluación de comportamientos.

6.2. Futuros trabajos

El haber desarrollado este sistema complejo da pie a futuras investigaciones en las que se continúe utilizando y mejorando en función de lo que se investigue. Un paso que se puede dar para mejorar la investigación es llevar el sistema a un entorno real, con un dron físico y un marcador para ver qué tal se comporta este sistema en ciertos escenarios con condiciones realistas.

También se puede seguir estudiando acerca del tema en el simulador hiperrealista si modificamos el entorno agregando condiciones climáticas o distintos obstáculos, ya que en este proyecto se han tenido en cuenta escenarios ideales en los que no hay factores

externos que pueden alterar el comportamiento del dron durante su ejecución. Hacer que el sistema pueda tomar decisiones en función de lo que se ve a través de sensores, detectando obstáculos o clima adverso que pueda desestabilizar, es un tema que puede traer cierto interés.

Por problemas de coste de ejecución, sabemos que en este trabajo no se realizan más de diez ejecuciones por escenario, lo cual hace que los resultados que se presentan no sean tan sólidos estadísticamente hablando. Un buen trabajo futuro puede ser realizar un número suficiente de ejecuciones de cada escenario que puede llevar a conclusiones más robustas, obteniendo resultados estadísticos que sean más exactos.

Además, en cuanto al número de agentes que realizan búsquedas en el entorno, en nuestro caso establecemos que solo uno sea el que ejecute la misión. Es interesante ver si al agregar más agentes por misión se alcanzan consecuencias atractivas, valorando cómo interactúan entre ellos, cómo afrontan estos problemas los algoritmos y qué trayectorias se generan si tienen en cuenta este factor de presencia de agentes.

BIBLIOGRAFÍA

- [1] R. Bellman, "The theory of dynamic programming," *Bulletin of the American Mathematical Society*, vol. 60, n.º 6, pp. 503-515, 1954.
- [2] P. E. Hart, N. J. Nilsson y B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," *IEEE transactions on Systems Science and Cybernetics*, vol. 4, n.º 2, pp. 100-107, 1968.
- [3] R. A. Howard, *Dynamic programming and markov processes*. John Wiley, 1960.
- [4] L. P. Kaelbling, M. L. Littman y A. R. Cassandra, "Planning and acting in partially observable stochastic domains," *Artificial Intelligence*, vol. 101, n.º 1, pp. 99-134, 1998. doi: [https://doi.org/10.1016/S0004-3702\(98\)00023-X](https://doi.org/10.1016/S0004-3702(98)00023-X). [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S000437029800023X>.
- [5] G. E. Box y G. C. Tiao, *Bayesian inference in statistical analysis*. John Wiley & Sons, 2011.
- [6] P. Lanillos, "Minimum time search of moving targets in uncertain environments," Tesis doct., Ph. D. thesis, 2013.
- [7] S. Pérez-Carabaza, E. Besada-Portas, J. A. López-Orozco y J. M. d. l. Cruz, "Planificador de búsqueda en tiempo mínimo en un sistema de control de RPAS," en *XXX-VII Jornadas de Automática*, Comité Español de Automática, 2016, pp. 785-792.
- [8] S. Pérez-Carabaza, J. Scherer, B. Rinner, J. A. López-Orozco y E. Besada-Portas, "UAV trajectory optimization for Minimum Time Search with communication constraints and collision avoidance," *Engineering Applications of Artificial Intelligence*, vol. 85, pp. 357-371, 2019.
- [9] P. Lanillos, J. Yanez-Zuluaga, J. J. Ruz y E. Besada-Portas, "A bayesian approach for constrained multi-agent minimum time search in uncertain dynamic domains," en *Proceedings of the 15th annual conference on Genetic and evolutionary computation*, 2013, pp. 391-398.
- [10] S. Pérez-Carabaza, E. Besada-Portas, J. A. Lopez-Orozco y G. Pajares, "Minimum Time Search in Real-World Scenarios Using Multiple UAVs with Onboard Orientable Cameras," *Journal of Sensors*, vol. 2019, n.º 1, p. 7 673 859, 2019.
- [11] E. Besada-Portas, J. L. Risco-Martín, J. A. López-Orozco y J. J. Navarro-Corcuera, "Análisis y planificación de misiones de búsqueda y rescate en el entorno marítimo," en *XL Jornadas de Automática*, Universidade da Coruña, Servizo de Publicacións, 2019, pp. 8-15.

- [12] Ø. Breivik y A. A. Allen, “An operational search and rescue model for the Norwegian Sea and the North Sea,” *Journal of Marine Systems*, vol. 69, n.º 1-2, pp. 99-113, 2008.
- [13] T. M. Kratzke, L. D. Stone y J. R. Frost, “Search and rescue optimal planning system,” en *2010 13th International Conference on Information Fusion*, IEEE, 2010, pp. 1-8.
- [14] S. Pérez-Carabaza, E. Besada-Portas, J. A. López-Orozco y G. Blasco, “Modelado y optimización de misiones de búsqueda de objetivos mediante UAVs,” en *XL Jornadas de Automática*, Universidade da Coruña, Servizo de Publicacións, 2019, pp. 574-581.
- [15] P. Lanillos, E. Besada-Portas, J. A. Lopez-Orozco y J. M. De la Cruz, “Minimum time search in uncertain dynamic domains with complex sensorial platforms,” *Sensors*, vol. 14, n.º 8, pp. 14 131-14 179, 2014.
- [16] S. Demers, P. Gopalakrishnan y L. Kant, “A generic solution to software-in-the-loop,” en *MILCOM 2007-IEEE Military Communications Conference*, IEEE, 2007, pp. 1-6.
- [17] Microsoft, *AirSim: High-Fidelity Visual and Physical Simulation for Autonomous Vehicles*, <https://microsoft.github.io/AirSim/>, 2021.
- [18] S. Shah, D. Dey, C. Lovett y A. Kapoor, “Airsim: High-fidelity visual and physical simulation for autonomous vehicles,” en *Field and Service Robotics: Results of the 11th International Conference*, Springer, 2018, pp. 621-635.
- [19] Dronecode, *PX4 Autopilot User Guide*, <https://docs.px4.io/main/en/>, 2025.
- [20] Dronecode, *QGroundControl User Guide*, https://docs.qgroundcontrol.com/Stable_V4.4/en/qgc-user-guide/, 2025.
- [21] C. Ramirez-Atencia y D. Camacho, “Extending QGroundControl for automated mission planning of UAVs,” *Sensors*, vol. 18, n.º 7, p. 2339, 2018.
- [22] Dronecode, *MAVLink Developer Guide*, <https://mavlink.io/en/>, 2025.
- [23] Dronecode, *MAVSDK User Guide*, https://docs.qgroundcontrol.com/Stable_V4.4/en/qgc-user-guide/, 2025.
- [24] F. Xie, M. Müller y R. Holte, “Jasper: the art of exploration in greedy best first search,” *The Eighth International Planning Competition (IPC-2014)*, pp. 39-42, 2014.
- [25] J. P. Snyder, *Map projections—A working manual*. US Government Printing Office, 1987, vol. 1395.
- [26] J. P. Llerena Caña, J. García Herrero y J. M. Molina López, “Error Reduction in Vision-Based Multirotor Landing System,” *Sensors*, vol. 22, n.º 10, 2022. doi: [10.3390/s22103625](https://doi.org/10.3390/s22103625). [En línea]. Disponible en: <https://www.mdpi.com/1424-8220/22/10/3625>.

- [27] P. Senin, “Dynamic time warping algorithm review,” *Information and Computer Science Department University of Hawaii at Manoa Honolulu, USA*, vol. 855, n.º 1-23, p. 40, 2008.

ANEXO A. DECLARACIÓN DE USO DE IA GENERATIVA

He usado IA Generativa en este trabajo

Marca lo que corresponda:

SI NO

Parte 1: reflexión sobre comportamiento ético y responsable

Ten presente que el uso de IA Generativa conlleva unos riesgos y puede generar una serie de consecuencias que afecten a la integridad moral de tu actuación con ella. Por eso, te pedimos que contestes con honestidad a las siguientes preguntas (*Marca lo que corresponda*):

Pregunta
1. En mi interacción con herramientas de IA Generativa he remitido datos de carácter sensible con la debida autorización de los interesados. Sí, he usado estos datos con autorización NO, he usado estos datos sin autorización NO, no he usado datos de carácter sensible
2. En mi interacción con herramientas de IA Generativa he remitido materiales protegidos por derechos de autor con la debida autorización de los interesados. Sí, he usado estos materiales con autorización NO, he usado estos materiales sin autorización NO, no he usado materiales protegidos
3. En mi interacción con herramientas de IA Generativa he remitido datos de carácter personal con la debida autorización de los interesados. Sí, he usado estos datos con autorización NO, he usado estos datos sin autorización NO, no he usado datos de carácter personal

4. Mi utilización de la herramienta de IA Generativa ha **respetado sus términos de uso**, así como los principios éticos esenciales, no orientándola de manera maliciosa a obtener un resultado inapropiado para el trabajo presentado, es decir, que produzca una impresión o conocimiento contrario a la realidad de los resultados obtenidos, que suplante mi propio trabajo o que pueda resultar en un perjuicio para las personas.

SI

NO

Parte 2: declaración de uso técnico

Declaro haber hecho uso del sistema de IA Generativa ChatGPT principalmente para ayudar con la escritura del proyecto, es decir, se ha empleado para obtener sinónimos de palabras o expresiones similares, así como para la consulta de normas de ortografía, sin llegar a plasmar el texto completo para que lo reformule, simplemente preguntando por palabras en concreto.

Otro uso que he hecho de esta herramienta es para poder obtener referencias bibliográficas sobre algunos aspectos del trabajo que finalmente no han sido utilizadas por no estar relacionadas con lo esperado y por obtener mejores resultados al buscar en Google Académico.

En cuanto a aspectos del desarrollo del código del proyecto, debido a los numerosos sistemas elaborados y su complejidad, he solicitado ayuda con la optimización de los códigos.

Finalmente he utilizado la IA para poder incluir este anexo en el documento, pues es que este ha sido desarrollado utilizando sistema LaTeX y el formulario era un documento Word, por lo que para poder transformarlo y debido a los pocos recursos existentes para realizar esto, he necesitado su ayuda.

Parte 3: reflexión sobre utilidad

El uso de la IA Generativa me ha servido de gran ayuda ya que en mi caso me cuesta mucho redactar textos sin repetir las mismas palabras y expresiones cuando quiero describir conceptos. En muchas ocasiones se puede buscar en páginas web o en diccionarios, pero no siempre se obtiene la palabra que buscas y menos a la hora de buscar expresiones.

Para la optimización de código, que es el otro caso en el que me ha ayudado, ha sido de gran ayuda. Los códigos que he desarrollado, en ocasiones utilizaban algoritmos complejos que no había visto nunca y, en cuanto a optimización y rendimiento eran bastante malos.

En cuanto a la bibliografía, no he obtenido gran ayuda, ya que el tema es muy específico y a la IA le cuesta un poco y acaba mostrando estudios y lecturas más generales.

ANEXO B. CUADERNOS JUPYTER CON EL ANÁLISIS DE DATOS

A continuación se muestra un listado con los diferentes cuadernos de Jupyter que se han desarrollado durante el trabajo para el análisis de datos, los cuales se encuentran en un repositorio de GitHub.

- `bf_lawnmower.ipynb`: resultados del algoritmo Bf-lawnmower
- `bf_expanding.ipynb`: resultados del algoritmo Bf-expanding
- `ldfs_miope.ipynb`: resultados del algoritmo Ldfs-miope
- `ldfs_heur.ipynb`: resultados del algoritmo Ldfs-heur
- `comparacion_metodos.ipynb`: resultados de todas las estrategias combinadas

Todos estos cuadernos pueden encontrarse en el siguiente repositorio de GitHub: https://github.com/Jompy-GitHub/MTS-UncertainEnvironment/tree/main/TFG_Alvaro